МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский ядерный университет «МИФИ»
(НИЯУ МИФИ)

На правах рукописи



РЫМОВ ДМИТРИЙ АНДРЕЕВИЧ

ФОРМИРОВАНИЕ И РЕКОНСТРУКЦИЯ ОПТИЧЕСКИХ СИГНАЛОВ НА ОСНОВЕ НЕЙРОСЕТЕВЫХ МЕТОДОВ, АДАПТИРОВАННЫХ ДЛЯ ФОТОННЫХ СИСТЕМ

Диссертация на соискание ученой степени кандидата наук
Специальность 1.3.6 – Оптика

Научный руководитель: доктор физико-математических наук
Стариков Ростислав Сергеевич

Москва 2026

Оглавление

Введение 5
1. Обработка сигналов в фотонике и информационной оптике 12
1.1 Сигналы в оптике 12
1.2 Голография 13
1.2.1 Синтез компьютерных голограмм 15
1.2.2 Восстановление изображений из голограмм и их фильтрация 19
1.3 Обработка сигналов в микроволновой фотонике 26
1.4 Оптическое кодирование информации 28
1.4.1 Оптическое кодирование с использованием когерентного освещения 28
1.4.2 Оптическое кодирование с использованием пространственно-некогерентного излучения 29
1.5 Нейронные сети в оптической обработке информации 31
1.5.1 Сверточные нейронные сети 32
1.5.2 Функции активации 34
1.5.3 Функции потерь 36
1.5.4 Обучающие выборки 37
1.6 Основные архитектуры сверточных нейронных сетей 38
1.6.1 Сверточные нейронные сети 38
1.6.2 Генеративно-состязательные модели 40
1.6.3 Обучение с учителем и без учителя 42
1.6.4 Физически-информированные нейронные сети 43
1.7 Нейросетевая обработка световых распределений 44
1.7.1 Нейросетевой синтез компьютерных голограмм 44
1.7.2 Нейросетевое восстановление изображений из голограмм 45
1.7.3 Нейросетевая обработка сигналов в микроволновой фотонике 46
1.7.4 Нейросетевой криптографический анализ системы оптического кодирования 46
1.8 Метрики численной оценки качества изображений 47
Выводы по первой главе 49
2. Синтез компьютерных голограмм с использованием физически-информированной нейронной сети 50

2.1 Методы синтеза компьютерных голограмм, основанные на парном обучении 50
2.2 Интеграция численной модели дифракции Френеля в физически-информированную нейронная сеть 55
2.3 Разработанная двухканальная нейросетевая архитектура для синтеза компьютерных голограмм трехмерных сцен 58
2.4 Численное восстановление изображений из голограмм, синтезированных предложенным нейросетевым методом 61
2.4.1 Создание обучающей выборки, специализированной для задач голографии 63
2.4.2 Обучение нейронной сети с использованием обучающей выборки большого объема 69
2.4.3 Синтез компьютерных голограмм с различными параметрами оптической системы 72
2.5 Синтез компьютерных голограмм цветных сцен 74
2.6 Оптическое восстановление изображений из компьютерных голограмм 3D-сцен 77
Выводы по второй главе 84
3. Нейросетевая фильтрация голограмм 2D- и 3D-сцен 85
3.1 Методы восстановления изображений из голограмм, основанные на парном обучении 85
3.2 Разработанная двухканальная нейросетевая архитектура для фильтрации голограмм 87
3.3 Синтез обучающей выборки 88
3.4 Фильтрация голограмм 2D-сцен 89
3.5 Фильтрация голограмм 3D-сцен 90
Выводы по третьей главе 95
4. Восстановление сигналов в микроволновой фотонике 96
4.1 Нейросетевая фильтрация однотоновых сигналов 96
4.2 Нейросетевая фильтрация двухтоновых сигналов 103
Выводы по четвертой главе 108
5. Нейросетевой криптоанализ системы оптического кодирования с пространственно-некогерентным освещением 109
5.1 Численное моделирование оптического кодирования с пространственно-некогерентным освещением 110

5.2 Архитектура нейронной сети для криптоанализа оптического кодирования 113

5.3 Воссоздание ключей из численно-синтезированных кодированных изображений 114

5.4 Воссоздание ключей из оптически-зарегистрированных кодированных изображений 116

Выводы по пятой главе 121

Заключение 122

Список литературы 124

Введение

Современные задачи обработки информации предъявляют все более высокие требования одновременно и к информативности используемых сигналов, и к скорости их обработки. Методы и средства фотоники и оптической обработки информации уже обеспечивают чрезвычайно высокие возможности формирования, передачи и преобразования временных и пространственных сигналов. К середине 2020-х годов были продемонстрированы фотонные и оптические системы различного принципа действия и функционала, обеспечивающие пропускную способность до десятков Пбит/с при передаче и до десятков Гбит/с при обработке. Новейшая мировая практика демонстрирует, что в самом ближайшем будущем применение оптики позволит передавать и преобразовывать информацию со скоростями, физически недостижимыми для традиционных электронных подходов.

Задачи построения высокопроизводительных фотонных и оптических информационных систем предполагают неуклонный рост качества используемых сигналов, в том числе терабитных цифровых потоков, сверхширокополосных (сотни ГГц) аналоговых сигналов и пространственных сигналов высокого разрешения (вплоть до Гпикс). Существующие точностные ограничения оптики обусловили необходимость поиска новых подходов к формированию и реконструкции оптических сигналов в обсуждаемых системах. Перспективным направлением в данной области является разработка и применение нейронных сетей, а конкретно – нейронных сетей сверточных архитектур. Такие нейронные сети позволяют оперативно и с высоким качеством формировать и обрабатывать пространственные и временные световые распределения, что создает широкий диапазон потенциальных применений. Однако большинство существующих подходов полагается на способность нейронных сетей находить некую связь между входными и выходными сигналами без учета физических особенностей решаемой задачи. Это позволяет получать

качественные результаты, но, зачастую, с большими затратами временных и/или вычислительных ресурсов. Особенности и ограничения применения нейронных сетей для фотонных систем на данный момент остаются слабо изученными.

К наиболее популярным разделам оптической обработки информации, в которых активно применяются нейросетевые методы, относятся голография, оптическое кодирование и микроволновая фотоника. Именно для них выявление и оценка влияния физической реализации поставленных задач на эффективность применения нейронных сетей представляют наибольший практический интерес.

Так, современные нейросетевые методы синтеза компьютерных голограмм уже интегрируют численные модели расчета дифракции в процесс обучения. Однако условия применения обученной нейронной сети для синтеза голограмм, оптимизированных под конкретную аппаратную реализацию системы оптического восстановления (со значениями длины волны лазерного излучения, размера пикселя пространственно-временного модулятора света и расстояния до плоскости восстановления, отличающимися от использованных в процессе обучения) остаются слабо изученными. С другой стороны, существующие нейросетевые методы восстановления изображений из голограмм создают однозначную связь между входными и выходными данными, что не позволяет изменить параметры восстановления или реализовать дополнительную постобработку голограммы за счет фильтрации ее пространственных частот. В области оптического кодирования незакрытой остается задача нейросетевого криптографического анализа методов, использующих пространственно-некогерентное освещение. В микроволновой фотонике нейросетевой подход может быть применен для обработки сигналов аналоговых оптических трактов с целью восстановления исходного качества передаваемых сигналов в условиях, когда классические алгоритмические подходы не дают удовлетворительного результата.

Целью работы является разработка, исследование и совершенствование нейросетевых методов формирования и реконструкции оптических сигналов с применением численной модели дифракции и фильтрации пространственных частот для перспективных высокопроизводительных фотонных систем. Для достижения поставленной цели необходимо решить следующие задачи:

Задачи исследования

Для достижения поставленной цели необходимо было решить следующие задачи:

1. Интегрировать математическую модель расчета дифракции в нейросетевой метод синтеза компьютерных голограмм 3D-сцен и адаптировать его для учета ключевых параметров оптической системы (длина волны лазерного излучения, размер пикселя пространственно-временного модулятора света, расстояния от плоскости голограммы до плоскостей восстановления).

2. Определить требования и реализовать алгоритмы создания оптимальных обучающих выборок, предназначенных для нейросетевого синтеза и фильтрации голограмм.

3. Синтезировать голограммы 3D- и цветных сцен с различными параметрами оптической системы, с использованием разработанной физически-информированной нейронной сети.

4. Разработать метод подавления нулевого порядка дифракции, который позволил бы извлекать объектную информацию из голограмм 2D- и 3D-сцен без необходимости подбора входных параметров фильтрации.

5. Исследовать возможности подавления шумов и нелинейных искажений сигналов, записанных на выходе аналогового оптического тракта.

6. Применить нейросетевой метод в рамках криптографического анализа системы оптического кодирования с пространственно-некогерентным освещением с целью выявления ее уязвимостей.

Методы исследования

Задачи, поставленные в работе, решались с помощью численного моделирования и проведения оптических экспериментов. Моделирование распространения света выполнялось с использованием численной модели расчета дифракции Френеля. Численные эксперименты проводились в рамках стандартов цифровой и нейросетевой обработки изображений. Оптические эксперименты включали создание установки для оптического восстановления голограмм, проведение регистраций восстановленных изображений и сравнение полученных результатов с результатами численного моделирования.

Научная новизна

1. Разработана физически-информированная нейронная сеть, которая позволяет синтезировать голограммы 3D- и цветных сцен с параметрами численной модели дифракции, отличными от использованных при обучении.

2. Впервые оптически восстановлено изображение 3D-сцены, содержащей 16 сечений мегапиксельного разрешения, из компьютерной голограммы, синтезированной с использованием нейросетевых подходов.

3. Разработан метод нейросетевого излечения объектной волны в плоскости голограммы, который при использовании частотной фильтрации устраняет нулевой порядок дифракции из восстановленных изображений 3D-сцен.

4. Предложена схема нейросетевой криптографической атаки, воссоздающая ключи кодирования с точностью, достаточной для извлечения оптически кодированной информации.

Практическое значение

1. Разработанный неитеративный нейросетевой метод синтеза компьютерных голограмм 3D- и цветных сцен может быть использован для макетирования, оптимизации и аппаратной реализации систем 3D- и голографического отображения.

2. Разработанный метод синтеза компьютерных голограмм может быть использован для формирования заданных распределений светового поля в задачах оптического захвата атомов, фотостимуляции нейронов, микробиологии и др.

3. Разработанный метод фильтрации нулевого порядка дифракции может быть применен для упрощения процесса получения качественных голографических изображений (например, в микроскопии).

4. Применение нейросетевой обработки сигналов аналоговых оптических трактов позволяет подавлять искажения выходного сигнала тракта, обусловленные нелинейностью его элементов.

5. Разработанная схема криптографической атаки на систему оптического кодирования с пространственно-некогерентным освещением может быть использована в рамках криптографического анализа для выявления и устранения уязвимостей и создания более надежных систем оптического кодирования.

Положения, выносимые на защиту

1. Интеграция численной модели дифракции в нейронную сеть позволяет синтезировать голограммы 3D-сцен в широком диапазоне параметров оптической системы без дополнительного обучения, и с быстродействием, на порядок превышающим итеративные алгоритмы.

2. Применение разработанного нейросетевого метода позволяет за одну итерацию синтезировать компьютерную голограмму 3D-сцены, содержащей

до 16 сечений мегапиксельного разрешения, с качеством оптического восстановления, соответствующим итеративным подходам с точностью 99,5%.

3. Комбинация извлечения объектной волны в плоскости голограммы и частотной фильтрации позволяет устранить нулевой порядок дифракции из восстановленного изображения 3D-сцены и повысить значение индекса структурного сходства в 2,5 раза по сравнению с фильтрацией без извлечения.

4. Предложенный нейросетевой метод воссоздания ключей кодирования оптической криптографической системы с пространственно-некогерентным освещением обеспечивает корректное декодирование с вероятностью не менее 95%.

Апробация работы

Основные результаты диссертационной работы были представлены автором на российских и международных конференциях:

- «Фотоника и информационная оптика» (Москва, 2019-2026);
- «ГОЛОЭКСПО» (Геленджик, 2021; Уфа, 2025);
- «Технологии дополненной и виртуальной реальности» (Москва, 2025);
- «Всероссийская конференция по проблемам динамики, физики частиц, физики плазмы и оптоэлектроники» (Москва, 2024);
- «Невская фотоника» (Санкт-Петербург, 2023);
- «Современные проблемы физики и технологий», (Москва, 2022);
- «Фундаментальные проблемы оптики–2019», (Санкт-Петербург, 2019).

Публикации по теме

По теме диссертации опубликовано 33 работы, из которых 5 статей в рецензируемых научных изданиях, включённых в Перечень ВАК и/или базы данных Web of Science или Scopus, имеющих квартили Q1 (1 работа), Q2

(1 работа), Q3-Q4 (1 работа), К3 (2 работы), 2 свидетельства о регистрации программ для ЭВМ (РИД) и 26 тезисов докладов в сборниках трудов международных и всероссийских конференций, индексируемых в базе данных РИНЦ.

Структура и объем работы

Диссертация состоит из введения, 5 глав, заключения и списка литературы. Общий объем диссертации составляет 133 страницы, включая 69 рисунков, 12 таблиц и список литературы из 121 наименований.

1. Обработка сигналов в фотонике и информационной оптике

1.1 Сигналы в оптике

Фотоника – это научно-технологическое направление, посвященное применению света для обработки и передачи информации. Сигналом в данном случае будет являться модулированное световое излучение. Для модуляции амплитудно-фазовых характеристик могут быть использованы пространственно-временные модуляторы света (ПВМС). В то время как подходы фурье-анализа позволяют управлять пространственными частотами световых распределений.

Сигналы в фотонных системах позволяют передавать информацию с высокой частотой (ТГц) и высокой степенью параллелизма, и позволяют создавать многоканальные системы передачи информации, используя различные параметры излучения, такие как длина волны или поляризация.

Голографические оптические системы позволяют осуществлять регистрацию, преобразование и восстановление амплитудной и фазовой составляющих волнового фронта.

В голографии активно применяются методы фильтрации в пространственной или фурье-плоскости для подавления влияния нежелательных порядков дифракции, возникающих в процессе восстановления изображения исходной сцены. Под исходной сценой в данном случае понимается объект, изображение которого регистрируются с помощью голограммы. В процессе восстановления свет распространяется от плоскости голограммы до плоскости восстановления, в и которой формируется изображение объекта.

Синтез компьютерных голограмм (КГ) – подход на основе решения обратной задачи дифракции путем численного расчета распространения света, позволяющий создать голограмму, формирующую заданное изображение. Изображения, записанные на КГ, могут быть восстановлены как численно, так и оптически, например, с использованием ПВМС.

Другой областью, активно использующей голографические подходы, является оптическое кодирование, которое позволяет создавать быстродействующие и надежные криптографические системы. Оптическое кодирование основывается на операции свертки исходного изображения с ключом кодирования, реализуемой оптически. Результатом свертки является кодированное изображение, которое может быть впоследствии декодировано с использованием корректного ключа. Особый интерес представляет кодирование с использованием пространственно-некогерентного освещения, обладающее более простой аппаратной реализацией и не подверженное спекл-шуму.

Таким образом, фотонные системы, основанные на использовании световых волн для передачи и обработки сигналов, применяются для широкого круга задач. Преобразования сигналов в таких системах могут быть описаны в рамках скалярной теории дифракции и на основе подходов фурье-анализа.

1.2 Голография

Голография – это интерференционный метод регистрации как амплитудной, так и фазовой составляющих световой волны. Он реализуется за счет регистрации интерференционной картины между двумя когерентными волнами: объектной и опорной. Объектная волна несет информацию о регистрируемом объекте и при интерференции со свободно распространяющейся опорной волной интерференционная картина будет зависеть от разности фаз двух волн.

В области голографии можно выделить три основных подхода, в зависимости от метода регистрации или синтеза:

- Аналоговая голография – оптические интерференционные методы регистрации волновых полей в фоторегистрирующей среде; оптическое восстановление волн.

- Цифровая голография – оптические интерференционные методы регистрации волновых полей с использованием матричных фоторегистраторов; численная обработка и восстановление волн, а также оптическое восстановление путем вывода на физический носитель.
- Компьютерная голография – численный расчет распространения излучения; численная обработка и восстановление волн или оптическое восстановление путем вывода синтезированных КГ на физический носитель.

Пример схемы регистрации цифровой голограммы (ЦГ) представлен на рис. 1.1.

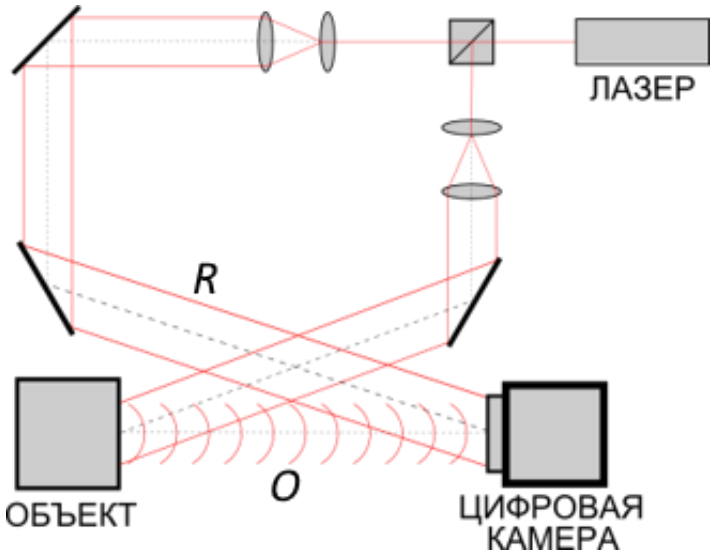


Рис. 1.1 Оптическая схема регистрации цифровой голограммы, O – объектная волна, R – опорная.

Пусть объектная волна $O(x,y)$ определяется как комплексный фазор:

$$O(x,y) = O'(x,y)e^{-i\varphi(x,y)}, \quad (1.1)$$

где $O'(x,y)$ – амплитуда волны, $\varphi(x,y)$ – ее фаза. Опорная волна аналогичным образом записывается как:

$$R(x,y) = R'(x,y)e^{-i\psi(x,y)}, \quad (1.2)$$

Суммарная зарегистрированная интенсивность при интерференции опорной и объектной волн:

$$I(x,y) = |O'(x,y)|^2 + |R'(x,y)|^2 +$$

$$+2\ O'(x,y)R'(x,y)\ \cos[\psi(x,y) - \varphi(x,y)], \qquad (1.3)$$

Третий член выражения зависит от разности фаз опорной и объектной волн. Таким образом, при записи голограммы сохраняется информация как об амплитуде, так и о фазе объектной волны.

1.2.1 Синтез компьютерных голограмм

Компьютерные голограммы могут быть рассчитаны как результат численного синтеза. Численный синтез КГ представляет собой решение обратной задачи дифракции, т.е. голограмма рассчитывается для заранее определённого изображения сцены, которое и будет в последствии восстанавливаться.

Самым распространенным на данный момент алгоритмом расчета КГ является алгоритм Герчберга-Сэкстона (ГС) [1]. Он позволяет численно рассчитывать качественные фазовые КГ для произвольных изображений за несколько десятков итераций.

Итерация алгоритма ГС представлена на рис. 1.2 и может быть описана следующим образом:

1. Выбор целевой амплитуды (в плоскости восстановления изображения) и начального приближения фазы (в плоскости голограммы).
2. Расчет дифракции световой волны, обладающей соответствующей фазой, от плоскости голограммы до плоскости восстановления.
3. Замена амплитуды полученной волны на целевую амплитуду.
4. Обратный расчет дифракции от плоскости восстановления до плоскости голограммы.
5. Сохранение фазовой составляющей полученной волны.
6. Принятие полученного фазового распределения как голограммы или возврат на шаг 2.

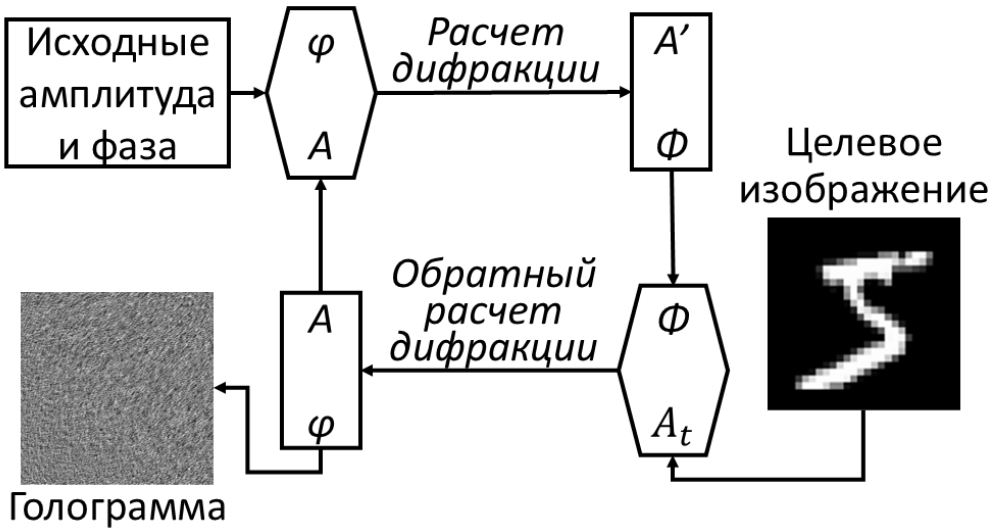


Рис. 1.2 Схема алгоритма ГС.

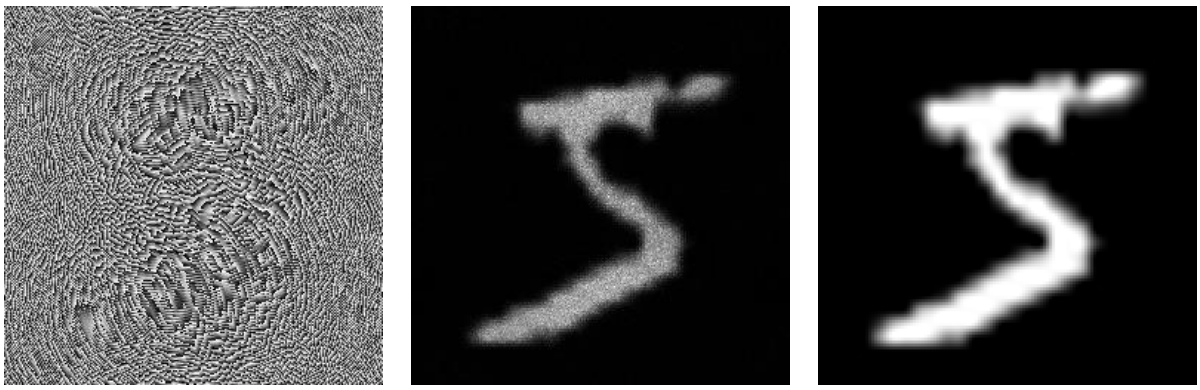
Для расчета дифракции световой волны обычно используют преобразования Френеля (ур. 1.4).

$$\text{К}\,(\text{x},\text{y}) = \frac{exp(jkz)}{j\lambda z} \times exp\left(\frac{j\pi}{\lambda z}(x^2 + y^2)\right) \times$$

$$\times FFT\left(H(u,v) \times exp\left(\frac{j\pi}{\lambda z}(u^2 + v^2)\right)\right), \quad (1.4)$$

где К (x, y) – распределение оптического поля в плоскости восстановления, k – волновое число, z – расстояние от плоскости голограммы до плоскости восстановления, λ – длина волны, $H(u, v)$ – распределение оптического поля в плоскости голограммы, (u, v) – координаты в плоскости голограммы, (x, y) – координаты в плоскости восстановления, FFT – преобразование Фурье.

В качестве начального приближения фазы обычно используют случайные равномерно распределенные значения от 0 до 2π. Примеры КГ, синтезированной с использованием алгоритма ГС, и изображения, восстановленного из нее, показаны на рис. 1.3.



(а) (б) (в)

Рис. 1.3 (а) – КГ, синтезированная с использованием алгоритма ГС; (б) – восстановленное из нее изображение; (в) – исходное изображение.

Фазовые КГ, синтезированные с использованием алгоритма ГС, преобразуют падающее на них излучение в один дифракционный порядок, соответствующий формируемому изображению объекта. Таким образом, теоретическая дифракционная эффективность фазовых КГ может приближаться к 100%, что означает что вся интенсивность излучения, падающая на КГ, будет формировать восстановленное изображение без потерь на неинформативные порядки дифракции. КГ могут использоваться в качестве фокусирующих элементов [2], для создания 3D-сцен [3], распознавания изображений и других задач [4].

Алгоритм ГС также может быть использован для синтеза КГ, содержащих изображения 3D– и цветных сцен. Под 3D-сценой в данном случае понимается набор плоских сечений, находящихся вдоль оси распространения излучения. Пример 3D-сцены, составленной из нескольких сечений, представлен на рис. 1.4. При распространении света от плоскости голограммы будет формироваться несколько плоскостей восстановления, каждая из которых соответствует одному из сечений исходной 3D-сцены, составляя таким образом восстановленное изображение 3D-сцены.

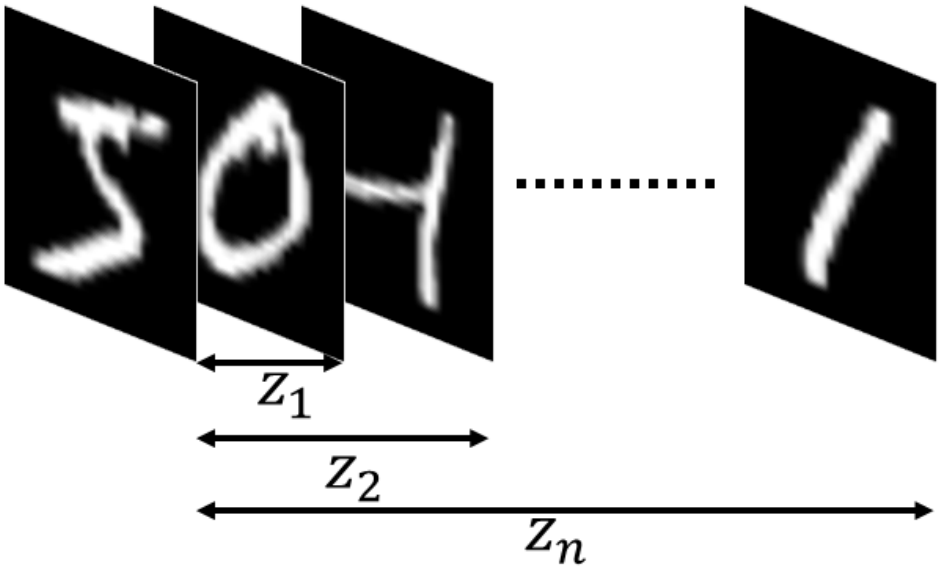


Рис. 1.4. Пример формирования 3D-сцены из набора плоских изображений.

Алгоритм ГС для синтеза КГ 3D-сцен может быть описан следующими шагами:

1. Выбор целевой амплитуды (набора сечений, составляющих 3D-сцену) и начального приближения фазы.
2. Расчет дифракции от плоскости голограммы до плоскостей восстановления (заданное расстояние для каждого сечения).
3. Замена амплитуды полученной волны на целевую амплитуду.
4. Обратный расчет дифракции от плоскости восстановления до плоскости голограммы.
5. Использование только фазовой части полученной волны.
6. Принятие суммы фазовых распределений всех сечений как голограммы или возврат на шаг 2.

Синтез КГ цветных сцен схож с синтезом КГ 3D-сцен, однако восстановленное изображение формируется путем расчета трех цветовых каналов (красный, синий, зеленый) на одинаковом расстоянии от плоскости КГ. В оптической установке данный подход реализуется путем использования трех лазеров с различными значениями длин волн излучения. Пример установки для восстановления КГ цветных сцен представлен на рис. 1.5.

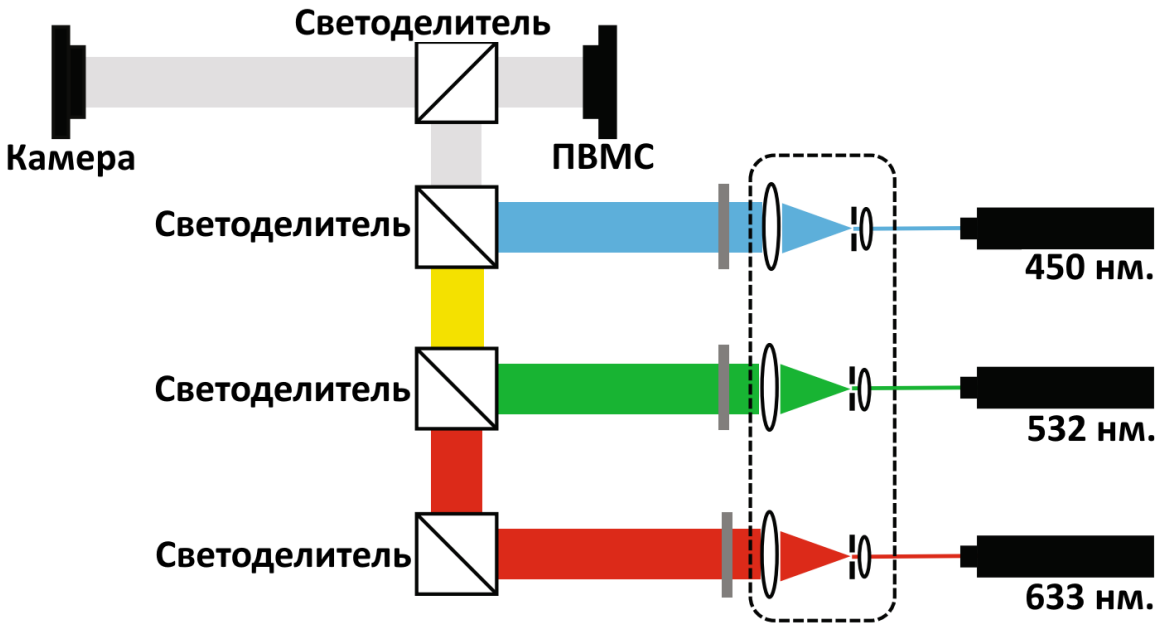


Рис. 1.5. Пример восстановления изображения цветной сцены из голограммы с использованием трех лазеров, с разными длинами волн излучения.

Существующие методы синтеза КГ это, как правило, итеративные методы, часто основанные на алгоритме ГС [5]. Его основным недостатком является его низкое быстродействие, поскольку для получения качественной КГ могут потребоваться десятки или сотни итераций. Следовательно, алгоритм ГС не может обеспечить оперативный синтез КГ. Это особенно заметно в случае синтеза КГ 3D-сцен, когда требуется проводить расчет дифракции для каждого из сечений, формирующих 3D-сцену. Для задач отображения (например, для создания голографических дисплеев или устройств дополненной реальности) может потребоваться синтез КГ 3D– и цветных сцен с быстродействием, близким к реальному времени, что не может быть реализовано с использованием современных итеративных алгоритмов. Одним из вариантов решения этой задачи является создание методов, основанных на использовании нейронных сетей.

1.2.2 Восстановление изображений из голограмм и их фильтрация

Восстановление информации (изображения) из голограммы происходит путем освещения ее когерентной волной. При этом происходит дифракция падающей волны на зарегистрированной интерференционной

картине (голограмме). Схема восстановления изображений из голограмм представлена на рис. 1.6.

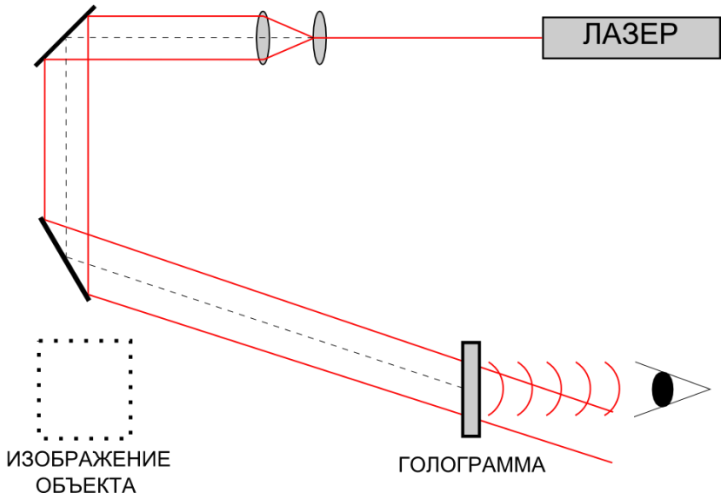


Рис. 1.6 Схема восстановления изображения из голограммы

Суммарная интенсивность опорной и объектной волн может также быть представлена в виде:

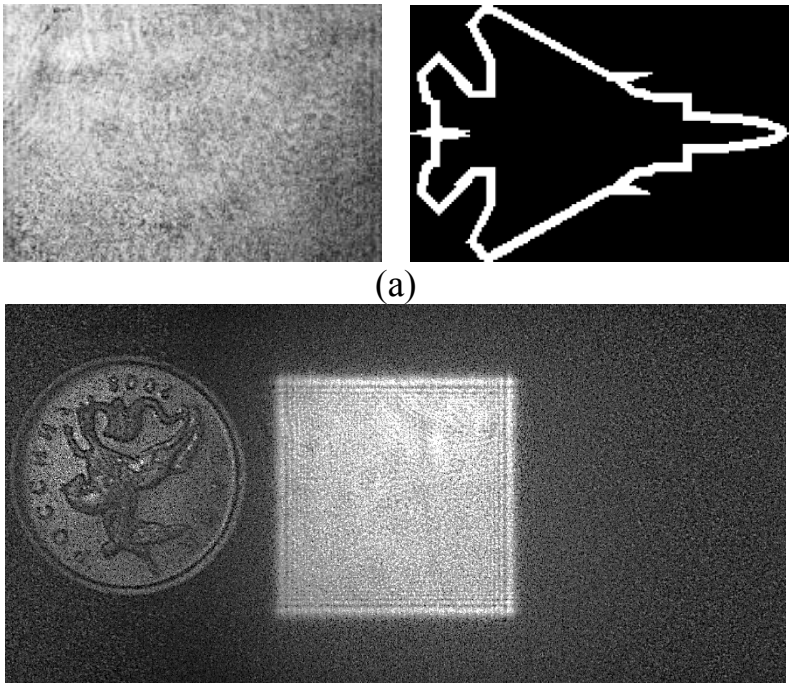
$$I(x,y) = |O(x,y) + R(x,y)|^2 = |O|^2 + |R|^2 + OR^* + O^*R, \qquad (1.5)$$

где O^*, R^* – комплексные сопряженные для волн O и R. При восстановлении изображения из голограммы в плоскости восстановления будут присутствовать три дифракционных порядка. Первые два слагаемых отвечают за «0» порядок, представляющий не продифрагировавшую часть освещающей волны, а третье и четвертое слагаемые отвечают за «-1» и «+1» порядки соответственно. «+1» порядок представляет собой действительное изображение объекта, а «-1» – мнимое [6].

Схема восстановления, представленная на рис. 1.6, может соответствовать как аналоговым голограммам, так и цифровым или компьютерным. Для оптического восстановления компьютерных или цифровых голограмм потребуется их воспроизведение с использованием ПВМС или перенос на физический носитель, например печать на пленке.

В зависимости от угла между объектным и опорным пучком при регистрации, голограммы можно поделить на осевые и внеосевые. В осевых голограммах угол равен нулю и при восстановлении все три порядка дифракции будут перекрываться в пространстве, во внеосевых голограммах

из-за ненулевого угла порядки дифракции могут быть разделены в пространстве, что упрощает получение качественного изображения объекта. Примеры изображений, восстановленных из осевой и внеосевой голограмм, представлены на рис. 1.7.



(а)

(б)

Рис. 1.7 Пример перекрытия изображения нулевым порядком дифракции при восстановлении изображения из осевой голограммы и исходного изображения (а); пример изображения, восстановленного из внеосевой голограммы (б).

Из рис. 1.7 видно значительное негативное влияние нежелательных порядков дифракции («0», «-1»), особенно в случае осевой голограммы, где наблюдается полное перекрытие информативного порядка. Однако некоторые практические применения, например, микроскопия широко используют осевые схемы регистрации, с связи с простотой их реализации для получения изображений высокого разрешения [7]. Таким образом необходимо создание методов подавления нежелательных порядков дифракции для улучшения качества восстановленных изображений.

Для борьбы с нежелательными порядками дифракции в цифровой голографии применяются методы фильтрации. Существуют различные группы методов фильтрации голограмм: линейные и нелинейные, итеративные и неитеративные, действующие как в предметной, так и в частотной областях [6–9]. Неитеративные методы позволяют производить фильтрацию наиболее оперативно, так как не требуют повторных вычислений. Методы, действующие в предметной плоскости, взаимодействуют непосредственно с интенсивностью голограммы, в то время как методы, работающие в частотной плоскости, взаимодействуют с ее фурье-спектром.

Фильтрация в пространственной плоскости подавляет более плавные изменения интенсивности голограммы. Такие изменения часто представляют собой низкочастотные шумы или, например, нулевой порядок дифракции, который является самой значимой составляющей суммарной интенсивности голограммы. В результате фильтрации сохраняются более высокочастотные компоненты. Среди распространенных методов фильтрации в пространственной плоскости можно выделить следующие: вычитание среднего значения интенсивности и вычитание значений, полученных с использованием медианной фильтрации.

Метод вычитания среднего значения [10]: В начале производится нахождение среднего значения интенсивности зарегистрированной голограммы. Далее вычитанием полученного среднего значения из интенсивности каждого отсчета голограммы рассчитывается модифицированный набор интенсивностей голограммы, при восстановлении из которого будет наблюдаться подавление нулевого порядка дифракции. Эффективность данного метода фильтрации обуславливается тем, что наиболее значительный вклад в нулевой порядок вносят интенсивности, значения которых не изменяются на всей плоскости голограммы. Таким образом, вычитание среднего значения может уменьшить вклад нулевого порядка дифракции в восстановленное изображение.

Данный метод прост в применении, но не может быть оптимизирован в зависимости от конкретных параметров голограмм, поскольку вычитание каких-либо других значений интенсивности, кроме среднего, не приведет к улучшению качества восстановленного изображения.

Медианный фильтр [11]: фильтрация голограмм достигается путем вычитания из голограммы значений, полученных с помощью медианной фильтрации (расчет медианного значения интенсивности из окрестности элемента изображения размером $m \times n$). Принцип действия данного фильтра схож с вычитанием среднего значения. Для получения качественного результата важен оптимальный выбор окрестности $m \times n$. Данный метод, как и метод вычитания среднего значения, прост в реализации, но подбор оптимальной окрестности может занять несколько итераций.

Фильтрация в частотной плоскости производит преобразования в фурье-спектре голограммы для подавления частот, отвечающих за нежелательные порядки дифракции.

Метод выбора области обнуления частот [6]: работает за счет умножения фурье-спектра голограммы на маску, обнуляющую частоты, соответствующие «0» и «-1» порядкам дифракции. Результат фильтрации зависит от параметров маски. Изменяя их, можно добиться оптимального уровня фильтрации, сохраняющего «+1» порядок дифракции, максимально снижая влияние остальных. Этот метод позволяет эффективно бороться с неинформативными порядками дифракции, но автоматизация подбора области обнуления может быть затруднительна при необходимости обработки набора голограмм. Неоптимальный же выбор области обнуления может привести к потере полезной информации.

Обнуление частот по порогу [12]: работает за счет того, значения частот, соответствующих «0» порядку дифракции, имеют значительно большие значения, чем «+1» и «-1». Выбрав уровень, выше которого будет происходить обнуление частот, можно добиться уменьшения влияния «0» порядка на восстановленное изображение. Важен оптимальный выбор

порога, поскольку слишком высокий порог будет неэффективен, а слишком низкий приведет к потере полезной информации. Автоматизация определения корректной области обнуления частот для набора голограмм может быть затруднительна, особенно в случаях, когда необходимо обрабатывать голограммы разных типов объектов.

Гауссова фильтрация [12] происходит путем умножения фурье-спектра голограммы на обратную функцию Гаусса. Это позволяет подавить нежелательные порядки дифракции и создать плавный переход между фильтруемыми частотами и частотами, относящимися к «+1» порядку. Фильтрацию можно контролировать, изменяя параметры функции Гаусса. Как и для метода области обнуления частот, оптимальный подбор параметров может быть трудоемкой задачей; ухудшение качества восстановленного изображения в данном случае может происходить из-за сохранения нежелательных частот по краям области фильтрации.

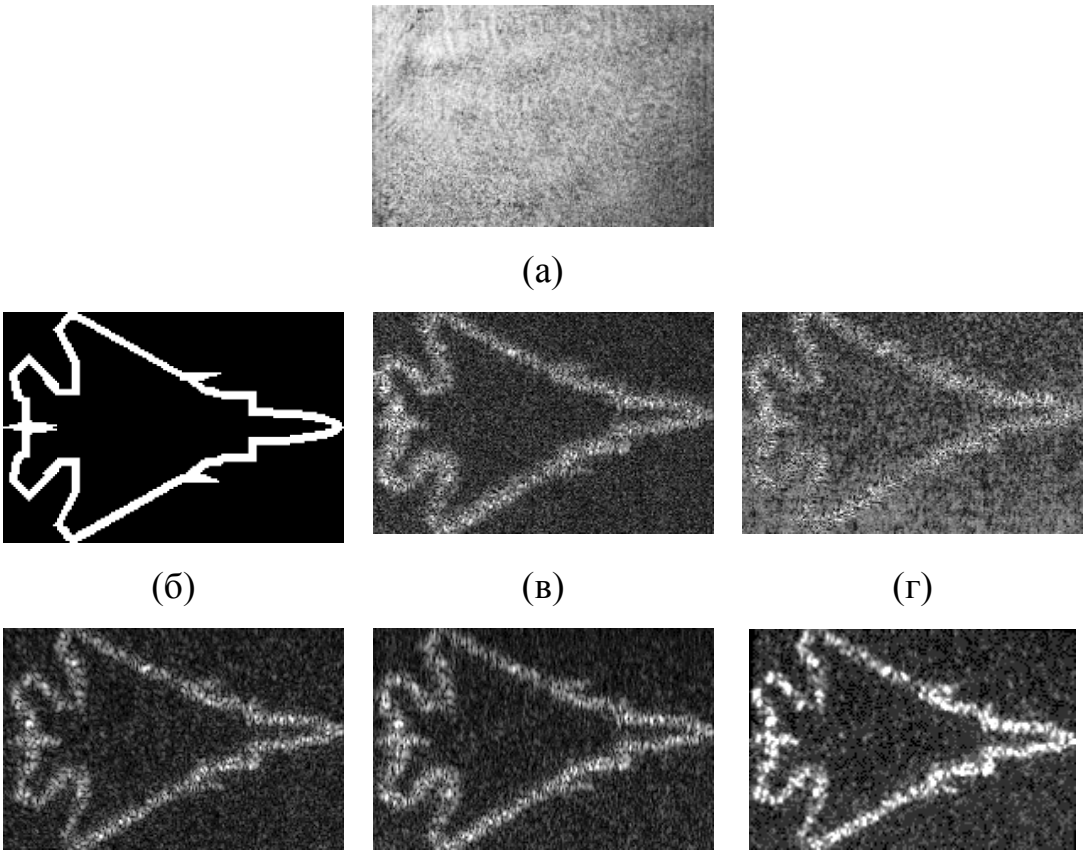
Каждый из рассмотренных методов фильтрации имеет свои ограничения в зависимости от принципа действия и набора параметров, которые контролируют результат. Однако используя и комбинируя основные подходы, можно достигнуть более высокого качества восстановленных изображений.

Комбинированный подход может быть продемонстрирован на примере метода, осуществляющего нелинейную фильтрацию в пространственной плоскости и использующего модификацию фильтра Гаусса в частотной плоскости [13]. Метод заключается в умножении фурье-спектра, рассчитанного на основе логарифма интенсивностей исходной голограммы, на комбинацию обратной функции Гаусса и оконного фильтра:

$$I' = F^{-1}[F[ln(I)] * G] \quad (1.7)$$

где I – интенсивность голограммы, F, F^{-1} – прямое и обратное преобразования Фурье, G – комбинация обратной функции гаусса и оконного фильтра.

Сравнение результатов применения описанных фильтров представлено на рис. 1.8.



(а) (б) (в) (г) (д) (е) (ж)

Рис. 1.8 Изображение, восстановленное из осевой голограммы без применения фильтрации (а): наблюдается перекрытие дифракционных порядков; исходное изображение (б); изображения, полученные после применения различных методов фильтрации: вычитание среднего значения (в); вычитание значений, полученных с использованием медианной фильтрации (г); выбор области обнуления частот (д); гауссова фильтрация (е); комбинированный нелинейный фильтр (ж).

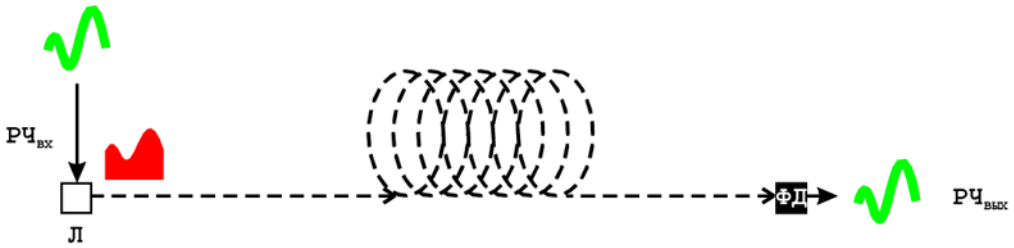
Как видно из рис. 1.8, применение описанных методов фильтрации позволяет восстановить изображения из голограмм, заметно подавляя влияние нежелательных порядков дифракции. Также из рис. 1.4 видно, что использование комбинации методов приводит к дальнейшему повышению качества. Однако комбинированные методы с большим числом параметров

могут быть сложны в применении. Например, при фильтрации набора голограмм объектов различных типов с отличающимися параметрами фильтрации автоматизация процесса подбора параметров может быть трудоемкой. Следовательно, существует необходимость создания альтернативных методов, которые могут позволить оперативно производить фильтрацию голограмм без необходимости подбора параметров фильтрации и со сравнимым или превосходящим качеством восстановленного изображения. Одним из перспективных подходов к решению этой задачи может являться создание методов, основанных на использовании нейронных сетей.

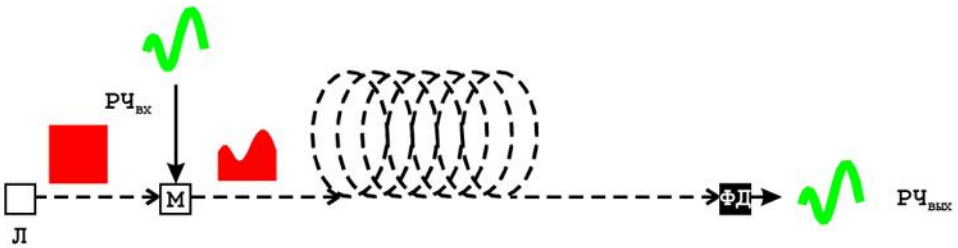
1.3 Обработка сигналов в микроволновой фотонике

Аналоговый оптический тракт (АОТ) является базовым элементом систем микроволновой фотоники [14]. Различные варианты оптоволоконных АОТ широко применяются в радиотехнических системах различного назначения. АОТ обеспечивают широкую полосу частот передачи, а также устойчивость к внешнему электромагнитному воздействию.

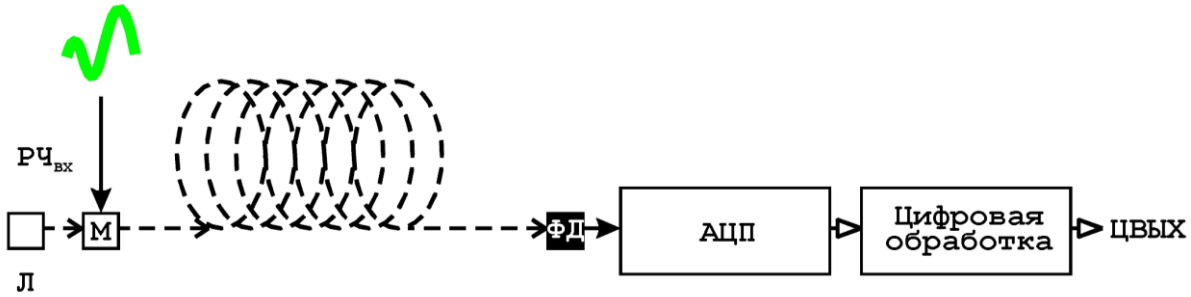
Существует два основных типа АОТ, различающиеся по типу модуляции – с прямой и с внешней. В настоящее время, с активным развитием цифровых технологий актуальным вариантом реализации является АОТ с цифровым выходом (рис. 1.9).



(а)



(б)



(в)

Рис. 1.9 АОТ с прямой модуляцией (Л – лазер, ФД – фотодетектор) (а); АОТ с внешней модуляцией (М – модулятор) (б); АОТ с внешней модуляцией с цифровым выходом (в).

Эффективность применения АОТ ограничивается наличием шумов и нелинейных искажений, ухудшающих качество выходного сигнала. Одной из актуальных задач является линеаризация сигналов АОТ, поскольку нелинейные искажения не могут быть компенсированы фильтрацией.

Существуют различные методы линеаризации – как аппаратные, так и алгоритмические. Алгоритмические методы позволяют производить цифровую обработку сигнала АОТ и являются перспективным направлением [15].

Одним из распространенных методом обработки является цифровая обратная передача. Она основана на, решении нелинейного уравнения Шредингера для моделирования обратного распространения сигнала. Это позволяет подавить искажения, возникающие из-за нелинейных эффектов, такие как самофазовая и кроссфазовая модуляция. Оптоволокно разбивается на множество коротких участков, на каждом из которых рассчитываются и компенсируются потери от дисперсии и нелинейности. Это позволяет существенно повысить качество сигнала. Однако такой метод требует больших вычислительных затрат, и его эффективность напрямую зависит от точности моделирования волокна и параметров системы.

1.4 Оптическое кодирование информации

1.4.1 Оптическое кодирование с использованием когерентного освещения

Оптическое кодирование является активно развивающейся технологией [16–29] интерес к которой начал расти в 1995 году с создания метода кодирования с двумя случайными фазовыми масками DRPE (double random phase encoding) [30], использующего пространственно-когерентное освещение. Принципиальная схема метода представлена на рис. 1.10.

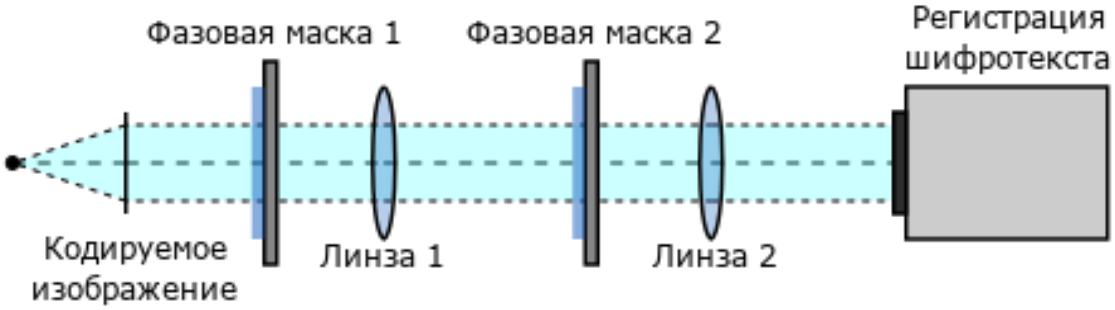


Рис. 1.10 Принципиальная схема оптического кодирования с двумя случайными фазовыми масками.

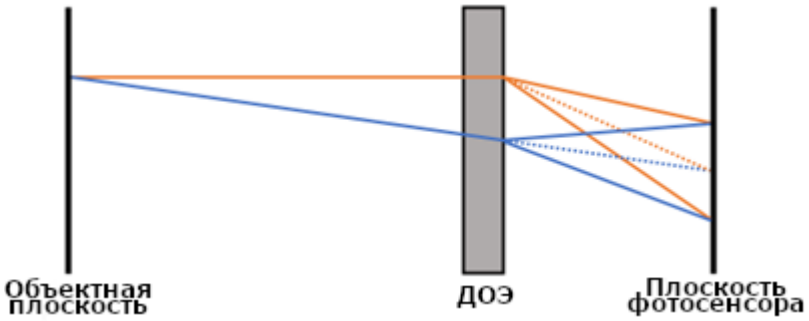
В методе DRPE в процессе кодирования на исходное изображение накладываются две случайные фазовые маски: одна в пространственной и

одна в фурье-плоскости. Затем происходит регистрация кодированного изображения.

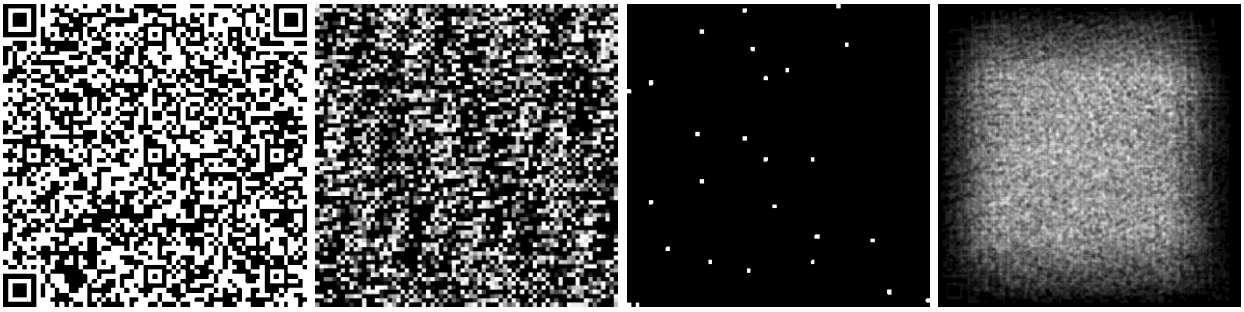
1.4.2 Оптическое кодирование с использованием пространственно-некогерентного излучения

Оптическая реализация DRPE требует высокой точности юстировки применяемого оборудования: так, допустимое смещение фазовых масок не должно превышать 10 мкм. Также получаемые кодированные изображения сильно подвержены влиянию спекл-шума. Альтернативным подходом, лишенным этих недостатков, является использование пространственно-некогерентного освещения. Этот подход был впервые предложен в 2001 году [31]. Кодированные изображение в данном случае представляет собой распределение интенсивности – свертку исходного изображение и ключа кодирования, который является функцией рассеяния точки (ФРТ) дифракционного оптического элемента (ДОЭ), синтезированного с использованием алгоритма ГС. Такой подход имеет ряд преимуществ по сравнению с DRPE, например отсутствие спекл-шума за счет использования пространственно-некогерентного освещения и упрощение оптической реализации из-за отсутствия необходимости голографической регистрации амплитудно-фазовых кодированных изображений [32].

Принципиальная схема процесса оптического кодирования с пространственно-некогерентным освещением, примеры исходного изображения, кодированного изображения и ключа кодирования показаны на рис. 1.11.



(а)



(б) (в) (г) (д)

Рис. 1.11 Схема оптического кодирования с пространственно-некогерентным освещением (а); исходное изображение (б); ДОЭ, содержащий ключ кодирования (в); ключ кодирования (ФРТ ДОЭ) (г); кодированное изображение (д).

Оптическое кодирование с пространственно-некогерентным освещением позволяет эффективно получать кодированные изображения, не подверженные спекл-шуму в процессе регистрации, что позволяет расширить потенциальные практические применения такого подхода в сравнении с более сложным и требовательным к точности юстировки DRPE.

Преимущества оптического кодирования включают высокую криптографическую стойкость за счет большого пространства ключей кодирования (множества доступных реализаций ключа), обеспечиваемого их двумерностью, и высокую пропускную способность, обеспечиваемую оптическими методами обработки информации. Так, современные ПВМС обеспечивают частоту кадров до десятков кГц при мегапиксельном разрешении отображаемого изображения [33,34], что только усиливает интерес к методам оптического кодирования.

Надежность существующих методов оптического кодирования и анализ их уязвимостей являются предметом активных исследований. Одним из обязательных этапов криптографического анализа является изучение устойчивости разрабатываемой системы к различным типам криптографических атак [22,35–39], среди которых отдельную область интересов представляют атаки на использовании нейросетевых подходов.

1.5 Нейронные сети в оптической обработке информации

Нейронные сети (НС) – математические модели, структура которых вдохновлена биологическими нейронными системами.

НС обучаются с использованием больших наборов данных, в которых нейронная сеть в процессе обучения находит структурные и статистические закономерности. Такой набор данных называется обучающей выборкой. Обучающая выборка содержит в себе информацию, которая организована и размечена таким образом, чтобы обеспечить обучение НС в соответствии с поставленной задачей. Например, для задачи распознавания объектов размеченная выборка будет содержать изображения объектов различных классов, и каждому изображению будет соответствовать метка класса. В результате обучения НС становится способна эффективно обрабатывать новые данные схожей структуры, даже если они не были использованы в обучающей выборке.

При построении НС нет необходимости напрямую задавать алгоритм обработки входных данных. После реализации архитектуры НС требуется только подготовить структурированную обучающую выборку, наиболее соответствующую поставленной задаче. Сам процесс обучения также происходит без непосредственного участия человека.

НС имеют широкий набор возможных применений, таких как обработка речи или текста [40], машинное зрение [41] и распознавание образов, синтез изображений [42,43] и другие задачи [44–46].

1.5.1 Сверточные нейронные сети

Широко применяемым типом НС для задач преобразования изображений являются сверточные НС . В их основе лежит структура сетчатки человеческого глаза. Такие сети успешно справляются с задачами, требующими выделение характерных особенностей и закономерностей из изображений. В основе сверточных нейронных сетей лежит операция свертки, схема которой представлена на рис. 1.12. Свертка выполняется с использованием ядра, которое перемещается по цифровому изображению (представленному как матрица чисел) с заданным шагом, ядро перемножается с фрагментами изображения, результатом каждого шага является сумма полученных таким образом значений.

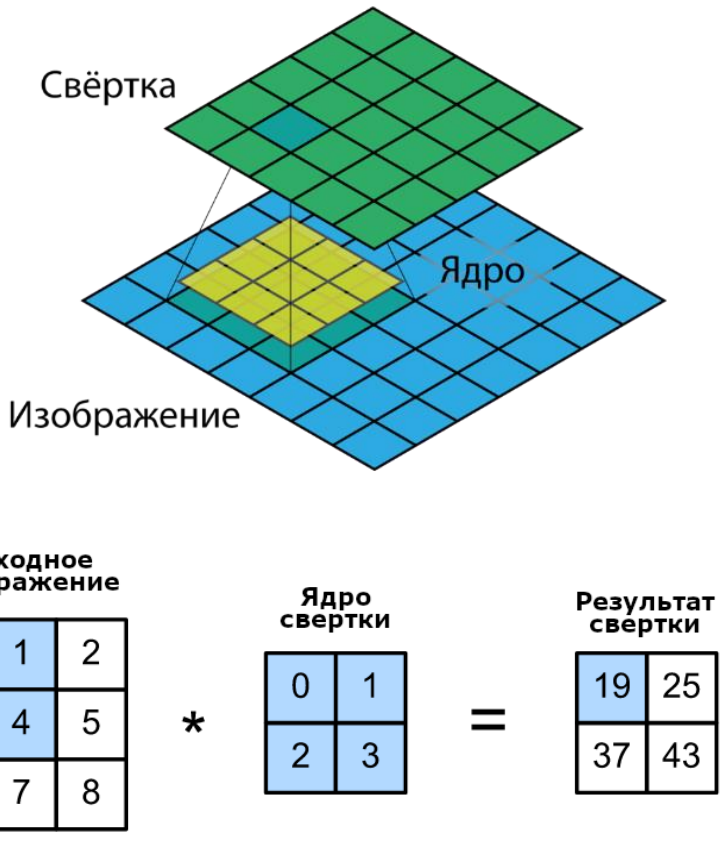


Рис. 1.12 Схема реализации операции свертки.

Сверточный слой НС, как правило, состоит из нескольких ядер свертки. Набор значений, полученных в результате действия всех операций сверточного слоя на исходное изображение, называется картой признаков.

Поскольку ядро свертки проходит по всему изображению, карта признаков будет содержать информацию о всем изображении. На первых слоях НС признаки могут представлять собой простые элементы изображения, такие как границы или простые переходы; последующие операции свертки обучаются извлекать все более сложные и абстрактные признаки.

Другим активно использующимся элементом архитектуры НС является батч-нормализация [47]. В процессе обучения распределения данных, подающихся в сверточные слои, изменяются в зависимости от параметров сети. Наиболее заметным этот эффект будет в глубоких НС с большим количеством слоев. В результате, сверточным слоям требуется перестраиваться под новые значения распределений, что замедляет процесс обучения. Батч-нормализация была разработана для компенсации этого эффекта. Для выполнения батч-нормализации для каждого набора изображений из обучающей выборки (батча) в процессе обучения рассчитывается среднее значение и дисперсия. После нормализации среднее значение каждого батча становится равным нулю, а дисперсия – единице. Батч-нормализация позволяет ускорить обучение глубоких сетей и является стандартным элементом сверточных НС.

Еще одним важным элементом сверточных НС является операция пулинга. Она уменьшает пространственный размер изображений, что позволяет уменьшить вычислительную нагрузку и выделить из изображения наиболее важные для поставленной задачи признаки. Пулинг выполняется путем перемещения ядра пулинга по изображению и отбора на каждом шаге элемента в соответствии с типом пулинга (например, по максимальному или по среднему значению), пример операции пулинга представлен на рис. 1.13.

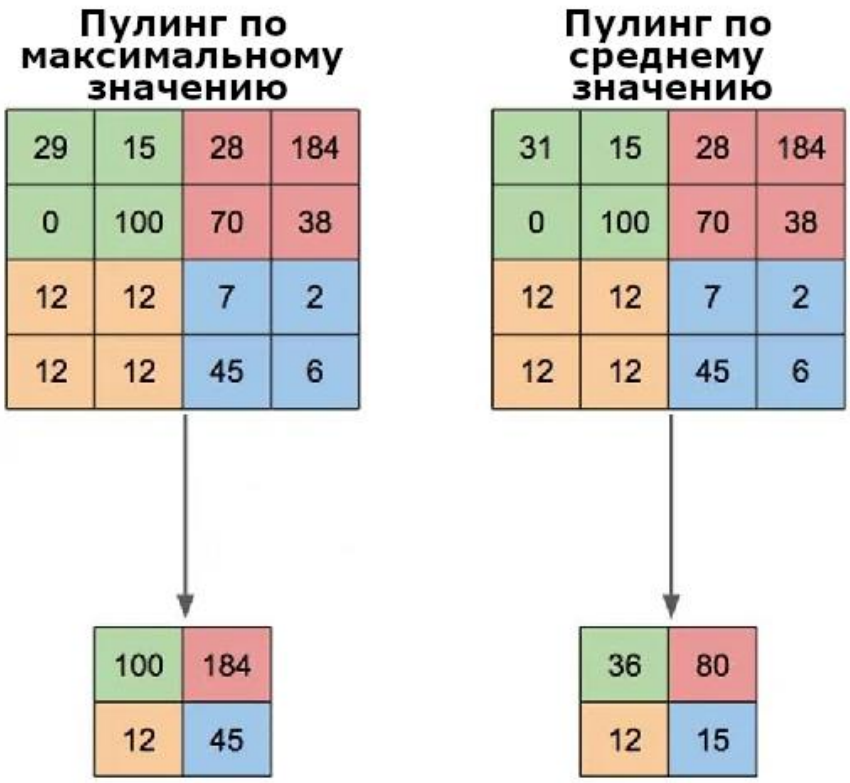


Рис. 1.13 Схема операции пулинга по максимальному и по среднему значению.

Рассмотренные элементы являются основными компонентами, современных сверточных нейронных сетей, и определяют их способность эффективно обрабатывать информацию.

1.5.2 Функции активации

Функции активации являются ключевыми элементами НС. Они вносят нелинейность в нейросетевую модель, что позволяет ей решать более сложные задачи. Добавление функций активации отличает НС от стандартных методов линейной регрессии.

Примерами широко используемых функций активации можно назвать функцию ReLU (Rectified linear unit, рис. 1.14) [48], LeakyReLU [49] и Swish [50].

Функции ReLU, LeakyReLU и Swish могут быть записаны как:

$$ReLU(x) = \begin{cases} 0, & x \leq 0 \\ x, & x > 0 \end{cases}; \quad (1.6)$$

$$leakyReLU(x) = \begin{cases} (0{,}3 * x), & x \leq 0 \\ x, & x > 0 \end{cases}; \quad (1.7)$$

$$Swish(x) = \frac{x}{1 + e^{-x}}, \quad (1.8)$$

где x – выход сверточного слоя.

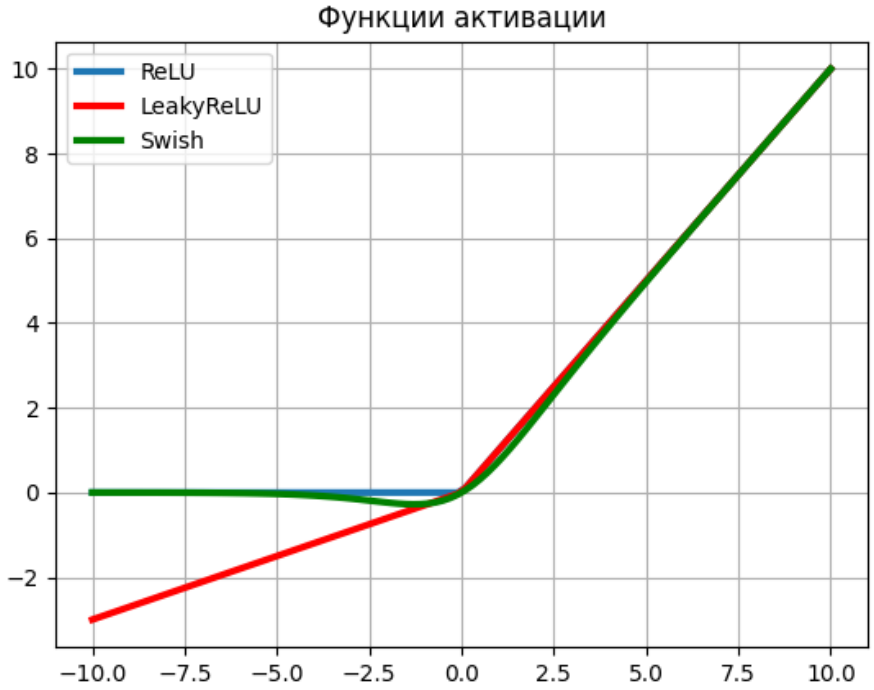


Рис. 1.14 Функции активации ReLU, LeakyReLU и Swish.

Поскольку при отрицательных значениях ввода ReLU равна нулю, могут возникать случаи, в которых результатом действия ReLU оказывается ноль в некоторых фрагментах обрабатываемого изображения, вне зависимости от исходного значения. Большое количество таких фрагментов снижает возможность НС обрабатывать информацию и ухудшает качество работы обученной модели.

Функция LeakyReLU позволяет решить эту проблему за счет добавления к ReLU отрицательной части с некоторым коэффициентом наклона. Это позволяет сохранить информацию и избежать деградации качества обучения в результате обнуления данных.

Swish – гладкая немонотонная функция с перегибом около нуля, что может позволить улучшить качество моделирования сложных зависимостей.

Однако использование Swish приводит к большей вычислительной нагрузке, поскольку она требует расчета экспоненциальных значений.

1.5.3 Функции потерь

Функции потерь – математические метрики, показывающие насколько результат работы НС отличается от истинных значений, заданных обучающей выборкой. Они направляют процесс обучения путем перестройки обучаемых параметров НС, с целью минимизации этой разницы. Количество параметров в НС определяется ее архитектурой (например, количеством сверточных слоев). В зависимости от задачи, число параметров может изменяться от нескольких сотен для простых задач, до миллиардов для больших моделей.

Выбор функции потерь определяется задачей, для которой предназначена НС. Например, для задач преобразования изображений функцией потерь может служить среднеквадратическая ошибка (СКО).

$$\text{СКО} = \frac{1}{n}\sum_{i=1}^{n}(A_i - B_i)^2, \tag{1.9}$$

где A_i, B_i – сравниваемые изображения, n – количество изображений, i – номер изображения.

Она позволяет сравнивать изображения, которые НС синтезирует в процессе обучения, с эталонными. Таким образом НС может обучаться преобразовывать изображения согласно заданным данным.

Функции потерь также могут быть составлены из нескольких функций, например, в уравнении 1.10 показана комбинированная функция потерь для задачи преобразования изображений, состоящая из СКО и функции Accuracy [51]:

$$L = \alpha * \left(1 - \frac{\sum_{i=1}^{n}(A_i - \langle A_i\rangle)(B_i - \langle B_i\rangle)}{\sqrt{\left(\sum_{i=1}^{n}(A_i - \langle A_i\rangle)^2\right)\left(\sum_{i=1}^{n}(B_i - \langle B_i\rangle)^2\right)}}\right) + \\ + \beta * \left(\frac{1}{n}\sum_{i=1}^{n}(A_i - B_i)^2\right), \tag{1.10}$$

где A_j – целевое изображение, B_i – восстановленное изображение, $\langle A_i \rangle$, $\langle B_i \rangle$ – средние значения A_i и B_i, i – номер изображения, n – количество изображений (сечений), α, β – весовые коэффициенты.

Функции потерь контролируют процесс обучения НС в соответствии с поставленной задачей, таким образом, подбор оптимальной функции потерь является ключевым этапом создания эффективной НС [52].

1.5.4 Обучающие выборки

Для обучения НС могут использоваться как экспериментально полученные выборки, так и выборки, синтезированные с использованием численных моделей. Одной из наиболее активно используемых выборок в задачах обработки изображений является набор рукописных цифр MNIST [53] (рис. 1.15). Она представляет собой набор изображений цифр, вручную размеченных в соответствии с их значением, и изначально была предназначена для задачи распознавания. Однако набор MNSIT также активно используется в задачах преобразования изображений, например, в голографии для наглядной демонстрации работы обученных НС.



Рис. 1.15 Примеры изображений рукописных цифр из набора MNIST.

Оптическая регистрация выборок, подобных MNIST – это трудоемкий процесс, поэтому на практике зачастую используются выборки, построенные из численно-синтезированных данных. Использование синтетических обучающих выборок может обеспечить достаточное количество данных, построенных по заданными параметрам, в случаях, когда экспериментальная регистрация невозможна или затруднительна. Так, например, при работе с биологическими тканями, которые не могут быть получены в достаточном количестве, активно используются их численные модели [54,55].

1.6 Основные архитектуры сверточных нейронных сетей

В основе работы сверочных нейронных сетей лежит операция свертки, что позволяет им эффективно работать с цифровыми изображениями, представляющими собой матрицы чисел. В контексте оптической обработки информации необходимо упомянуть, что оптически реализуемая операция свертки является одним из ключевых элементов фурье-анализа. В обоих случаях происходит локальное перемножение и суммирование входного сигнала (пикселей изображения или комплексного распределения светового поля) с ядром (ядро свертки или ФРТ оптической системы).

1.6.1 Сверточные нейронные сети

Одной из самых широко используемых архитектур сверточных НС является Residual Network (ResNet) [56]. Эта архитектура была разработана для решения проблемы затухания градиента – ухудшения качества работы НС при увеличении числа слоев выше некоего порогового значения [57]. До появления ResNet в 2015 году основным способом улучшения качества работы НС было увеличение количества слоев. Однако, при достижении некоего количества начинал проявляться обратный эффект – качество работы сети падало. ResNet решает эту проблему путем добавления промежуточных связей между слоями НС. Промежуточная связь соединяет некоторый слой НС с одним или несколькими последующими напрямую, таким образом

давая более глубоким слоям доступ к информации из более ранних. Пример блока ResNet представлен на рис. 1.16.

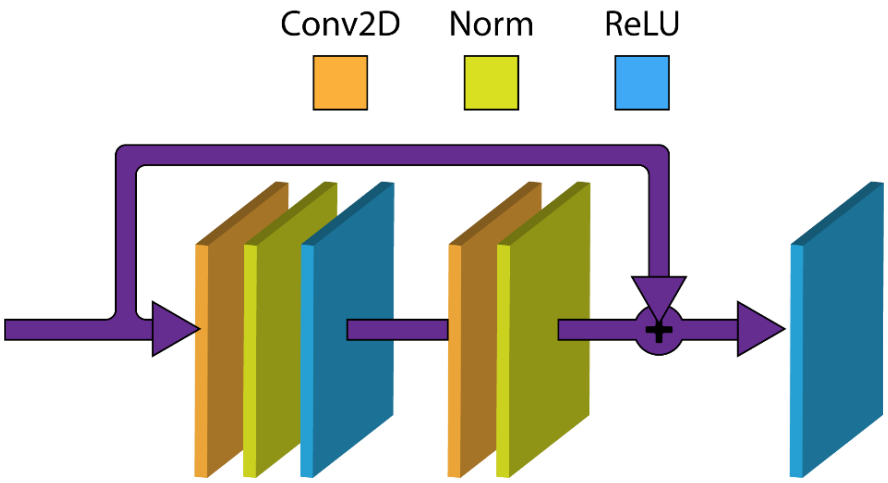


Рис. 1.16 Схема блока архитектуры ResNet.

Наибольшее распространение среди архитектур, используемых для задач голографии, дифракционной оптики, птихографии, когерентной дифракционной визуализации и других задач, получила архитектура U-Net [58]. Архитектура U-Net, представленная на рис. 1.17, имеет две части – энкодер и декодер. Энкодер сжимает и нормализует входные данные, декодер на основе этих данных создает изображение. Промежуточные связи, по аналогии с ResNet помогают НС обрабатывать информацию в процессе обучения. Интерполяция используется для увеличения разрешения синтезируемого декодером изображения, операция конкатенации позволяет без потерь объединить на одной оси промежуточную информацию и информацию, синтезируемой декодером.

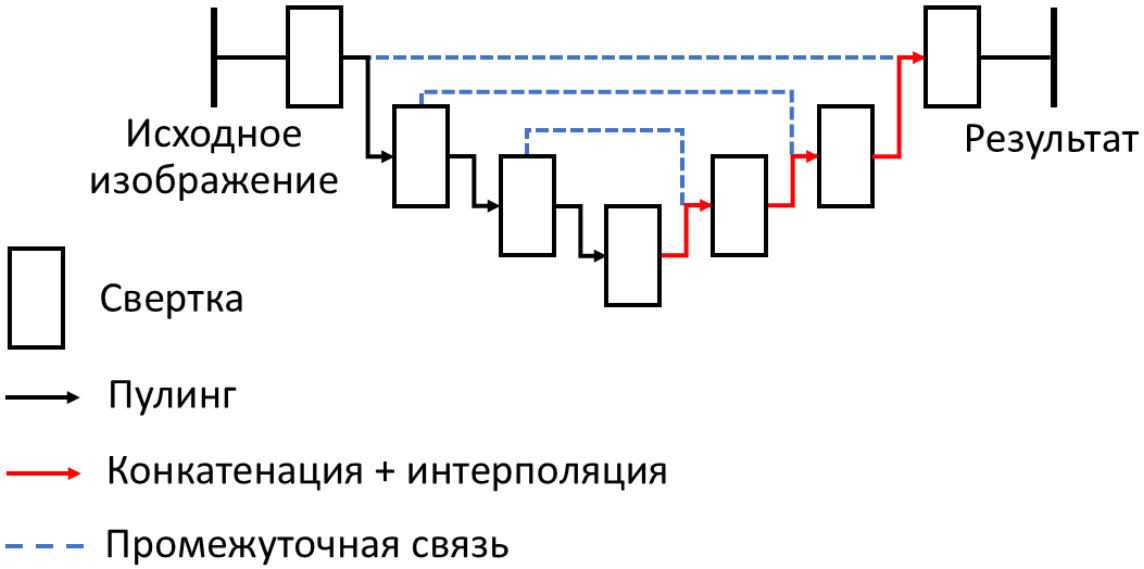


Рис. 1.17 Принципиальная схема архитектуры U-Net.

Эта архитектура эффективно показала себя для решения широкого спектра задач, в частности задач восстановления распределений амплитуды и фазы из голограмм [59–64], поэтому возникло большое количество ее модификаций, оптимизированных под разные задачи. Например, большую популярность получили модификации, содержащие несколько ветвей декодера [65–68]. Такие модификации являются эффективными в случае восстановления нескольких объектных сечений из одной голограммы. Используя несколько ветвей декодера, можно разделить пути синтеза этих объектов и тем самым улучшить итоговое качество восстановления для каждого из них.

1.6.2 Генеративно-состязательные модели

Генеративно-состязательные нейронные сети (ГСН, Generative adversarial network, GAN) на данный момент активно используются для различных задач [69,70]. Они позволяют эффективно создавать и преобразовывать изображения [71]. ГСН-модели представляют собой две НС – генератор и дискриминатор. Обе сети обучаются одновременно и имеют противоположные задачи, т.е. в процессе обучения конкурируют между собой. Генератор создает данные, которые имитируют по своей структуре

реальные данные из обучающей выборки. Дискриминатор, с другой стороны, обучается как на результатах работы генератора, так и данных из обучающей выборки с целью отличить их друг от друга. Дискриминатор таким образом обучается классифицировать данные на две категории: «реальные» и «синтезированные». В свою очередь за счет обратной связи с дискриминатором, генератор учится синтезировать данные близкие к реальным, которые не будут определены дискриминатором. Схема обучения ГСН представлена на рис. 1.18.

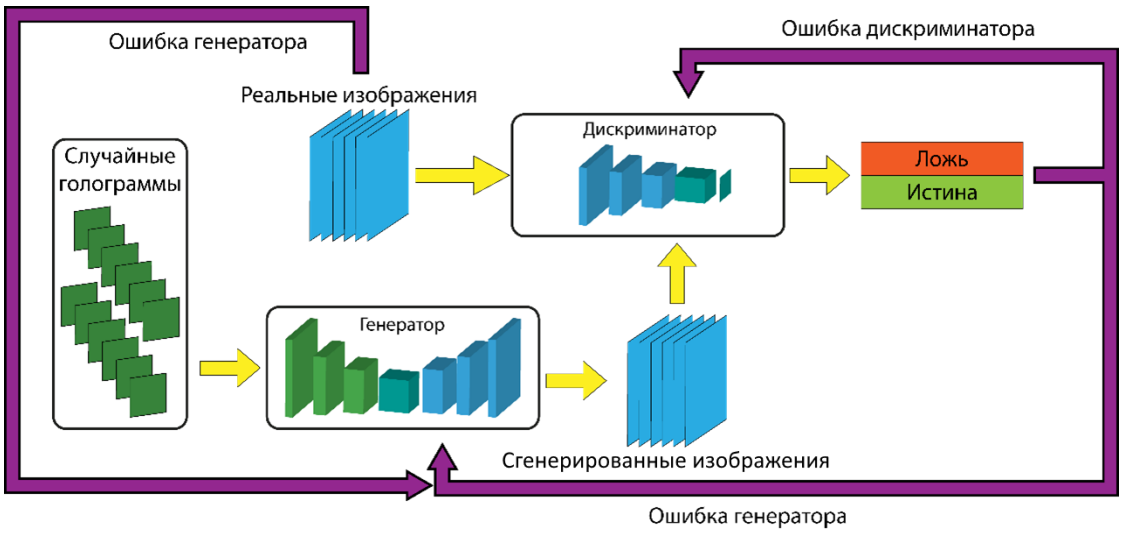


Рис. 1.18 Схема обучения генеративно-состязательной модели.

В качестве генератора как правило используются сверточные НС, например, U-Net или ее модификации. В качестве дискриминатора также используются сверточные НС, но часто с добавлением в конце полносвязанных слоев. Такая структура, позволяет использовать сверточный энкодер для выделения характерных признаков анализируемых данных, а полносвязный декодер использует эти признаки для того, чтобы определить, является ли анализируемое изображение реальным или синтезированным.

Дополнительная информация, получаемая за счет взаимного обучения двух НС, может позволить улучшить качество изображений, синтезируемых ГСН по сравнению с использованием одной НС. Однако обучение двух сетей одновременно требует более тонкого контроля параметров обучения,

поскольку для эффективного конкурентного обучения генератор и дискриминатор должны быть близки к друг другу по производительности на всем протяжении обучения.

1.6.3 Обучение с учителем и без учителя

Все вышеперечисленные нейросетевые архитектуры могут использоваться в задачах обработки изображений. Например, для задач восстановления изображений из голограмм на вход НС при обучении подается голограмма, а на выходе НС ей в соответствие ставится заранее подготовленное восстановленное изображение. Такой метод обучения называют парным (методом с учителем), поскольку для каждой голограммы есть заранее известный конечный результат восстановления. В общем случае обучение с учителем – это метод машинного обучения, заключающийся в использовании размеченной обучающей выборки, состоящей из пар входные данные – конечный результат. НС обучается закономерностям, согласно которым построены данные в выборке, и таким образом обучается обрабатывать данные схожего типа, даже если они не были использованы в процессе обучения.

Обучение без учителя не требует выборки из размеченных данных, в которой каждому исходному изображению соответствует определенное конечное. При непарном обучении эталонные изображения могут отсутствовать полностью или не быть привязаны к конкретным исходным изображениям. Непарное обучение может основываться, например, на цикличном использовании двух генеративно-состязательных моделей: генератор 1 преобразует A в B, а генератор 2 B в A.

Такие подходы позволяют упростить создание обучающих выборок, поскольку не требуется предварительная разметка данных в соответствии с результатом. Следовательно, появляется возможность обрабатывать большие наборы данных с меньшими временными и вычислительными затратами. Однако при непарном обучении требуется оптимальная настройка процесса

обучения, чтобы позволить НС найти корректные закономерности, которые соответствуют поставленной задаче.

Еще одним вариантом реализации непарного подхода является интеграция в НС численных моделей физических процессов, согласно которым НС будет выполнять преобразования данных. Подобные нейросетевые модели называются физически-информированными. Для задач голографии, это может принимать вид интеграции численной модели расчета дифракции в архитектуру НС.

1.6.4 Физически-информированные нейронные сети

Первые нейросетевые методы синтеза КГ основывались на использовании парных обучающих выборок, состоявших из объектов, относительно которых требуется синтезировать КГ, и самих КГ, заранее синтезированных с использованием одного из существующих методов (например, алгоритма ГС). Следовательно, НС обучалась синтезу КГ на основе параметров и особенностей метода, использованного для создания обучающей выборки.

Такой подход позволяет обучить НС, способную синтезировать КГ, с качеством на уровне метода, использованного для создания обучающей выборки. Быстродействие же такой НС может быть в несколько раз выше быстродействия исходного итеративного метода [51,72].

Ограничения же парного подхода проявляются в невозможности использования обученной НС для синтеза КГ с параметрами, отличными от параметров, заданных в алгоритме синтеза обучающей выборки. Например, при необходимости синтеза КГ с длиной волны лазера или расстоянием от плоскости голограммы до плоскости восстановления, отличающимися от использованных в обучающей выборке, потребуется заново синтезировать обучающую выборку с другими параметрами и повторить процесс обучения НС. Также качество КГ, использованное для создания обучающей выборки, является пределом для качества КГ, которое может быть достигнуто НС в процессе обучения.

Для преодоления этих ограничений активно развиваются физически информированные методы, которые используют неразмеченные обучающие выборки. В задаче синтеза КГ это может быть достигнуто с использованием численных моделей расчета дифракции. Это позволяет связать обучение с физическими принципами голографии (физически-информированная НС [73,74]) и направлять обучение для оптимального синтеза КГ.

Для задачи синтеза КГ физически-информированные НС могут позволить обойти ограничения парных моделей, которые требуют создания обучающих выборок с использованием методов с фиксированными параметрами. Поскольку в НС интегрирована численная модель расчета дифракции, параметры оптической системы, такие как расстояние от плоскости голограммы до плоскости восстановления, длина волны лазера, размер пикселя ПВМС могут быть изменены после обучения для создания соответствующих КГ без необходимости создания новой обучающей выборки или повторного обучения НС. Качество КГ, которые могут быть получены обученной физически-информированной НС будет таким образом определяться процессом численной обработки оптической информации в процессе обучения и набором исходных объектов, использованных в качестве обучающей выборки.

1.7 Нейросетевая обработка световых распределений

1.7.1 Нейросетевой синтез компьютерных голограмм

Методы синтеза КГ, основанные на использовании нейронных сетей – это активно развивающаяся область [51,72,75–81]. Среди существующих методов на данный момент наиболее активно развиваются физически-информированные подходы [51,81]. Например, в [51] представлена НС модель, использующая расчет распространения света для восстановления изображения из КГ, как часть функции потерь. Она позволяет создавать качественные КГ произвольных 3D-сцен, имеющих до 11 сечений с разрешением 1024×1024 пикселя, с быстродействием на порядок выше

традиционных алгоритмов. Однако вопрос использования обученной НС для синтеза КГ с различными параметрами оптической системы (такими как длина волны лазера, расстояние от плоскости КГ до плоскости восстановления и размер пикселя ПВМС) рассмотрен не был. Также численный расчет распространения света выполнялся только внутри функции потерь и не был интегрирован непосредственно в архитектуру НС.

1.7.2 Нейросетевое восстановление изображений из голограмм

Восстановление изображений – это всегда актуальная задача в цифровой голографии [82–84]. Восстановление информации из зарегистрированной голограммы требует дополнительной обработки для подавления нежелательных порядков дифракции. Существует множество различных методов фильтрации нулевого порядка, но они могут требовать значительных временных затрат или регистрации нескольких голограмм [7,12,85].

Восстановление изображений из голограмм с использованием НС является перспективным и активно развивающимся направлением [59,60,65–68,86–94]. Преимущества нейросетевых подходов особенно заметны в случае осевой записи голограмм, когда восстановленное изображение объекта может быть полностью перекрыто нежелательными порядками дифракции. Использование классических методов подавления этих порядков усложняет процесс восстановления и может требовать регистрации нескольких голограмм [8]. Существующие нейросетевые подходы предлагают как прямое восстановление интенсивности объекта из голограммы [59,66,86,89], так и извлечение амплитудной и фазовой информации объектной волны [65,67,90,91,95–97].

Использование подходов, основанных на использовании НС, позволяет обеспечить оперативное восстановление качественного изображения, не подверженного нежелательным порядкам дифракции. При этом достаточно

единственной голограммы, что позволяет снизить количество оптически регистрируемых голограмм и упростить процесс регистрации.

Однако существующие методы, как правило, основаны на непосредственном восстановлении исходной объектной информации. Это ограничивает возможности для дальнейшей модификации голограммы, в отличии от традиционных методов фильтрации нулевого порядка. После их применения возможно преобразование фурье-спектра голограммы или расчет распространения излучения от голограммы с иными параметрами.

Таким образом, существует задача создания нейросетевых методов фильтрации нулевого порядка голограмм, которые позволят сохранять голограмму для дальнейшей модификации.

1.7.3 Нейросетевая обработка сигналов в микроволновой фотонике

В настоящее время активно исследуются возможности применения различных архитектур нейронных сетей в задачах цифровой обработки сигналов АОТ, в том числе с целью улучшения качества сигналов АОТ и для выполнения линеаризации [98–106].

В области микроволновой фотоники (радиофотоники) активно исследуются возможности применения различных архитектур свёрточных нейронных сетей с целью линеаризации сигналов АОТ [101–103]. Таким образом, использование нейронных сетей в задаче цифровой обработки сигналов АОТ, имеет тенденцию к дальнейшему развитию, эта область исследований обладает высокой степенью актуальности.

1.7.4 Нейросетевой криптографический анализ системы оптического кодирования

В последние годы активно рассматривается использование НС в рамках криптографического анализа систем оптического кодирования [67,107–116]. Такие методы позволяют находить уязвимости в существующих системах

оптического кодирования информации и, таким образом, ускорять развитие более надежных методов.

Большинство работ в данной области посвящено методам, основанным на кодировании с когерентным освещением. Такие подходы показывают хорошие результаты при нейросетевом воссоздании исходных изображений из кодированных, однако они, как правило, используются для изображений небольшого размера: 32×32 или 64×64 пикселя.

Таким образом, задача криптоанализа систем оптического кодирования с пространственно-некогерентным освещением, использующим изображения с разрешением сопоставимым с разрешением современных ПВМС остается неисследованной.

1.8 Метрики численной оценки качества изображений

Рассмотренные задачи в значительной степени основываются на использовании численных методов обработки изображений. Следовательно, для анализа полученных результатов необходимо использовать численные метрики оценки качества изображений.

Качество изображений в голографических системах и системах оптического кодирования определяется путем численного сравнения с исходным (эталонным) изображением, которое было использовано для получения голограмм.

Для численной оценки качества изображений используются численные метрики оценки. В данной работе используются две основных метрики: коэффициент корреляции (КК) и индекс структурного сходства (ИСС). Метрики представлены в уравнениях 1.1-1.2.

$$\text{КК} = \frac{\sum_{i,j}(A_{ij}-\langle A_{ij}\rangle)(B_{ij}-\langle B_{ij}\rangle)}{\sqrt{\left(\sum_{i,j}(A_{ij}-\langle A_{ij}\rangle)^2\right)\left(\sum_{i,j}(B_{ij}-\langle B_{ij}\rangle)^2\right)}}, \quad (1.11)$$

где $\langle A_{ij}\rangle$,$\langle B_{ij}\rangle$ – средние значения яркости сравниваемых изображений $A_{i,j}$ и $B_{i,j}$. КК = 1 когда изображения идентичны.

$$\text{ИСС} = \frac{(2\langle A_{ij}\rangle\langle B_{ij}\rangle + c_1)(2\sigma_{AB} + c_2)}{\left(\langle A_{ij}\rangle^2 + \langle B_{ij}\rangle^2 + c_1\right)(\sigma_A^2 + \sigma_B^2 + c_2)}, \quad (1.12)$$

Где σ_A^2, σ_B^2 – дисперсия для величин A_{ij} и B_{ij} соответственно; σ_{AB}– ковариация для величин A_{ij} и B_{ij}; c_1, c_2 – константы. ИСС = 1 когда изображения идентичны.

Выводы по первой главе

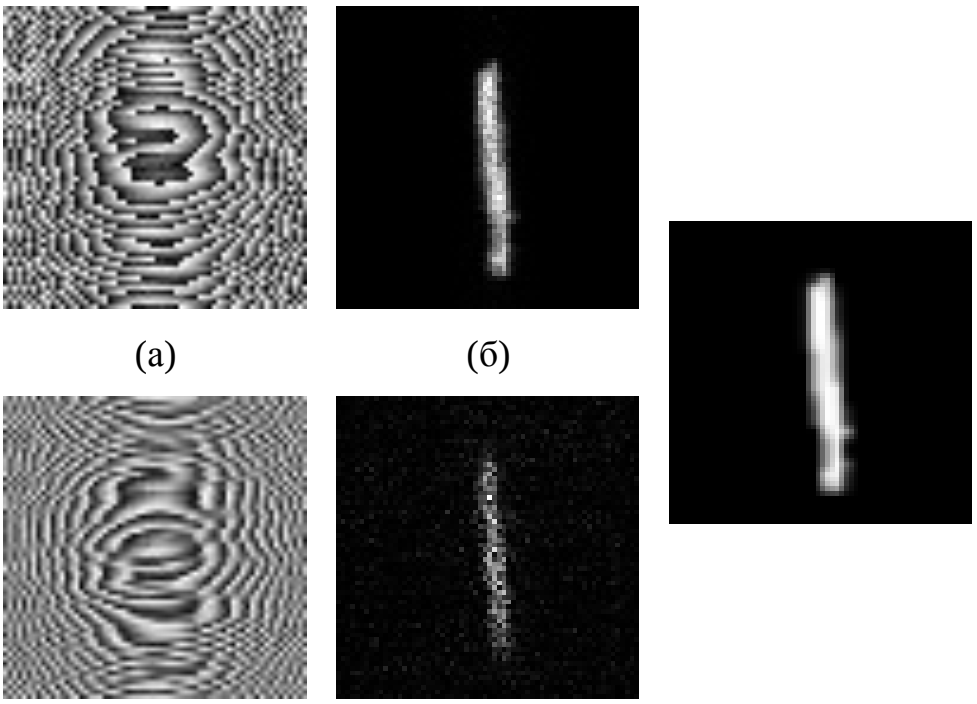
1. Проведен обзор текущих традиционных методов для задач голографии, микроволновой фотоники и оптического кодирования. Определены направления, которые для которых может эффективно применяться нейросетевая обработка сигналов.
2. Определены ограничения современных нейросетевых методов для задач голографии, микроволновой фотоники и оптического кодирования. Выявлены перспективные направления для создания модифицированных нейросетевых подходов, учитывающих физические принципы рассматриваемых задач.
3. Определены метрики численной оценки качества изображений, которые будут в дальнейшем использованы для оценки разработанных методов.

2. Синтез компьютерных голограмм с использованием физически-информированной нейронной сети

Первые НС методы синтеза КГ использовали парный подход к обучению – обучение с использованием выборки, состоящей из КГ, синтезированных существующим алгоритмом, и соответствующих им изображений. Однако такие методы имеют существенные ограничения. Поскольку для синтеза обучающей выборки используется существующий алгоритм, предельное качество восстановленных изображений, которое может быть достигнуто после обучения НС, будет определяться этим алгоритмом (например, ГС). Также при необходимости синтеза КГ с параметрами оптической системы, отличными от использованных в процессе обучения, потребуется создание новой выборки и повторное обучение НС.

2.1 Методы синтеза компьютерных голограмм, основанные на парном обучении

В качестве примера парного подхода была рассмотрена НС с архитектурой U-Net, обученная с использованием 50 000 изображений из набора рукописных цифр MNIST, с разрешением 64×64 пикселя, и соответствующих фазовых КГ, синтезированных с использованием алгоритма ГС. Пример КГ, полученных с использованием алгоритма ГС и обученной НС, а также соответствующие им восстановленные и исходное изображения представлены на рис. 2.1. Численная оценка приведена в таблице 2.1. Для оценки использовался тестовый набор из 1000 изображений.



(а) (б)

(в) (г) (д)

Рис. 2.1 Фазовая КГ, синтезированная с использованием алгоритма ГС (а); восстановленное из нее изображение (б); фазовая КГ, синтезированная с использованием обученной НС (в); восстановленное из нее изображение (г); исходное изображение (д).

Таблица 2.1 – Параметры КГ, полученных с использованием алгоритма ГС и обученной НС.

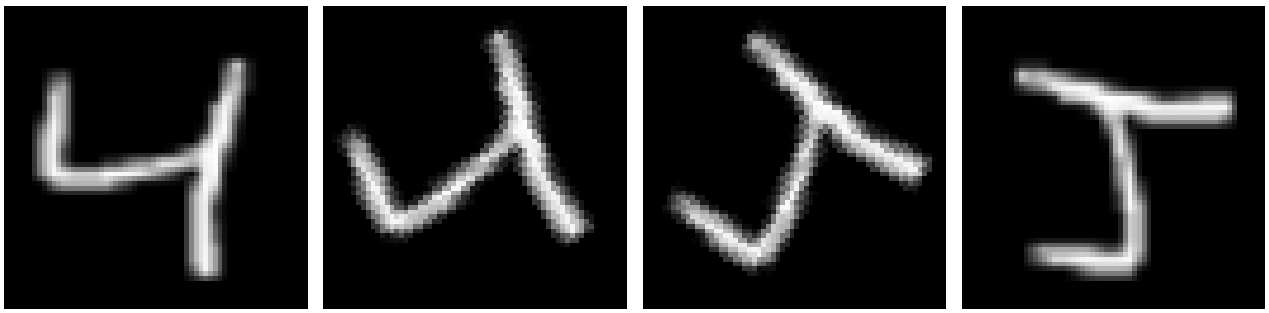
Метод синтеза КГ	**Время синтеза, сек**	**КК**
НС	0,03	0,66 ± 0,06
ГС	0,14	0,68 ± 0,02

Исходя из таблицы 2.1, качество изображений, восстановленных из КГ, синтезированных обученной нейронной сетью, сопоставимо с алгоритмом ГС. При этом нейронная сеть выполняет синтез быстрее – 0,03 с на синтез одной КГ размером 64×64 пикселя, по сравнению с 0,14 с, при использовании алгоритма ГС. Значения были рассчитаны с использованием графического ускорителя NVIDIA GeForce RTX 2060 SUPER.

Для обучения НС синтезу КГ 3D-сцен требуется создание соответствующей обучающей выборки. Она должна состоять из КГ, синтезированных алгоритмом ГС, и соответствующих им изображений 3D-сцен, состоящих из нескольких сечений. Для обучения использовались фазовые КГ и соответствующие им изображения 3D-сцен, построенные из четырех сечений, находившихся на различных расстояниях от плоскости КГ (0,007 м, 0,010 м, 0,013 м, 0,016 м). Примеры КГ и сечений 3D-сцены представлены на рис. 2.2.



(а)



(б)

Рис. 2.2 (а) – КГ, содержащая четыре сечения изображения 3D-сцены на различных расстояниях, синтезированная с использованием алгоритма ГС; (б) – сечения изображения 3D-сцены.

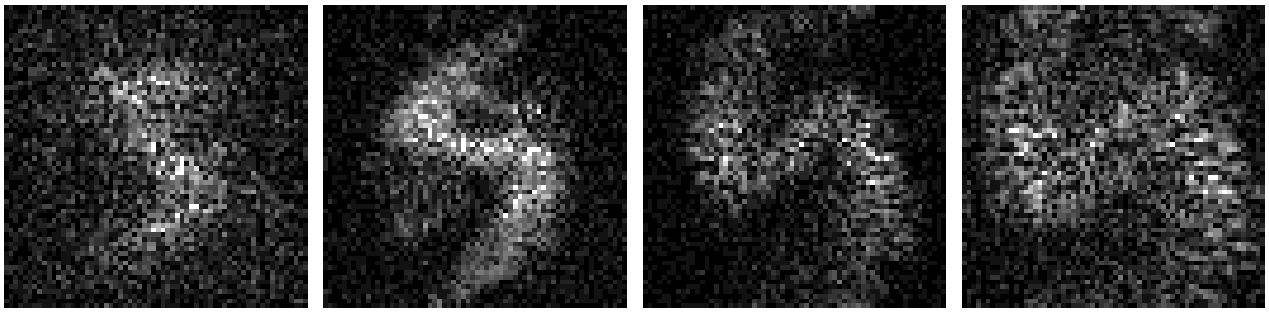
Примеры КГ, синтезированных алгоритмом ГС и обученной НС, и восстановленных из них изображений 3D-сцен представлены на рис. 2.3. Для численной оценки качества восстановленных изображений использовался тестовый набора из 100 КГ. Значения численных метрик качества рассчитывались отдельно для каждого сечения (таблица 2.2).



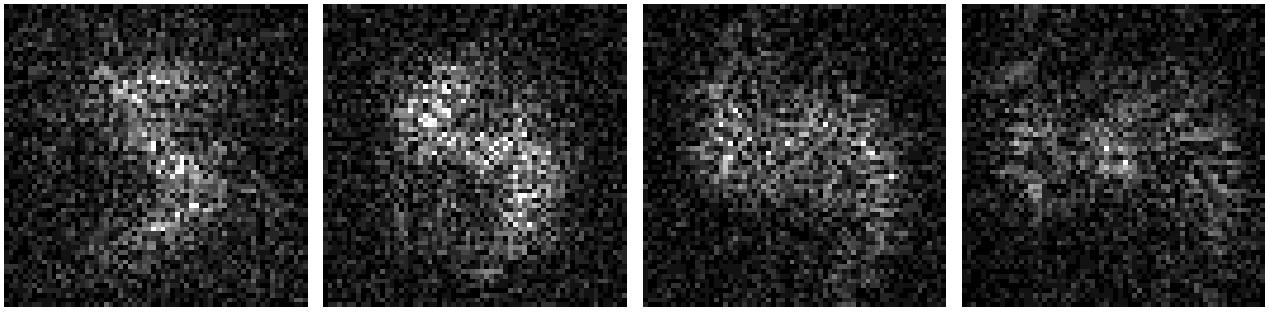
(а)



(б)



(в)



(г)

Рис. 2.3 КГ 3D-сцены, синтезированная с использованием алгоритма ГС (а); и обученной НС (б); (в, г) – сечения изображения 3D-сцены, восстановленные из (а) и (б) соответственно.

Таблица 2.2 – Численное сравнение изображений, восстановленных из КГ, полученных с использованием алгоритма ГС и обученной НС.

Метод синтеза	Расстояние до плоскости восстановления, м	КК
ГС	0,007	0,72±0,04
	0,010	0,68±0,03
	0,013	0,45±0,04
	0,016	0,37±0,06
НС	0,007	0,60±0,08
	0,010	0,58±0,06
	0,013	0,43±0,07
	0,016	0,36±0,06

В случае синтеза КГ 3D-сцен из полученных результатов видно, что НС позволяет создавать голограммы, качество которых сопоставимо с результатом применения алгоритма ГС. При этом НС синтезирует КГ значительно быстрее (0,08 сек для НС по сравнению с 2,1 сек для алгоритма ГС).

Качество синтезируемых КГ может быть повышено за счет использования обучающей выборки большего размера, или использования более сложных методов синтеза КГ для ее создания. Однако эти подходы не позволят преодолеть основные недостатки парного подхода к НС синтезу КГ. Основным ограничением данного подход является невозможность использования НС для синтеза КГ с параметрами оптической системы, отличными от заданных в процессе создания обучающей выборки. При необходимости синтеза КГ с использованием другой длины волны излучения лазера, другого расстояния от плоскости КГ до плоскости восстановления или размера пикселя ПВМС потребуется создание новой обучающей выборки и повторное обучение НС. Это сильно ограничивает практическую применимость такого подхода. Таким образом существует необходимость

создания более универсального метода, который позволит работать с широким диапазоном параметров и изображений. Одним из вариантов реализации такого метода является применение физически-информированных НС.

2.2 Интеграция численной модели дифракции Френеля в физически-информированную нейронная сеть

Физически-информированные модели позволяют создавать НС на основе физических принципов поставленной задачи. Для голографии это может выражаться в интеграции в архитектуру НС численной модели расчета дифракции, которая позволит использовать такие параметры оптической системы, как размер пикселя ПВМС, длина волны излучения лазера, расстояние от плоскости голограммы до плоскости восстановления в процессе обучения. НС, таким образом, будет в процессе работы производить численное решение уравнения дифракции, что дает возможность изменять эти параметры без необходимости повторного или дополнительного обучения. Недостатком таких моделей является их высокая ресурсоемкость, обучение физически-информированной НС займет примерно на порядок дольше, чем аналогичной НС без интеграции численной модели дифракции.

В основе разработанного физически-информированного метода лежит глубокая сверточная НС, которая в процессе обучения выполняет расчет КГ с использованием численной модели расчета дифракции Френеля. Принципиальная схема метода представлена на рис. 2.4.

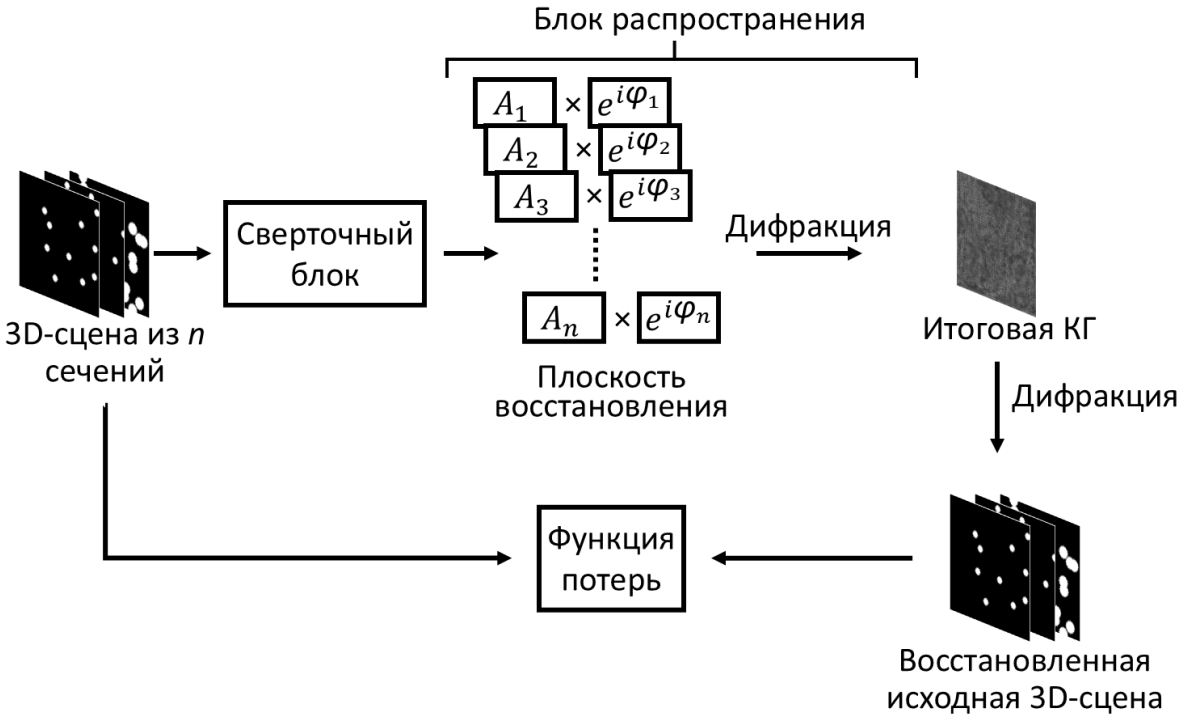


Рис. 2.4 Схема метода синтеза КГ 3D-сцен, на основе физически-информированной НС, состоящей из сверточного блока с двумя ветвями декодера и блока распространения со встроенной моделью расчета дифракции Френеля.

Распространение света в разработанной НС рассчитывается путем прямого вычисления интеграла Френеля (метод 1-FFT) [83]:

$$\text{К}\,(\text{x},\text{y},\text{z}) = \frac{exp(jkz)}{j\lambda z} \times exp\left(\frac{j\pi}{\lambda z}(x^2+y^2)\right) \times$$

$$\times FFT\left(H(u,v) \times exp\left(\frac{j\pi}{\lambda z}(u^2+v^2)\right)\right), \quad (2.1)$$

где $K(x,\ y)$ – волновой фронт в плоскости восстановления, k – волновое число, z – расстояние от плоскости голограммы до плоскости восстановления, λ – длина волны, $H(u,v)$ – волновой фронт в плоскости голограммы, (u, v) – координаты в плоскости голограммы, (x, y) – координаты в плоскости восстановления, FFT – преобразование Фурье.

Схема разработанного метода может быть описана следующим образом:

1. Изображения 3D-сцен, построенных из n сечений каждая, поступающие на вход НС обрабатываются сверточным блоком, состоящим из энкодера и двух ветвей декодера.
2. Для каждого сечения 3D-сцены одна из ветвей декодера выполняет синтез фазовой части комплексного распределения поля $A_n e^{i\varphi_n}$ в плоскости восстановления, а вторая амплитудной.
3. С использованием полученных амплитудно-фазовых распределений блок распространения выполняет обратный расчет дифракции Френеля до плоскости голограммы с использованием заданных в процессе обучения длины волны излучения лазера, размера пикселя ПВМС и расстояний от плоскости КГ до плоскостей восстановления, соответствующих сечениям изображения.
4. В плоскости голограммы фазовая часть суммарного комплексного распределения $e^{i\sum_1^n \tilde{\varphi}_n}$ принимается за итоговую фазовую КГ, синтезируемую НС.
5. Для расчета функции потерь L (уравнение 2.2) производится восстановление изображений из итоговой КГ и их сравнение с исходными изображениями.

$$L = 1 - \frac{\sum_{i,j,n}(A_{ijn} - \langle A_{ijn}\rangle)(B_{ijn} - \langle B_{ijn}\rangle)}{\sqrt{\left(\sum_{i,j,n}(A_{ijn} - \langle A_{ijn}\rangle)^2\right)\left(\sum_{i,j,n}(B_{ijn} - \langle B_{ijn}\rangle)^2\right)}}, \quad (2.2)$$

где $A_{i,j}$ – целевое изображение, $B_{i,j}$ – восстановленное изображение, $\langle A_{ijn}\rangle$, $\langle B_{ijn}\rangle$ – средние значения A_{ijn} и B_{ijn}, i,j – индексы пикселей, n – номер сечения.

В рамках задачи синтеза КГ критерием качества работы НС является качество изображений, которые могут быть восстановлены из полученных КГ.

2.3 Разработанная двухканальная нейросетевая архитектура для синтеза компьютерных голограмм трехмерных сцен

Для оптимального синтеза амплитудно-фазовой информации была применена архитектура с двумя ветвями декодера. Сверточный блок, представляет собой адаптированный под задачу синтеза КГ вариант архитектуры Y-Net [65]. Энкодер состоит из трех сверточных блоков, каждый из которых содержит 2 сверточных слоя. Каждая из ветвей декодера состоит из трех аналогичных блоков с добавлением четвертого блока, результат работы которого принимается за комплексные амплитудно-фазовые распределения, соответствующие сечениям 3D-сцены в плоскости восстановления.

Современные ПВМС имеют разрешение в несколько мегапикселей. Следовательно, для оптимального воспроизведения КГ с использованием современных устройств нейросетевой метод синтеза КГ должен быть способен оперативно работать с изображениями высокого разрешения. При увеличении разрешения изображений операции свертки выполняются над матрицами большего размера, что существенно увеличивает вычислительную нагрузку. Одним из вариантов повышения эффективности работы НС при работе с изображениями большого разрешения является техника чередования пикселей [41]. Чередование пикселей – это подход, широко использующийся в задачах увеличения разрешения изображений (суперразрешения). Он позволяет уменьшить вычислительную нагрузку за счет уменьшения пространственного разрешения изображений путем их разбиения на составляющие таким образом, что каждая полученная часть содержит информацию о всей плоскости изображения. Изображение с разрешением $X \times Y$ разделяется на несколько каналов путем выделения пикселей с шагом S. Результирующее изображение имеет разрешение $X/S \times Y/S$ и S^2 каналов.

При таком преобразовании не происходит потери данных, а расчеты выполняются с изображениями меньшего разрешения, что позволяет более

эффективно использовать ресурсы графического ускорителя. После выполнения ресурсоемких операций свертки выполняется обратное преобразование и восстанавливается исходное разрешение. Схема чередования пикселей представлена на рис. 2.5.

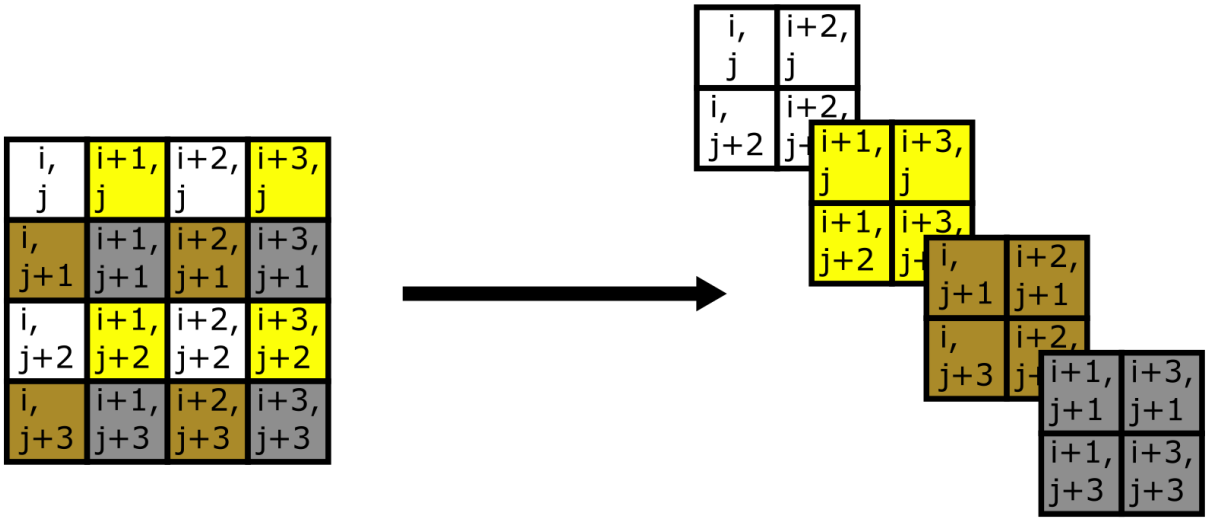


Рис. 2.5 Схема чередования пикселей

Применение чередования пикселей позволяет значительно сократить время обучения НС без потери качества. Для НС, обучаемой с использованием обучающей выборки из изображений 3D-сцен, содержащих четыре сечения с разрешением 512×512 пикселей, применение чередования с $S = 4$ приводит к сокращению каждой эпохи обучения (времени, которое требуется НС для обработки всей выборки) с 15 часов до 50 минут (обучение с использованием графического ускорителя NVIDIA GeForce RTX 5070 Ti).

Таким образом, итоговая предлагаемая архитектура состоит из сверточного блока, построенного из энкодера и двух ветвей декодера, и блока распространения, интегрирующего в архитектуру численную модель расчета дифракции Френеля. Техника чередования пикселей улучшает способность НС работать с изображениями высокого разрешения. Схема архитектуры представлена на рис. 2.6.

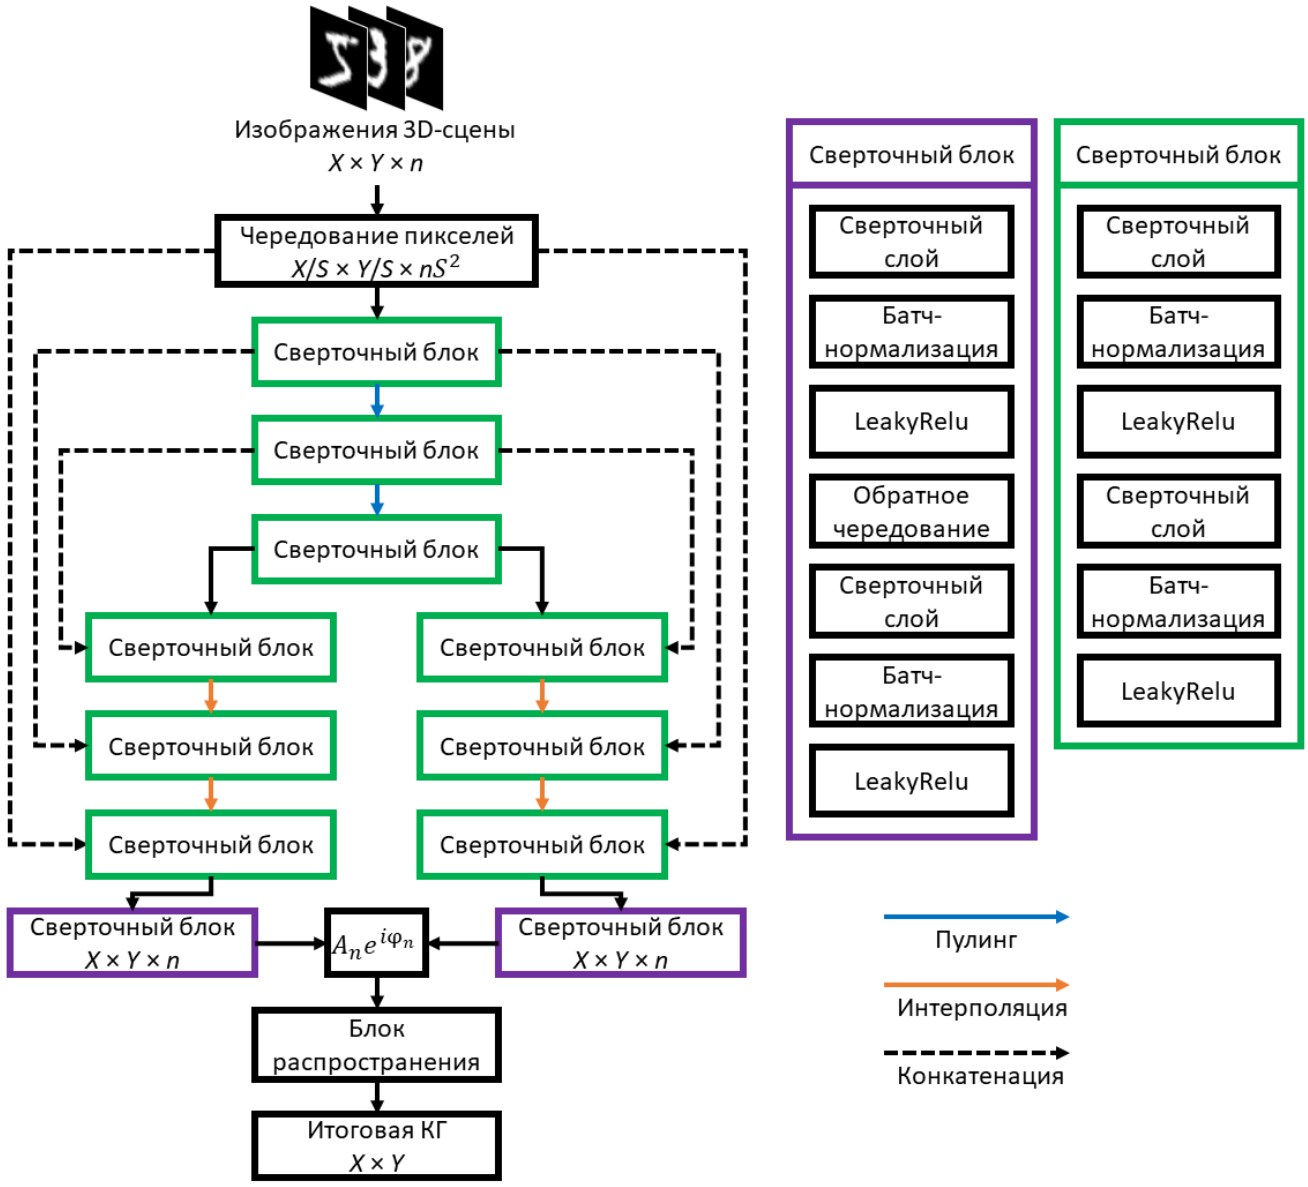
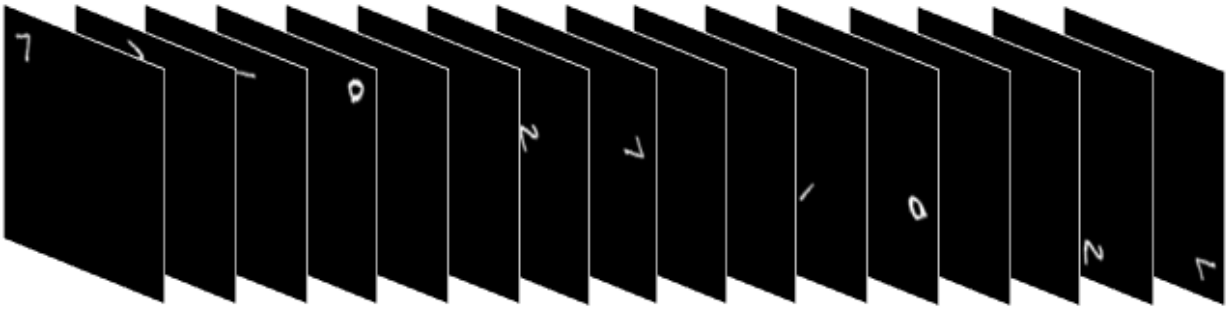


Рис. 2.6 Разработанная архитектура физически-информированной нейронной сети с двумя ветвями энкодера и интегрированной численной моделью дифракции Френеля.

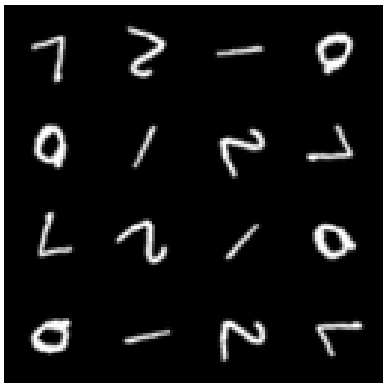
Итого, архитектура состоит из 22 сверточных слоев и имеет 7,8 млн. обучаемых параметров. Такая конфигурация является оптимальным компромиссом между качеством синтезируемых голограмм и временем обучения.

2.4 Численное восстановление изображений из голограмм, синтезированных предложенным нейросетевым методом

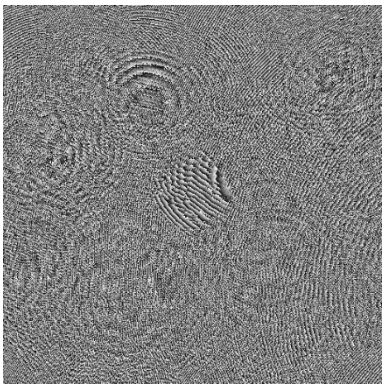
Для подтверждения эффективности разработанного физически-информированного метода, НС была обучена синтезу КГ изображений 3D-сцен, содержащих 16 сечений. Для построения сцен использовались изображения рукописных цифр из набора MNIST. Размер КГ составлял 512×512 пикселей. Изображения в разных сечениях были расположены таким образом, чтобы предотвратить перекрытие восстановленных изображений с несфокусированными изображениями из других сечений. Примеры расположения сечений, объединенного изображения сечений (их наложения), а также КГ, синтезированных с использованием алгоритма ГС и разработанной НС, представлен на рис. 2.7. Расстояния от плоскости голограммы до плоскостей сечений составляли от 0,05 м до 0,22 м.



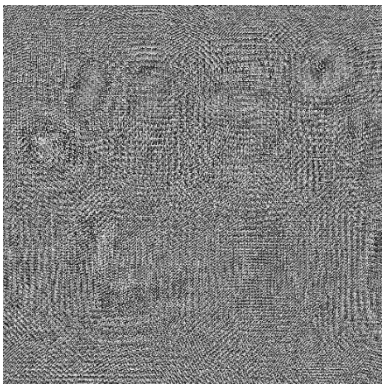
(а)



(б)



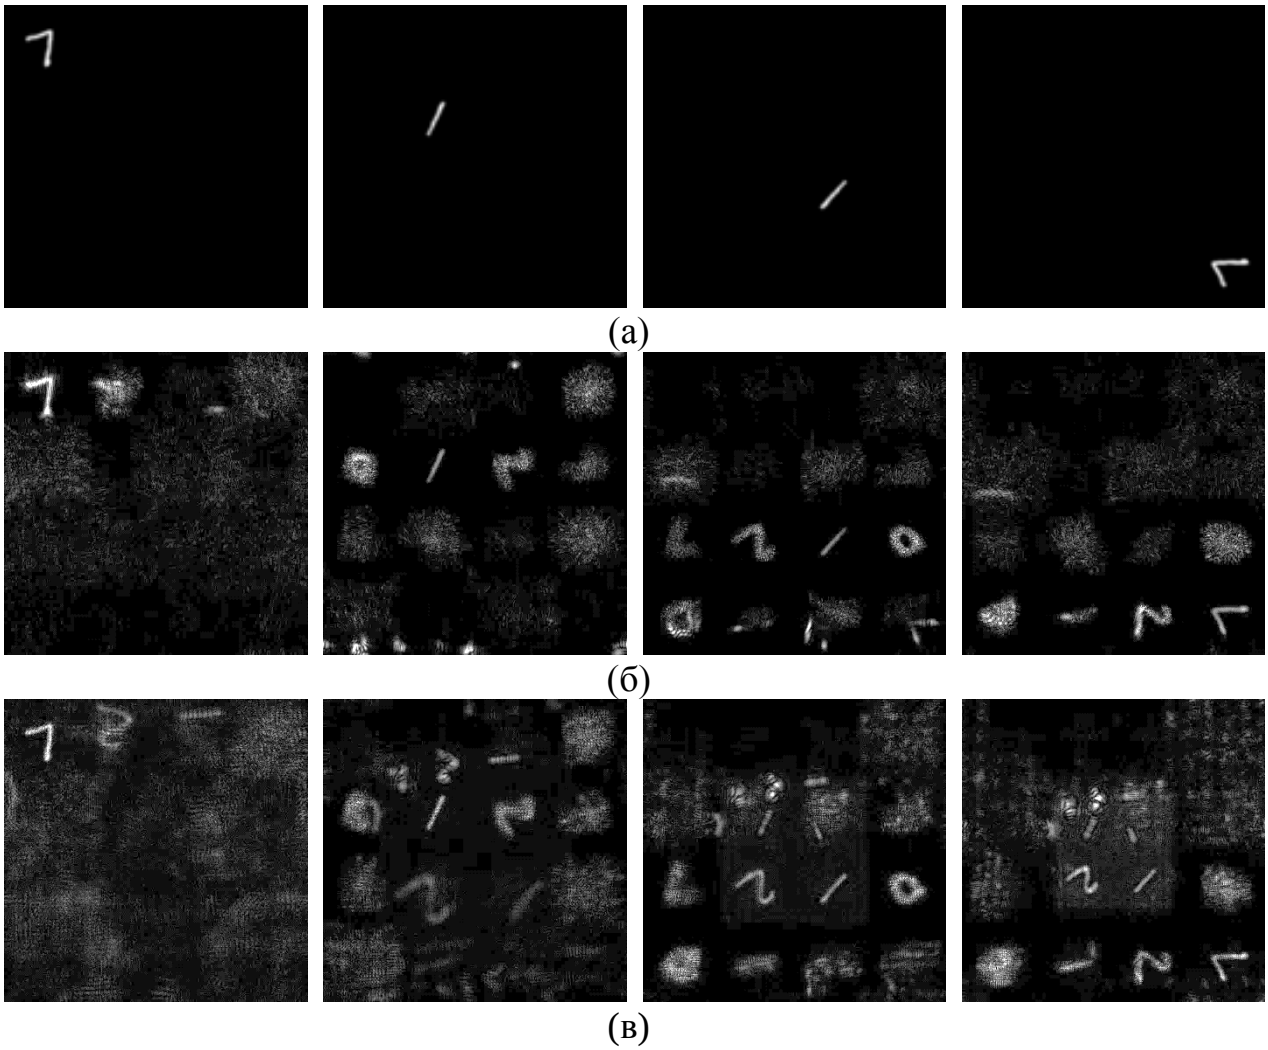
(в)



(г)

Рис. 2.7 Пример изображений 3D-сцены, построенной из 16 сечений (а); объединенное изображение всех 16 сечений (б); КГ, полученные с использованием алгоритма ГС (в) и разработанной НС (г).

Обучающая выборка включала 12500 изображений 3D-сцен, 16 сечений в каждой (наибольшее количество сечений для нейросетевого метода синтеза голограмм на данный момент). Для обучения использовался алгоритм оптимизации Adam с начальным шагом 0,002. Расчет проводился с использованием графического процессора NVIDIA GeForce RTX 2060 Super. Примеры сечений 3D-сцены и примеры изображений, восстановленных из КГ, синтезированных с использованием алгоритма ГС и разработанной НС, представлены на рис. 2.8. Оценка производилась для по набору из 100 изображений 3D-сцен, не участвовавших в обучении.



(а)

(б)

(в)

Рис. 2.8 Сечения исходной 3D-сцены (а); сечения изображений, восстановленных из КГ, полученных с использованием алгоритма ГС (б) и разработанного НС метода (в).

Как видно из рис. 2.8, использование разработанной НС позволяет получить достаточно хорошее качество восстановленных изображений и на порядок уменьшить время синтеза (0,2 сек против 1,8 сек для алгоритма ГС). Однако качество несколько уступает алгоритму ГС (КК = 0,78±0,03 против КК = 0,93±0,02 для алгоритма ГС), что говорит о необходимости оптимизации процесса обучения для улучшения качества КГ и восстановленных из них изображений.

2.4.1 Создание обучающей выборки, специализированной для задач голографии

Апробированная НС была обучена с использованием обучающей выборки, составленной на основе набора MNIST. Это выборка широко используется для демонстрации работы НС моделей, однако MNIST это относительно небольшой (60 000) набор простых однообразных изображений, и не является оптимальным для задач оптической обработки информации. Дальнейшее улучшение качества КГ, синтезируемых разработанным НС методом, было достигнуто путем создания специализированной обучающей выборки. Данная выборка позволяла контролировать соотношение высокочастотной и низкочастотной информации в изображении, и обладала увеличенным размером.

Для обеспечения разнообразия частотной информации были созданы выборки, основанные на использовании графических примитивов. Такие объекты позволяют эффективно управлять параметрами выборки за счет изменения линейного размера примитивов и их количества. Примеры изображений, составляющих обучающую выборку, и их параметры представлены на рис. 2.9.



10 примитивов с линейным размером 8 пикс.



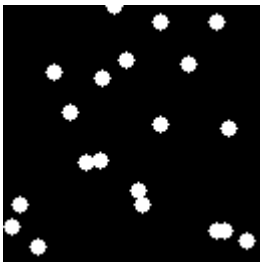
6 примитивов с линейным размером 24 пикс.



40 примитивов с линейным размером 2 пикс.



80 примитивов с линейным размером 2 пикс.



20 примитивов с линейным размером 4 пикс.



12 примитивов с линейным размером 12 пикс.

Рис. 2.9 Примеры изображений из специализированной обучающей выборки.

Для обучения физически-информированной НС синтезу КГ 3D-сцен было синтезировано 5 выборок, построенных из графических примитивов:

1. 8-10 примитивов, размером 8-36 пикс.
2. 6-80 примитивов, размером 8-36 пикс.
3. 20-40 примитивов, размером 2-12 пикс.
4. 40-80 примитивов, размером 2-8 пикс.
5. 10-40 примитивов, размером 2-8 пикс.

Каждая выборка состояла из 50 000 изображений 3D-сцен, построенных из 16 сечений, разрешением 128×128 пикс. Использование изображений небольшого разрешения при синтезе выборки позволяет сократить время синтеза и объем памяти, занимаемый выборкой. Поскольку выборки построены из графических примитивов, изображения могут быть увеличены, например, с использованием интерполяции методом ближайшего соседа, до необходимого разрешения сохраняя при этом соотношение между высоко- и низкочастотной информацией в изображении. Так, в процессе

обучения изображения сечений 3D-сцены были интерполированы до размера 512×512 пикс.

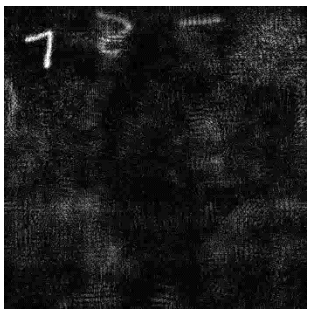
В процессе обучения разработанной физически-информированной НС использовались следующие параметры оптической системы:

- длина волны излучения лазера – 532 нм,
- размер пикселя ПВМС – 8 мкм,
- расстояние от плоскости голограммы до плоскостей восстановления варьировалось от 0,06 до 0,15 м.

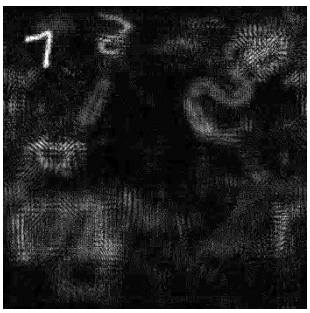
Далее с использованием синтезированных выборок и заданных параметров оптической системы были проведены эксперименты по обучению разработанной физически-информированной НС синтезу КГ 3D-сцен.

Для оценки качества работы обученных физически-информированных НС использовался набор рукописных цифр MNIST. Этот набор состоит из объектов, отличающихся от графических примитивов, использованных для построения обучающей выборки. Данный выбор позволил оценить, насколько НС, обученные на выборках из синтезированных примитивов, способны работать с новыми типами объектов, и сравнить их с НС обученной непосредственно на наборе MNIST.

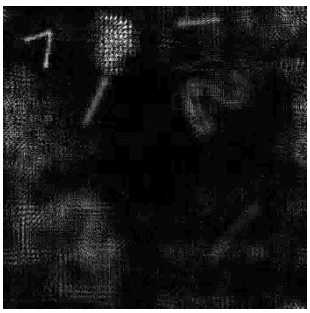
Примеры изображений, восстановленных из КГ, синтезированных разработанной физически-информированной НС, обученной с использованием набора MNIST и с использованием синтезированных выборок из графических примитивов, а также их численная оценка представлены на рис. 2.10. Для численной оценки проводилось сравнение изображений с исходными только в информативной области каждого сечения.



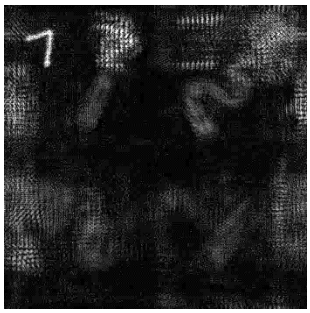
MNIST
КК: 0,78± 0,03



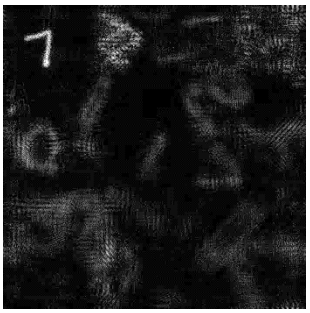
Линейный размер: 8-36
Количество: 8-10
КК: 0,83±0,03



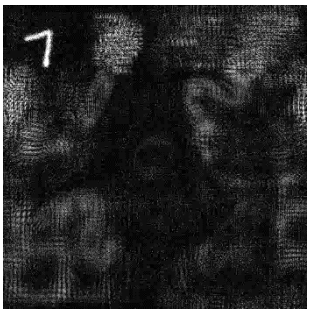
Линейный размер: 8-36
Количество: 6-80
КК: 0,83±0,04



Линейный размер: 2-12
Количество:20-40
КК: 0,84±0,02



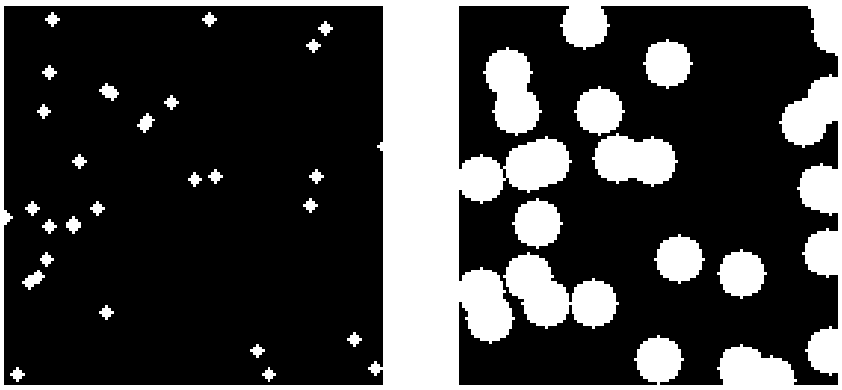
Линейный размер: 2-8
Количество: 40-80
КК: 0,81±0,03



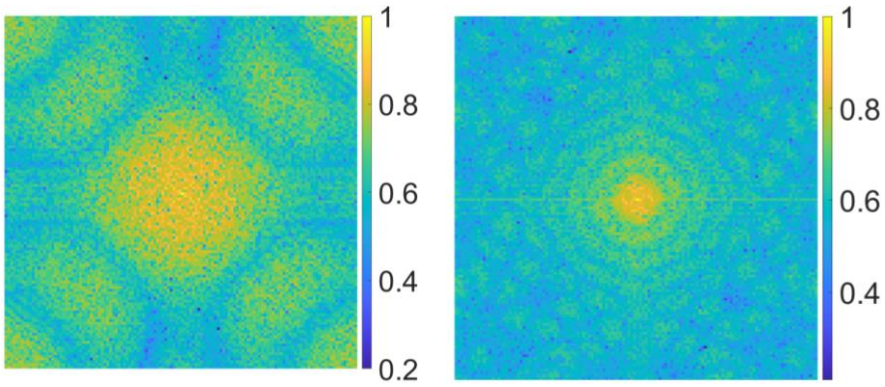
Линейный размер: 2-8
Количество: 10-40
КК: **0,85±0,01**

Рис. 2.10 Пример сечения изображения 3D-сцены, восстановленного из КГ, синтезированных разработанной НС, обученной с использованием разных обучающих выборок. Жирным выделено максимально достигнутое значение КК.

Как видно из рис. 2.10, каждая из выборок, построенных из графических примитивов, обеспечивает более высокое качество восстановленных изображений по сравнению с выборкой из набора MNIST. Из 5 рассмотренных выборок наилучший результат показала выборка, построенная из 10-40 графических примитивов с линейным размером 2-8 пикс. Данная выборка обладает более равномерное распределением информации по пространственным частотам. Примеры изображений из данной выборки и соответствующих им фурье-спектров представлены на рис. 2.11.



(а)



(б)

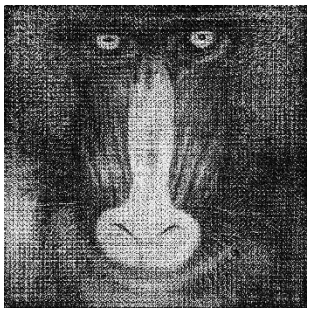
Рис. 2.11 Сечения 3D-сцены из разработанной оптимальной обучающей выборки (а) и соответствующие им фурье-спектры (б).

Далее была произведена оценка возможности использования НС, обученной на выборке, построенной из графических примитивов, для синтеза КГ естественных полутоновых изображений. Для этого разработанная физически-информированная НС была обучена синтезу КГ 2D-сцен с разрешением 512×512 пикс. Для обучения использовались следующие параметры оптической системы:

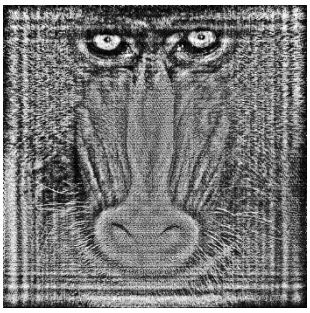
- длина волны излучения лазера – 532 нм,
- размер пикселя ПВМС – 8 мкм,
- расстояние от плоскости голограммы до плоскости восстановления – 0,06 м.

Примеры изображений, восстановленных из КГ, синтезированных разработанной физически-информированной НС, обученной с использованием набора MNIST и с использованием синтезированных

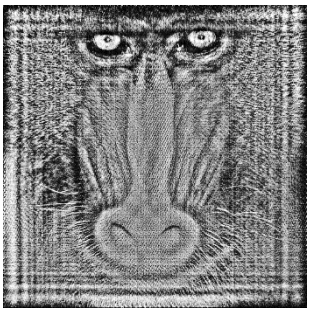
выборок из графических примитивов, а также их численная оценка представлены на рис. 2.12. Для сравнения использовалось стандартное тестовое изображение естественной сцены. Данное сравнение позволяет оценить, может ли НС, обученная с использованием графических примитивов, быть применена в случае полутоновых изображений естественных сцен.



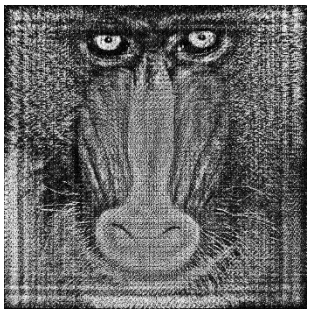
MNIST
КК: 0,43



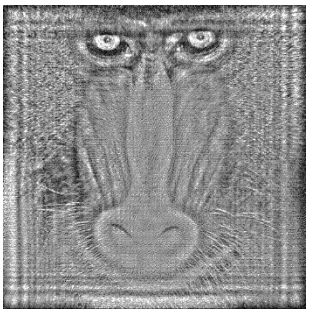
Линейный размер: 8-36
Количество: 8-10
КК: 0,44



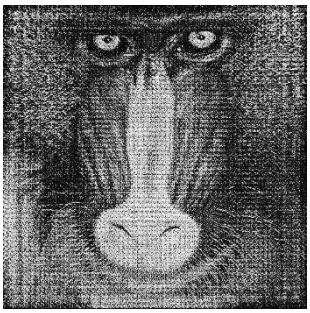
Линейный размер: 8-36
Количество: 6-80
КК: 0,44



Линейный размер: 2-12
Количество:20-40
КК: 0,47



Линейный размер: 2-8
Количество: 40-80
КК: 0,44



Линейный размер: 2-8
Количество:10-40
КК: **0,51**

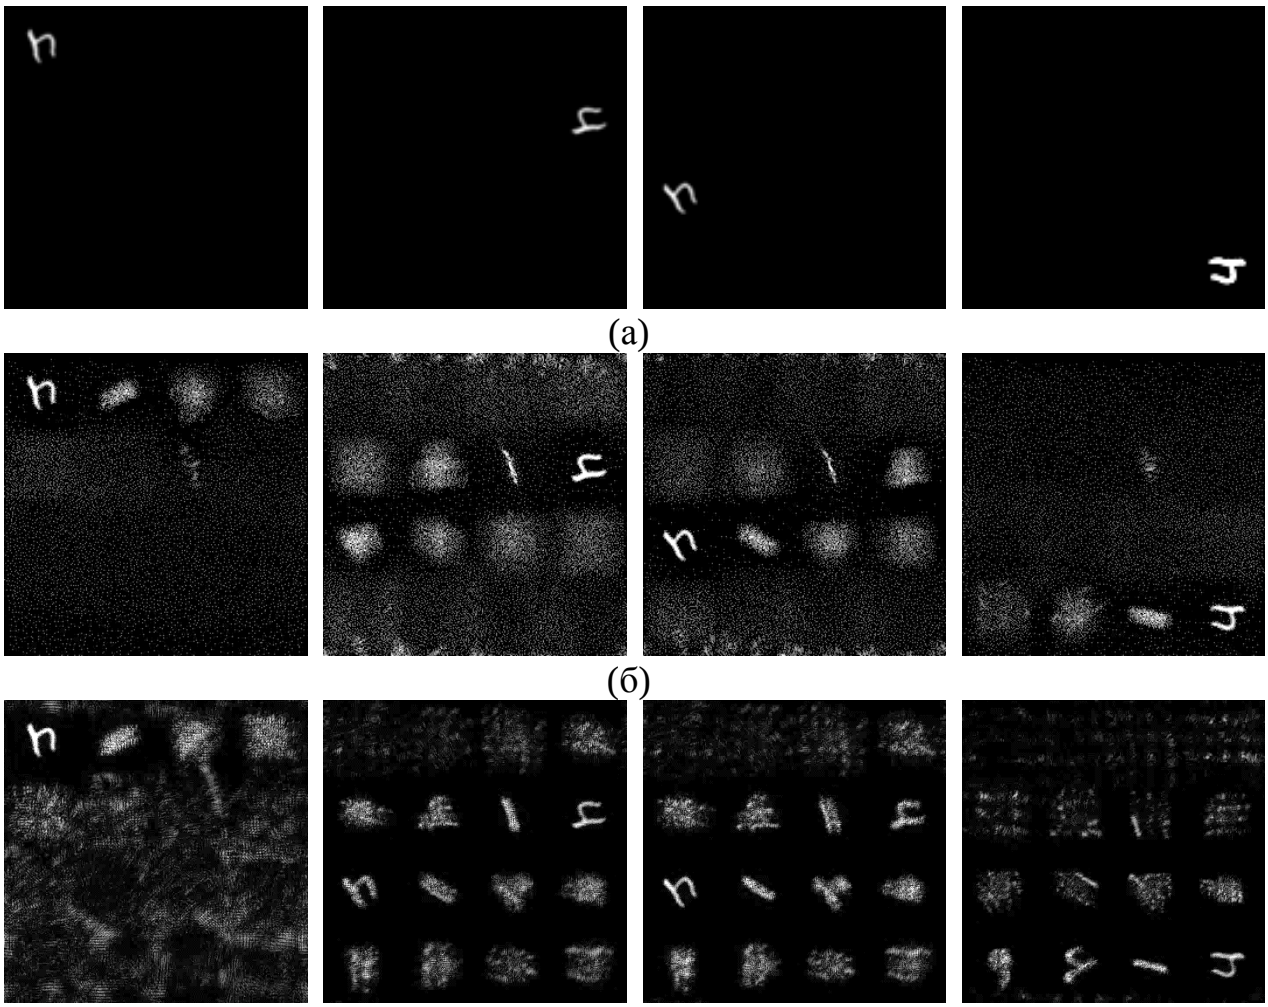
Рис. 2.12 Пример полутонового естественного изображения, восстановленного из КГ, синтезированных разработанной НС, обученной с использованием разных обучающих выборок. Жирным выделено максимально достигнутое значение КК.

Как видно из рис. 2.12, наилучший результат был также достигнут при использовании выборки с 10-40 примитивами с линейным размером 2-8 пикселей.

2.4.2 Обучение нейронной сети с использованием обучающей выборки большого объема

Для дальнейшего улучшения качества обучения была использована обучающая выборка, содержащая 200 000 изображений 3D-сцен. Это значительно увеличивает количество информации, доступное НС в процессе обучения. Обучение прозводилось с использованием выборки, продемонстрировавшей наилучшие результаты в предыдущем разделе.

Примеры сечений восстановленной 3D-сцены для КГ, синтезированных с использованием разработанного нейросетевого метода и алгоритма ГС, представлены на рис. 2.13. Численная оценка полученных результатов по информативной области восстановленных изображений для 100 проверочных КГ представлена в таблице 2.3.



(а)

(б)

(в)

Рис. 2.13 Примеры сечений 3D-сцены: исходные изображения (а); изображения, восстановление из КГ, синтезированных с использованием алгоритма ГС (б); и НС, обученной на выборке из 200 000 изображений 3D-сцен.

Таблица 2.3 Численное сравнение качества изображений, восстановленных из КГ, синтезированных с использованием разработанной НС и алгоритма ГС

Метод	**Время синтеза, сек**	**КК**
ГС	1,8	0,93±0,02
НС, выборка из 50 000 сцен	**0,2**	0,85±0,01
НС, выборка из 200 000 сцен		**0,92±0,01**

Как видно из таблицы 2.3, использование обучающей выборки большого объема значительно улучшает качество восстановленных

изображений, по сравнению с выборкой из 50 000 изображений 3D-сцен. Выборка обеспечивает качество восстановленных изображений, сопоставимое с алгоритмом ГС, при заметном уменьшении времени синтеза (9 раз), что говорит о возможности использования разработанной НС для синтеза КГ с различных типов объектов с качеством восстановленных изображений, не уступающим современному итеративному алгоритму.

Основным преимуществом НС синтеза КГ по сравнению с итеративным алгоритмом ГС является его быстродействие. График зависимости скорости синтеза от количества сечений 3D-сцены для алгоритма ГС и разработанного НС представлен на рис. 2.14. Размер объектных плоскостей и размер КГ составлял 512×512 пикселей, для измерения времени синтеза расчеты проводились с использованием графического процессора NVIDIA GeForce RTX 4090.

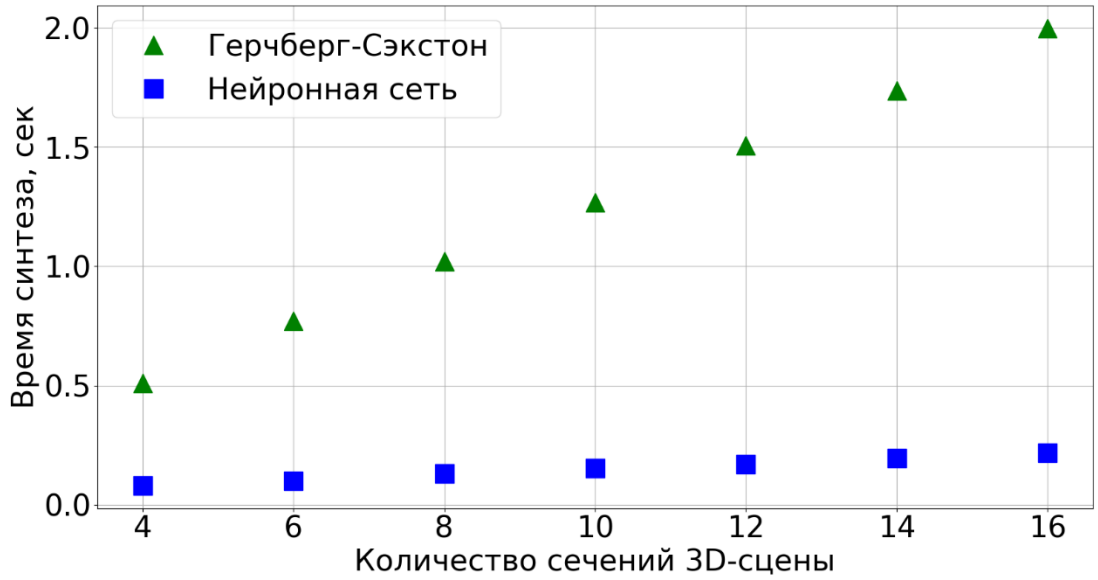


Рис. 2.14 Зависимость времени синтеза КГ от количества сечений изображения 3D-сцены для алгоритма ГС и разработанного НС метода.

Из рис. 2.14 видно, что преимущество разработанного метода по времени синтеза увеличивается по мере увеличения количества сечений в 3D-сцене и составляет 9 раз для 3D-сцен из 16 сечений размером 512×512

пикс, что демонстрирует преимущество по быстродействию разработанного нейросетевого метода перед традиционным итеративным алгоритмом.

2.4.3 Синтез компьютерных голограмм с различными параметрами оптической системы

Отличительным преимуществом разработанного подхода является возможность использования обученной НС для синтеза КГ с различными параметрами оптической системы: длина волны излучения лазера, размер пикселя ПВМС и расстояние от плоскости голограммы до плоскости восстановления – без необходимости повторного или дополнительного обучения. Для подтверждения этого НС, обученная с одним набором параметров оптической системы, была применена для синтеза КГ с другими параметрами. Результаты данных экспериментов представлены в таблице 2.4, в которой приведены различные параметры, использованные для синтеза КГ 3D-сцен из 16 сечений размером 512×512 пикселей. Значения параметров, использованные в процессе обучения НС, выделены жирным шрифтом. Значения параметров выбраны в соответствии с диапазонами, обеспечиваемыми современными устройствами (лазеры, ПВМС).

Таблица 2.4 Численное сравнение качества изображений, восстановленных из КГ 3D-сцен, синтезированных с использованием различных значений параметров оптической системы.

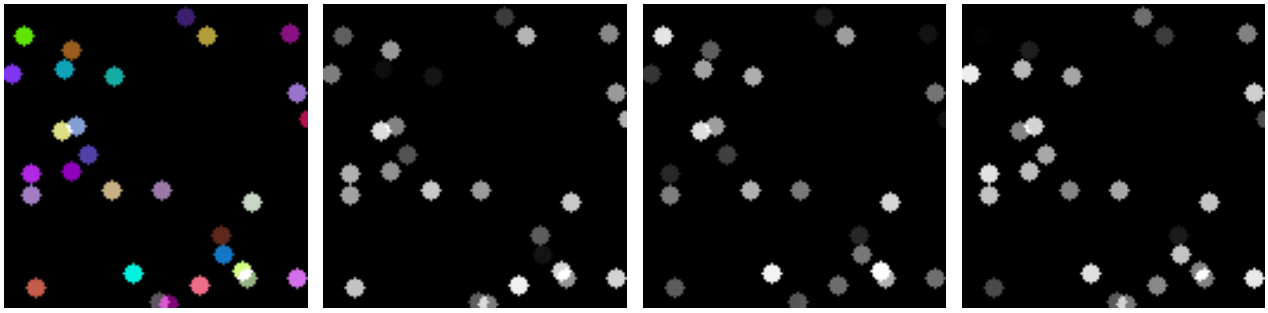
Параметр		КК
Длина волны: 473 нм		0,932 ± 0,012
	532 нм	**0,929 ± 0,011**
	633 нм	0,925 ± 0,013
Размер пикселя 4 мкм	ПВМС:	0,878 ± 0,009
	6 мкм	0,915 ± 0,009
	8 мкм	**0,929 ± 0,011**
	16 мкм	0,934 ± 0,012
	32 мкм	0,929 ± 0,011
Расстояние до плоскости восстановления: **0,15 м**	0,02-0,05 м	0,904 ± 0,019
	0,06-	**0,929 ± 0,011**
	0,1-0,25 м	0,927 ± 0,009
	0,2-0,3 м	0,902 ± 0,014

Как видно из таблицы 2.4 разработанная НС позволяет эффективно синтезировать КГ 3D-сцен для всего оптического диапазона длин волн без потери качества восстановленных изображений. Относительно размера пикселя ПВМС, качество изображений при его увеличении сохраняется, однако наблюдается некоторое ухудшение при его уменьшении. Тем не менее полученные результаты демонстрируют возможность применения обученной НС для значительной части современных ПВМС. Изменение расстояния от плоскости ПВМС до плоскостей восстановления демонстрирует возможность использования НС для синтеза голограмм изображений 3D-сцен в пределах приближения дифракции Френеля.

2.5 Синтез компьютерных голограмм цветных сцен

Цветные сцены, согласно принципу цветоделения, могут быть представлены как сцены, состоящие из трех сечений-цветовых каналов: красного, зеленого и синего. Следовательно, разработанная модель может быть использована для синтеза КГ цветных сцен при условии, что параметры обучения включают три сечения, располагающиеся на одном расстоянии от ПВМС. Расчет дифракции Френеля будет проводится для трех изображений на одинаковое расстояние с тремя различными длинами волн излучения, что приведет к формированию цветного изображения в плоскости восстановления.

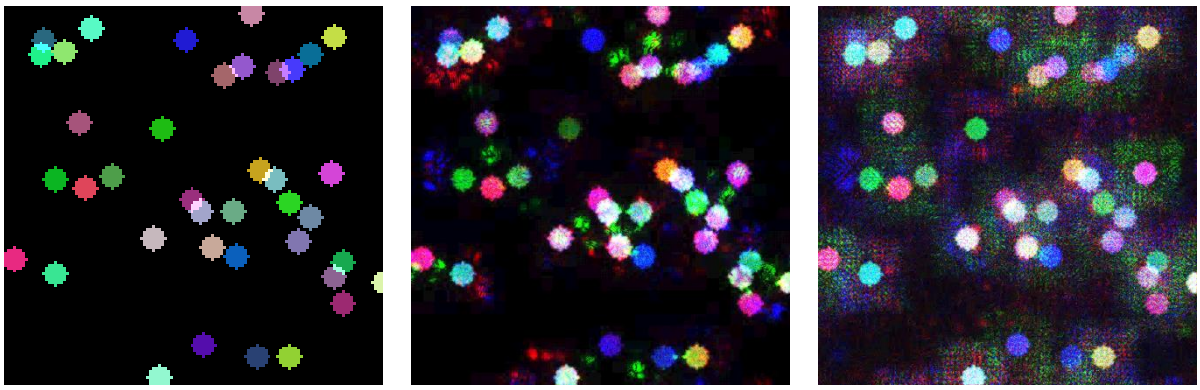
Обучающая выборка состояла из цветных 2D изображений, каждое из которых содержало три цветовых канала. Пример использованных изображений представлен на рис. 2.15. Размер изображений составлял 512×512 пикс., размер обучающей выборки – 50 000 изображений.



(а) (б) (в) (г)

Рис. 2.15. Пример изображений, используемых для синтеза КГ цветных сцен. (а) – цветное изображение; распределения интенсивности, соответствующие красному (б), зеленому (в) и синему (г) цветовым каналам.

Пример цветной сцены, восстановленной из КГ, синтезированной разработанной НС, представлен на рис. 2.16.



(а) (б) (в)

Рис. 2.16 Численное восстановление цветной сцены. Исходное изображение (а); изображения, восстановленные из КГ, полученных с использованием алгоритма ГС (б) и разработанной НС (в).

Как видно из рис. 2.16, изображение, полученное с использованием НС, обладает более высоким уровнем фонового шума по сравнению с алгоритмом ГС; однако для алгоритма ГС изображения помимо шума содержат и искажения, которые могут восприниматься как ложные объекты. Высокочастотный шум изображения, полученного с использованием НС, может быть устранен с помощью классических алгоритмов фильтрации. Для демонстрации этого был применен простейший метод пороговой фильтрации. График зависимости качества восстановленного изображения от значения порога фильтрации представлен на рис. 2.17, численная оценка – в таблице 2.5. Пример фильтрованных изображений представлен на рис. 2.18.

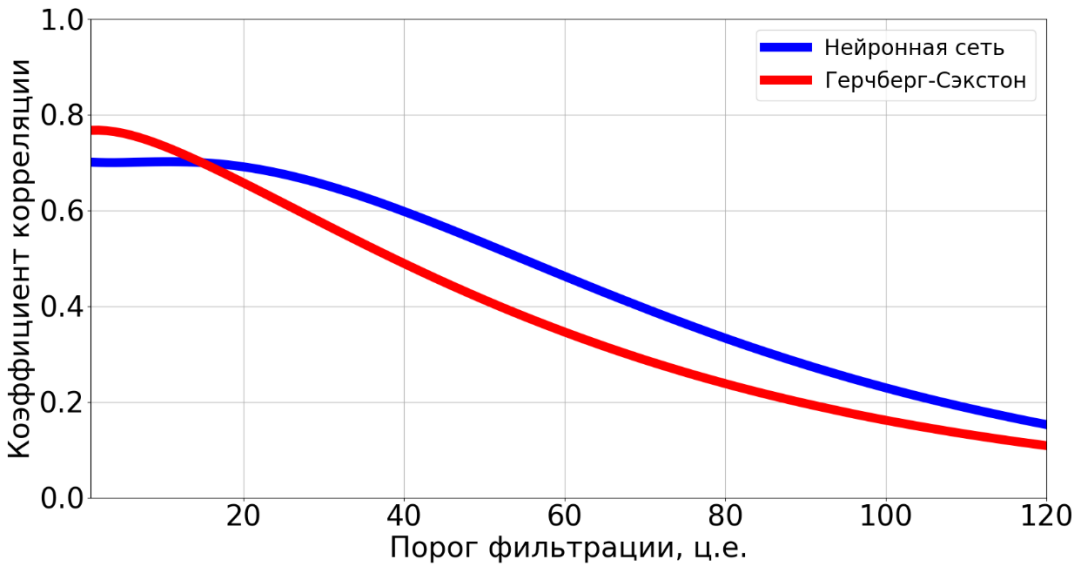
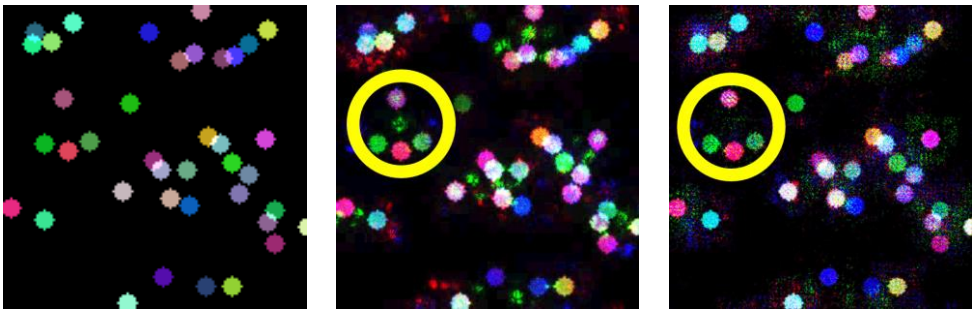


Рис. 2.17 Зависимость качества восстановления от порога фильтрации.

Таблица 2.5. Параметры изображений, восстановленных из КГ цветных сцен, после фильтрации.

Метод	Время синтеза, сек	КК
ГС	0,38	0,77 ± 0,05
НС	0,06	0,71 ± 0,01



(а) (б) (в)

Рис. 2.18 Исходное изображение (а); изображения, восстановленные из КГ, полученных с использованием алгоритма ГС (б) и разработанной НС (в), после применения пороговой фильтрации. Желтым выделена область, в которой наблюдается появление графического артефакта при использовании алгоритма ГС.

Рис. 2.18 показывает, что применение пороговой фильтрации позволяет снизить уровень шума в восстановленном изображении и избежать возникновения артефактов в случае КГ, синтезированной с использованием НС. В то время как для алгоритма ГС фильтрация приводит к снижению качества без подавления артефактов (несмотря на более высокое значение численной метрики, которое объясняется низким уровнем фонового шума).

Разработанный метод превосходит алгоритм ГС по скорости синтеза КГ в 6 раз и, несмотря на то что разработанный метод не учитывает особенности формирования цветных изображений в явном виде, позволяет восстанавливать их без возникновения графических артефактов.

2.6 Оптическое восстановление изображений из компьютерных голограмм 3D-сцен

Способность обученной НС синтезировать КГ высокого качества была продемонстрирована в ходе оптического эксперимента. Для этого изображения из КГ, синтезированных с использованием алгоритма ГС и разработанной физически-информированной НС, были восстановлены на оптической установке. Схема установки показана на рис. 2.19.

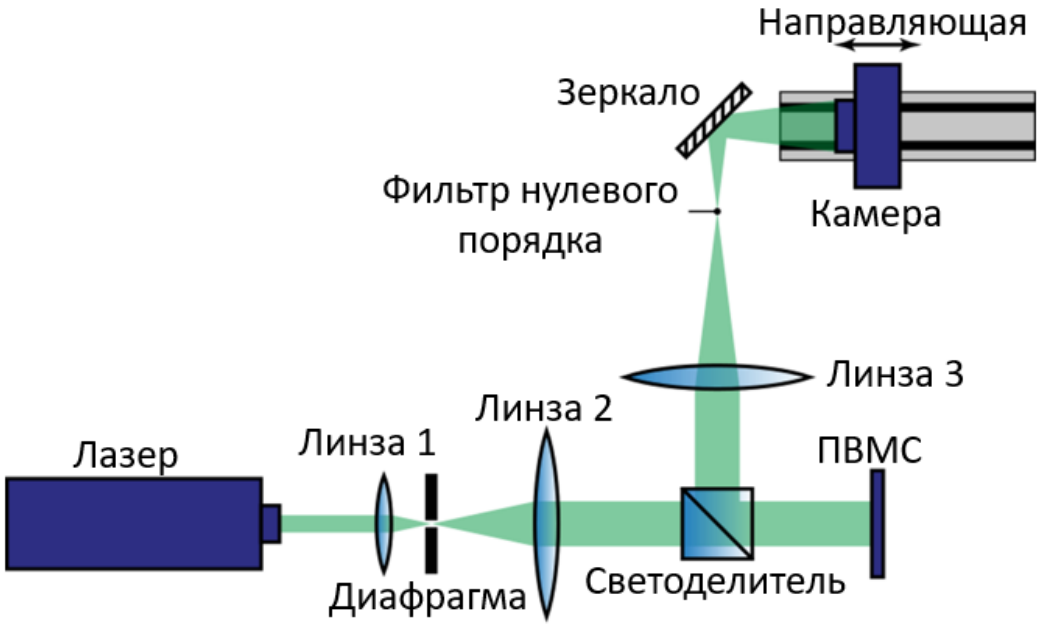
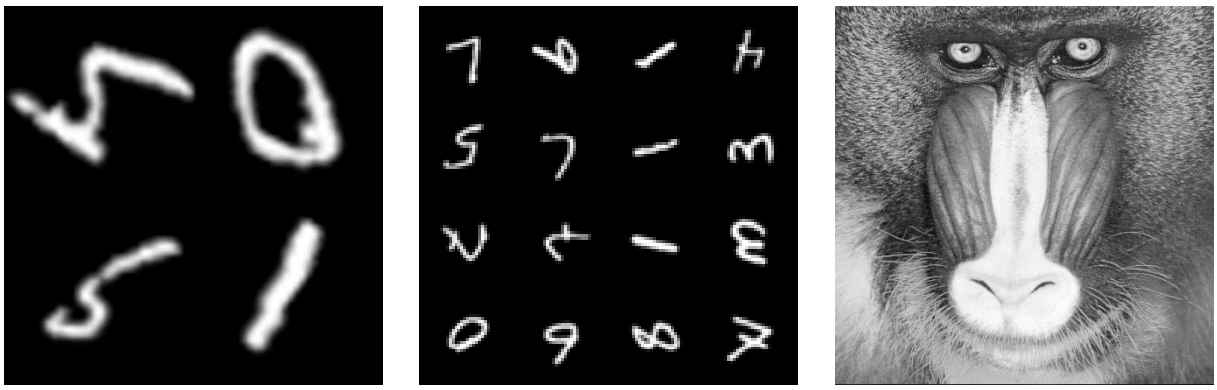


Рис. 2.19 Схема оптической установки для восстановления изображений из КГ.

Nd:YAG лазер, мощностью до 200 мВт с длиной волны 532 нм использовался в качестве источника излучения. Система пространственной фильтрации, состоящая из микролинзы (Линза 1), пинхола и коллимирующей линзы (Линза 2), использовалась для фильтрации луча и увеличения его поперечного размера. Затем излучение проходило через светоделительный куб на фазовый ПВМС HoloEye PLUTO-2 (1920×1080 пикселей; размер пикселя 8×8 мкм), на который выводились восстанавливаемые КГ. Далее излучение проходило через Линзу 3, в фокальной плоскости которой был размещен высокочастотный пространственный фильтр для устранения нулевого порядка дифракции. Далее с помощью Зеркала свет направлялся на Камеру Flare 48MP (7920×6004 пикселей; размер пикселя 4,6×4,6 мкм), располагавшуюся на направляющей, позволявшей перемещать камеру вдоль оси распространения излучения для регистрации каждого сечения 3D-сцены.

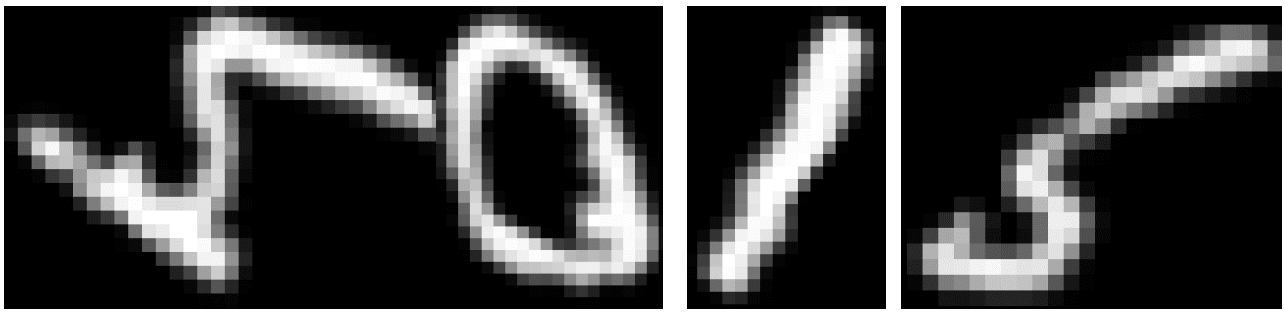
Алгоритм ГС и разработанная, физически-информированная НС использовалась для создания КГ разрешением 1024×1024 пикс. Были протестированы КГ изображений 3D-сцен, состоящих из 4 и 16 сечений. Также была протестирована голограмма 2D естественного изображения для демонстрации возможности применения НС, обученной на синтезированных графических примитивах, для синтеза КГ изображений более сложной структуры. Использованные сцены показаны на рис. 2.20. Объекты в 3D-сценах располагались равноудаленно друг от друга, чтобы минимизировать перекрытие между ними.



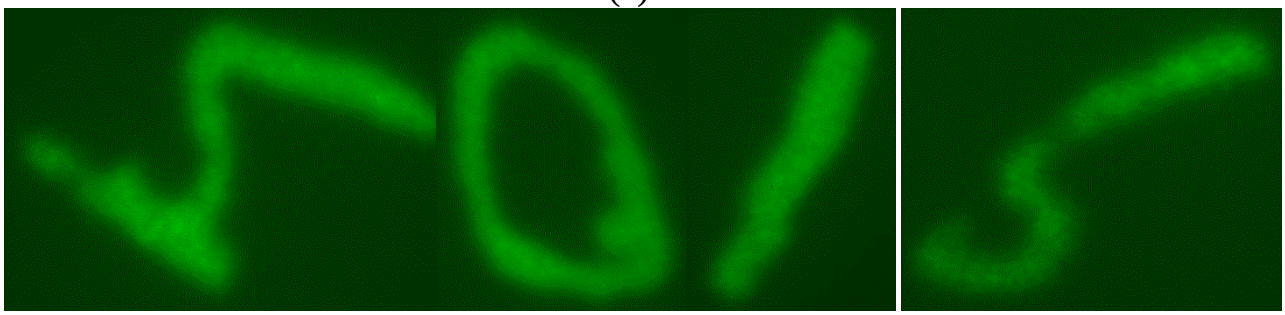
(а) (б) (в)

Рис. 2.20 Сводные изображения сцен, использованных для оптических экспериментов: (а) – 3D-сцена из четырех сечений, каждая цифра – отдельное сечение; (б) – 3D-сцена из 16 сечений, каждая цифра – отдельное сечение; (в) – 2D естественное изображение.

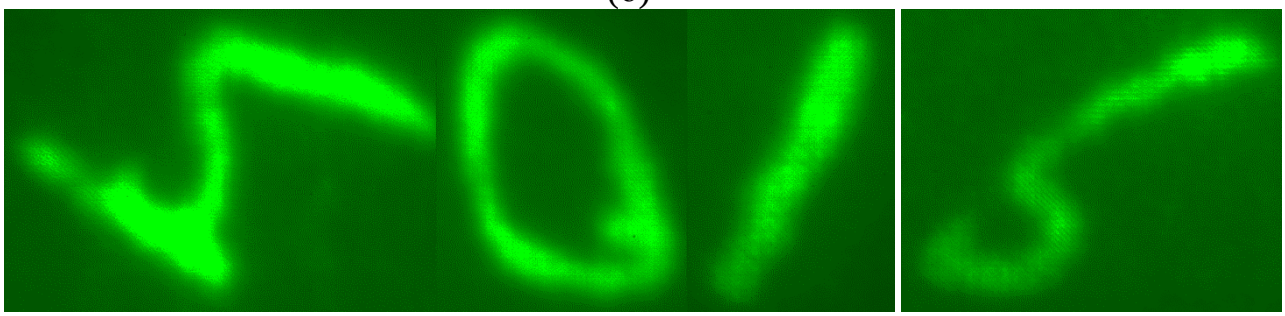
Изображения, оптически восстановленные из КГ изображений 3D-сцены из 4 сечений, синтезированных с использованием алгоритма ГС и обученной НС, а также исходные изображения показаны на рис. 2.21. Расстояния между плоскостью КГ и плоскостями восстановления варьировались от 0,12 до 0,3 м. Численная оценка приведена в таблице 2.6.



(а)



(б)



(в)

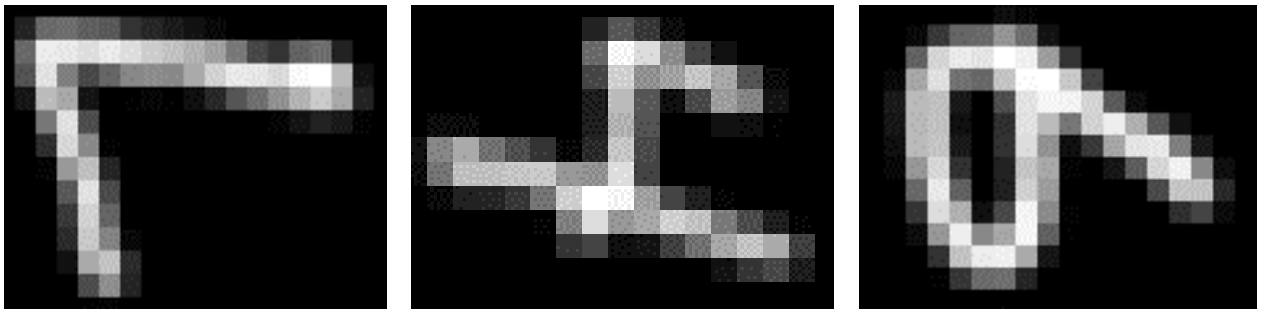
Рис. 2.21 Результаты оптического восстановления: исходные изображения (а); изображения, восстановленные из КГ, синтезированных с использованием алгоритма ГС (б) и разработанной НС (в).

Таблица 2.6 Численная оценка изображений, оптически восстановленных из КГ 3D-сцен, содержащих 4 сечения, синтезированных с использованием алгоритма ГС и разработанной НС.

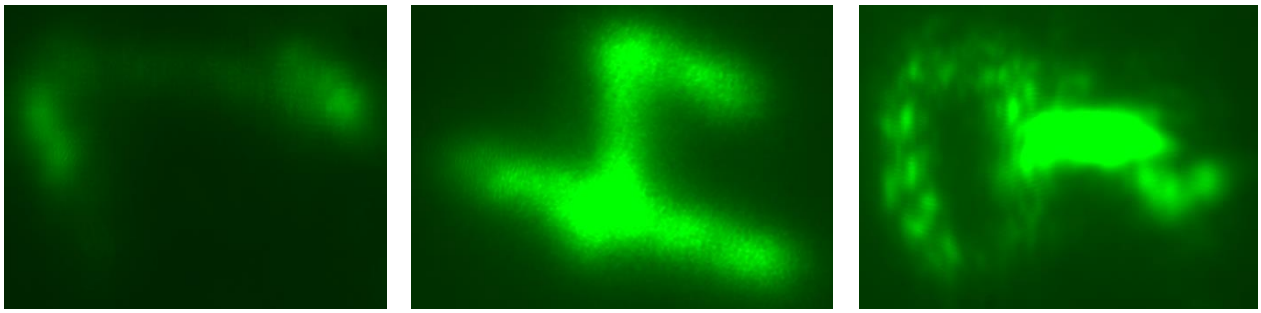
Метод	**Время синтеза, сек**	**КК**
ГС	0,7	0,91 ± 0,02
НС	0,3	0,92 ± 0,03

Из рис. 2.21 и таблицы 2.6 видно, что разработанная НС не уступает алгоритму ГС по качеству восстановленных изображений, превосходя его по скорости синтеза в 2 раза.

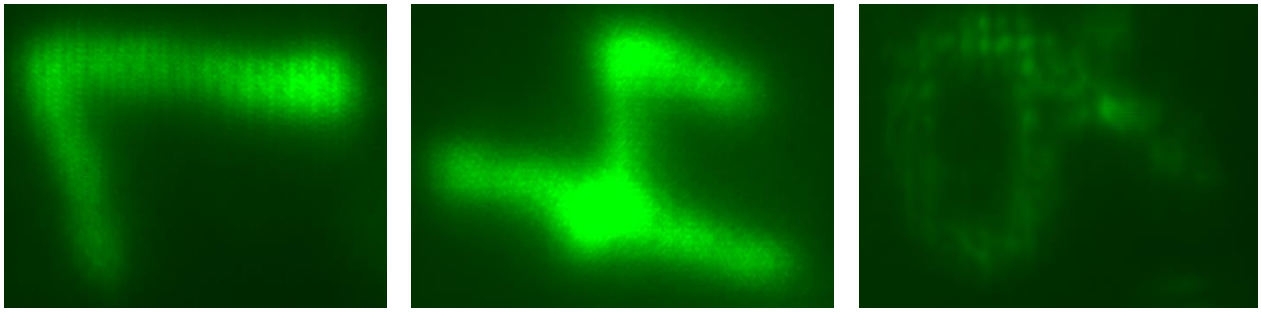
Далее было проведено оптическое восстановление КГ, содержащих 16 сечений 3D-сцены. Расстояние между плоскостями восстановления и плоскостью КГ варьировалось от 0,06 до 0,15 м. Исходные изображения трех из 16 сечений представлены на рис. 2.22а, изображения, восстановленные из КГ, синтезированных с использованием алгоритма ГС и разработанной НС – на рис. 2.22(б, в). Численная оценка представлена в таблице 2.7.



(а)



(б)



(в)

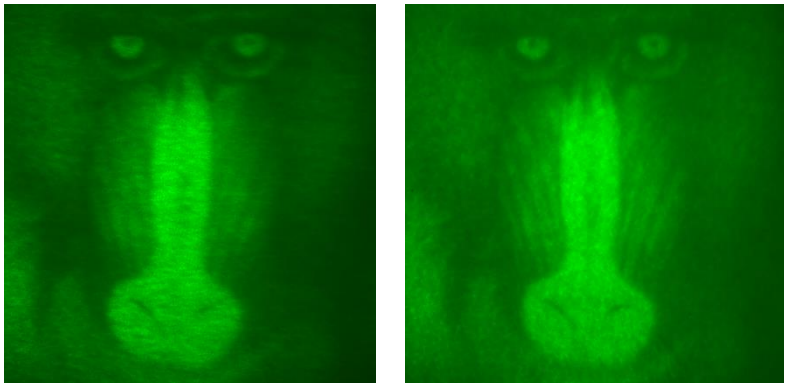
Рис. 2.22 Результаты оптического восстановления изображений из КГ 3D-сцены, содержащей 16 сечений: исходные изображения (а); изображения, восстановленные из КГ, синтезированных с использованием алгоритма ГС (б) и разработанной НС (в).

Таблица 2.7 Численная оценка изображений, оптически восстановленных из КГ 3D-сцены, содержащей 16 сечений, синтезированных алгоритмом ГС и разработанной НС.

Метод	**Время синтеза, сек**	**КК**
ГС	2,5	0,79 ± 0,15
НС	0,4	0,82 ± 0,14

Из рис. 2.22 и таблицы 2.7 видно, что разработанная физически-информированная НС обеспечивает высокое качество восстановления, сравнимое с алгоритмом ГС. Изображения, восстановленные из КГ, синтезированных НС, более четкие и яркие за счет более высокой дифракционной эффективности, по сравнению с изображениями, восстановленными из КГ, синтезированных с использованием алгоритма ГС. Это особенно заметно на рис. 2.22(б, в), где изображение, восстановленное из КГ, синтезированной алгоритмом ГС, имеет лишь небольшую часть четко видимых участков, в то время как изображение НС освещено равномерно и однородно.

Изображения, восстановленные из КГ полутоновой сцены, синтезированных с использованием разработанного НС метода и алгоритма ГС, показаны на рис. 2.23, численная оценка – в таблице 2.8.



(а) (б)

Рис. 2.23 Результаты оптического восстановления полутоновой сцены: изображение, восстановленное из КГ, синтезированных ГС (а) и НС (б).

Таблица 2.8 Численная оценка изображений, оптически восстановленных из КГ, синтезированных с использованием алгоритма ГС и разработанной НС модели.

Метод	**Время синтеза, сек**	**КК**
ГС	0,17	0,69
НС	0,05	0,69

В случае КГ 2D-сцены разработанная НС превосходит алгоритм ГС по скорости в три раза, без потери качества восстановленного изображения. Это показывает, что разработанный физически-информированный нейросетевой метод способен синтезировать КГ сложных полутоновых сцен с качеством на уровне современных итеративных алгоритмов. Данные результаты также подтверждают, что НС, обученная только на простых численно-синтезированных объектах, может успешно обрабатывать произвольные естественные сцены.

Выводы по второй главе

1. Предложена физически-информированная архитектура нейронной сети, содержащая две ветви декодера, которая интегрирует численную модель расчета дифракции Френеля для синтеза компьютерных голограмм изображений 3D-сцен.
2. Показано, что нейронные сети, обученные с использованием разработанных обучающих выборок на основе графических примитивов, могут быть успешно применены для синтеза голограмм, содержащих объекты различных классов (контурные, бинарные, естественные полутоновые).
3. Продемонстрирована возможность использования однократно обученной разработанной нейронной сети для синтеза голограмм со значениями параметров дифракции, отличными от использованных при обучении.
4. Разработанная физически-информированная нейронная сеть может быть применена для синтеза компьютерных голограмм цветных сцен. Восстановление изображений из голограмм, синтезированных с использованием разработанной нейронной сети, происходит без возникновения искажений, которые могут быть восприняты как ложные объекты, в отличие от традиционного алгоритма синтеза.
5. Численное и оптическое восстановление голограмм показало, что предложенная физически-информированная нейронная сеть может обеспечить повышение скорости синтеза голограмм изображений 3D-сцен на порядок по сравнению с итеративными алгоритмами, с эквивалентным качеством восстановления (значения коэффициента корреляции совпадают с точностью 99,5%).

3. Нейросетевая фильтрация голограмм 2D- и 3D-сцен

Методы, основанные на использовании НС, позволяют эффективно извлекать информацию из голограмм напрямую, без восстановления всех дифракционных порядков. Однако итогом работы подобных методов, как правило, является объектная информация в плоскости восстановления. То есть, после их применения теряется возможность работы непосредственно с голограммой для ее дальнейшей модификации.

Таким образом, существует задача создания метода фильтрации голограмм, который позволит восстанавливать из фильтрованных голограмм изображения, не подверженные негативному влиянию нежелательных порядков дифракции. Подобный метод может быть использован в комбинации с традиционными методами для дальнейшего улучшения качества восстановленных изображений (например, подавления шумов).

3.1 Методы восстановления изображений из голограмм, основанные на парном обучении

В качестве примера нейронной сети, которая восстанавливает интенсивность объектной волны из голограммы напрямую, может быть рассмотрена модель на основе архитектуры U-Net. Для ее обучения применялась обучающая выборка, состоящая из голограмм и соответствующих им исходных изображений. Для этого были использованы 50 000 изображений рукописных цифр из набора MNIST и рассчитанные от них методом прямого расчета дифракции амплитудные голограммы Френеля со случайной фазовой составляющей. Примеры КГ, использованных в процессе обучения, исходного изображения и изображения, восстановленного из КГ без применения фильтрации, представлены на рис. 3.1.



(а) (б)

Рис. 3.1 Фазовая КГ, рассчитанная методом прямого расчета дифракции (а), исходный объект (б), изображение, восстановленное из КГ без применения фильтрации (в).

Как видно из рис. 3.1, изображение, восстановленное без применения фильтрации, практически полностью перекрывается нулевым порядком дифракции, что демонстрирует необходимость применения фильтрации для его подавления.

Восстановление с использованием обученной НС представлено на рис. 3.2, численная оценка – в таблице 3.1.



(а) (б) (в)

Рис. 3.2 Фазовая КГ (а); восстановленное с использованием обученной НС изображение (б); исходный объект (в).

Таблица 3.1 Численное сравнение исходных изображений и изображений, восстановленных с использованием НС (среднее по 100 изображениям)

КК	ИСС
0,9996±0,0003	0,87±0,07

Как видно из рис. 3.2 и таблицы 3.1, НС позволяет качественно восстановить исходное изображение и подавить нежелательные порядки дифракции. Продемонстрированный метод показывает, что НС могут быть эффективно использованы для восстановления изображений из голограмм. Однако при таком подходе восстановление происходит путем непосредственного извлечения интенсивности исходного изображения.

Подобные НС методы активно развиваются, например, в [65] была представлена архитектура Y-Net, с двумя ветвями декодера, одна из которых отвечала за восстановление амплитудной информации, а вторая – фазовой. Для обучения использовалась выборка, состоявшая из цифровых голограмм и восстановленной амплитудной и фазовой информации в объектной плоскости. Такой подход демонстрирует потенциал развития НС методов для полного восстановления объектной волны из голограмм, однако он также не позволяет получить фильтрованную голограмму, которая может быть восстановлена в сочетании с традиционными методами для дальнейшего улучшения качества восстановления.

3.2 Разработанная двухканальная нейросетевая архитектура для фильтрации голограмм

Для подавления влияния нулевого порядка дифракции с сохранением голограммы для дальнейшей обработки был разработан нейросетевой метод извлечения амплитудной и фазовой информации объектной волны в плоскости голограммы. Такой подход является альтернативой прямого извлечения информации в плоскости восстановления и может быть применен для голограмм 2D- и 3D-сцен.

Используется сверточная архитектура нейронной сети с двумя ветвями декодера, основанная на архитектуре Y-net, представленной в [65]. В подходе [65] восстановление амплитудной и фазовой информации выполняется в плоскости восстановления, а обучающая выборка состоит из цифровых голограмм и восстановленной из них амплитудной и фазовой информации. В отличие от [65], разработанный метод действует в плоскости голограммы и использует обучающую выборку, состоящую из компьютерных голограмм Френеля и соответствующей им амплитудно-фазовой объектной информации в плоскости голограммы. Схема архитектуры НС представлена на рис. 3.3.

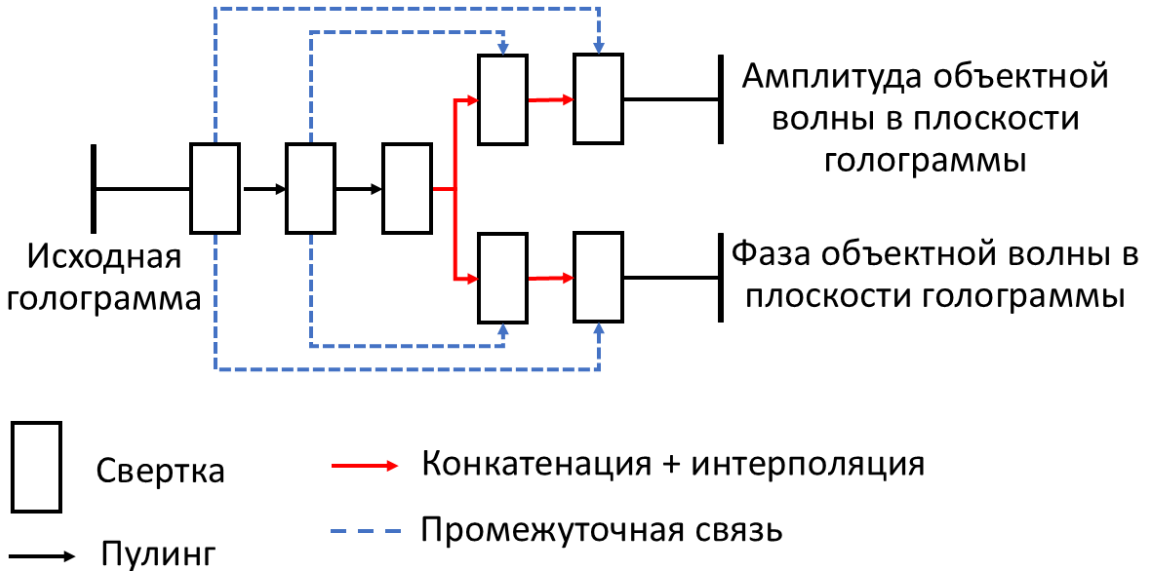


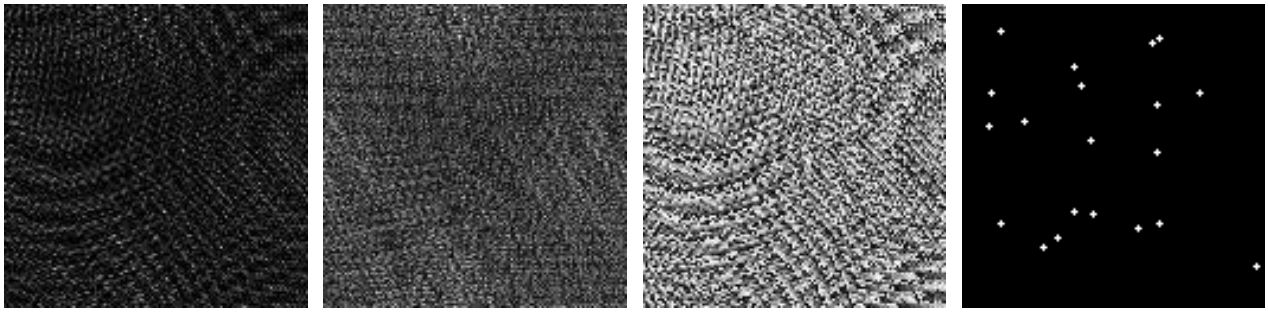
Рис. 3.3 Схема используемой архитектуры НС с двумя ветвями декодера [65].

Результатом работы разработанного метода является амплитуда и фаза объектной волны в плоскости голограммы. Нейронная сеть отбрасывает информацию, отвечающую за нежелательные порядки дифракции и позволяет использовать полученные амплитудно-фазовые распределения для восстановления качественных изображений.

3.3 Синтез обучающей выборки

Для синтеза КГ использовались изображения графических примитивов, представленные во второй главе. Обучающая выборка состояла из 50 000 КГ Френеля со случайной фазовой составляющей, разрешением 128×128 пикс,

каждой из которых соответствует амплитудно-фазовое распределение объектной волны в плоскости голограммы. Примеры КГ, амплитудного и фазового распределения объектной волны, а также исходного изображения представлены на рис. 3.4.



(а) (б) (в) (г)

Рис. 3.4 Пример объектов из обучающей выборки: КГ (а); амплитуда (б) и фаза (в) объектной волны; исходный объект (г).

Для обучения использовался алгоритм оптимизации Adam с начальным шагом 0,002. Расчет проводился с использованием графического процессора NVIDIA GeForce RTX 4090.

3.4 Фильтрация голограмм 2D-сцен

Пример исходной голограммы представлен на рис. 3.5(а); исходного изображения на рис. 3.5(б), исходного амплитудно-фазового распределения на рис. 3.5(в), амплитудно-фазового распределения, синтезированного с использованием обученной НС на рис. 3.5(г), изображения, восстановленные прямым расчетом дифракции из исходной голограммы и фильтрованного с использованием НС амплитудно-фазового распределения – на рис.3.5(д, е). Численная оценка качества восстановленных изображений представлена в таблице 3.2, значения рассчитывались по 100 проверочным КГ, которые не участвовали в обучении.

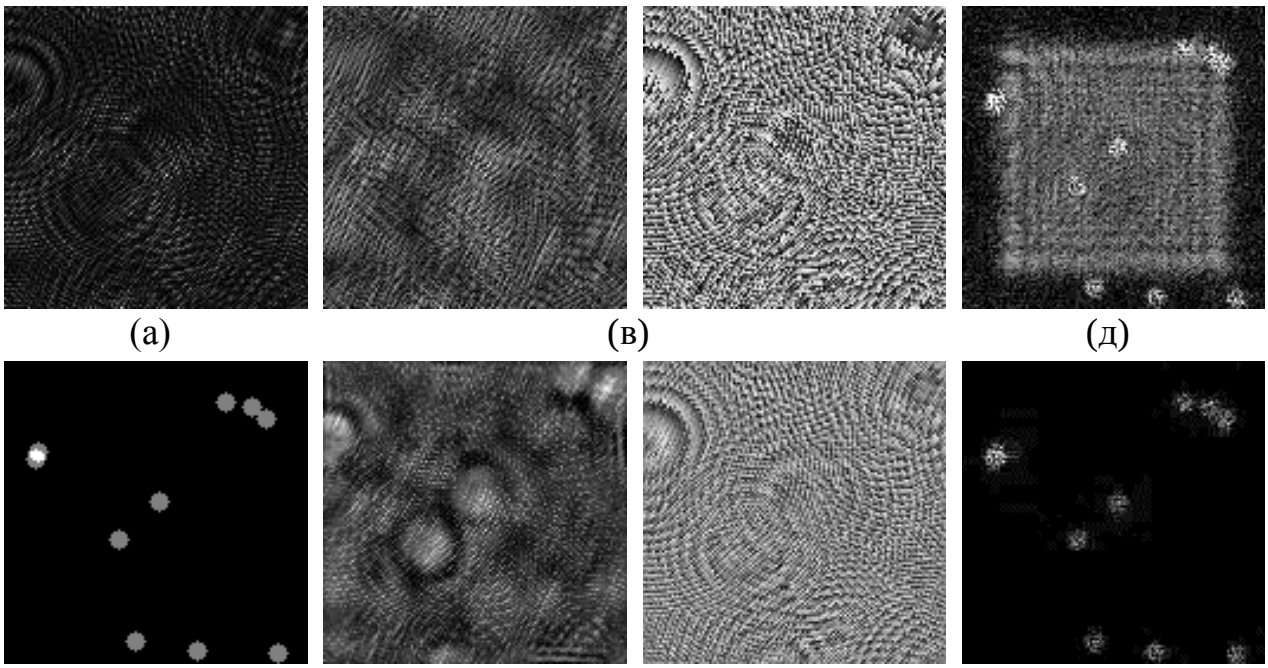


Рис. 3.5 Голограмма (а); исходное изображение (б); амплитуда и фаза объектной волны (в); амплитудная и фазовая информация, извлеченная с использованием обученной НС (г); изображение, восстановленное из голограммы напрямую (д); изображение, восстановленное из амплитудно-фазового распределения, извлеченного обученной НС (е).

Таблица 3.2 Численная оценка качества изображений, восстановленных с использованием обученной НС.

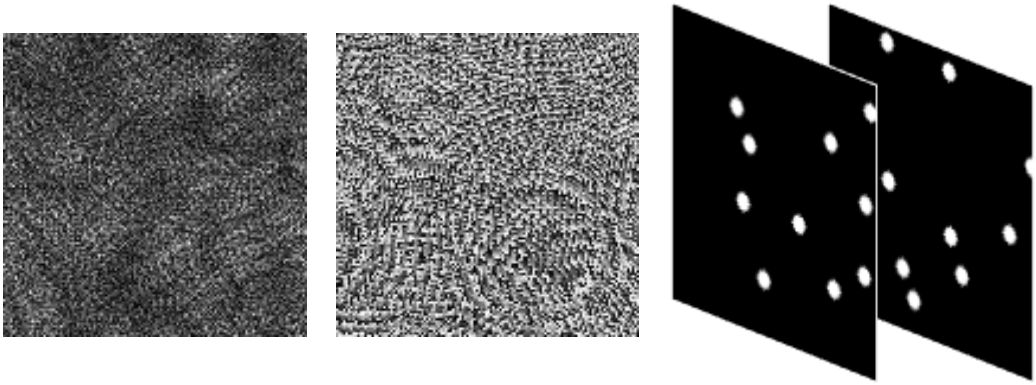
Метрика	**НС**	**Прямое восстановление**
КК	0,67±0,02	0,39±0,04
ИСС	0,73±0,09	0,15±0,06

Как видно из рис. 3.5 и таблицы 3.2, разработанная НС позволяет значительно подавить влияние нулевого порядка дифракции на качество восстановленных изображений. Это подтверждается как визуальной, так и численной оценкой.

3.5 Фильтрация голограмм 3D-сцен

Разработанный метод также может быть применен для голограмм 3D-сцен. В данном случае обучающая выборка состояла из 100 000 КГ, с

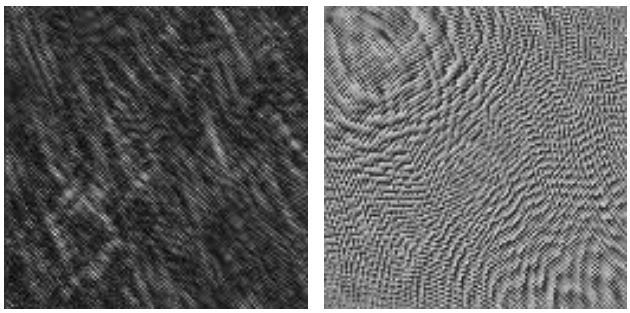
разрешением 128×128 пикселей, каждая из которых содержала два объектных сечения. Пример распределения амплитуды и фазы объектной волны в плоскости голограммы; двух плоских сечений, формирующих 3D-сцену в плоскости восстановления представлен на рис. 3.6. Амплитуда и фаза связаны с объектными сечениями расчетом распространения излучения на соответствующие расстояния (0,02 м, 0,023 м).



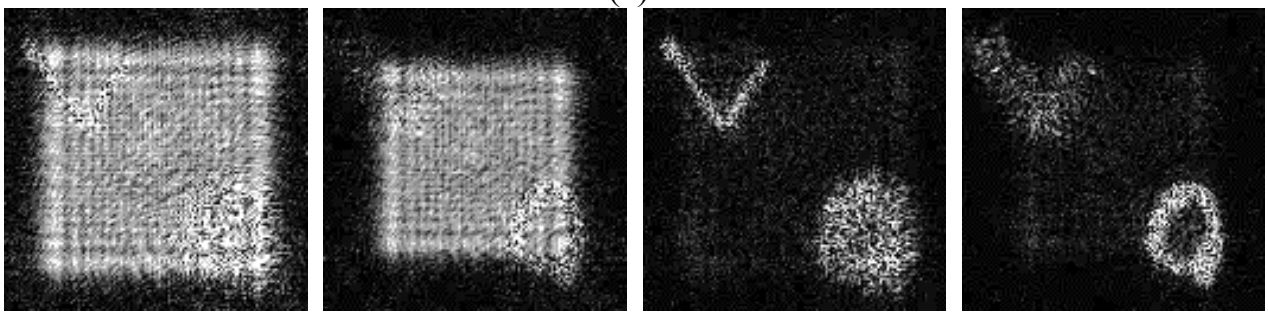
(а) (б) (в)

Рис. 3.6 Пример: амплитуды (а) и фазы (б) объектной волны, и соответствующие сечения 3D-сцены (в).

Пример результата восстановления изображений с использованием амплитудной и фазовой информации, извлеченной обученной НС в сравнении с восстановлением без применения фильтрации показан на рис. 3.7, на примере КГ 3D-сцены, состоящей из двух объектов из базы данных рукописных цифр MNIST. Использование объектов, отличных от использованных в процессе обучения позволяет продемонстрировать, что разработанная НС не ограничена только одним типом объектов, и демонстрирует эффективность обучающей выборки, состоящей из численно-синтезированных графических примитивов. Численная оценка приведена в таблице. 3.3.



(а)



(б) (в)

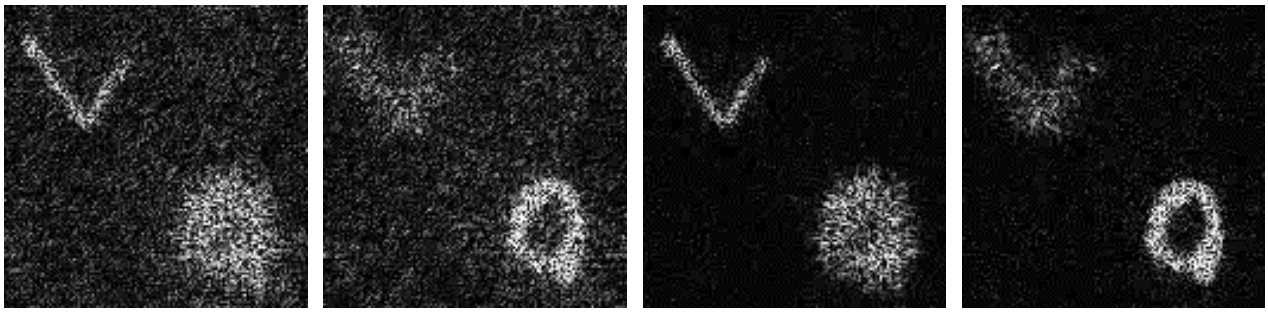
Рис. 3.7 Распределения амплитуды и фазы объектной волны, полученные с использованием обученной НС (а); соответствующие изображения сечений 3D-сцены восстановленные без применения фильтрации (б); с применением нейросетевой фильтрации (в).

Таблица 3.3 Численная оценка качества изображений сечений 3D-сцен, восстановленных с использованием НС и методом прямого расчета дифракции.

Метрика	**Сечение**	**Прямой расчет дифракции**	**НС**
КК	1	0,21±0,05	0,46±0,11
	2	0,22±0,05	0,60±0,08
ИСС	1	0,13±0,03	0,45±0,09
	2	0,26±0,05	0,51±0,09

Как видно из рис. 3.7 и таблицы 3.3, разработанный НС подход обеспечил не только качественное восстановление всех сечений 3D-сцены, но и значительное подавление нежелательных порядков дифракции. Однако, на восстановленных изображениях все еще заметен нулевой порядок дифракции. Он может быть дополнительно подавлен с использованием частотной фильтрации. Примеры восстановления с применением

дополнительной частотной фильтрации (обнуления части спектра, отвечающей за нулевой порядок) представлены на рис. 3.8. Численная оценка приведена в таблице 3.4.



(а) (б)

Рис. 3.8 Изображения, восстановленные с применением частотной фильтрации (а); с применением разработанной нейросетевой и частотной фильтрации (б).

Таблица 3.4 Численная оценка качества изображений сечений 3D-сцен, восстановленных с использованием НС и методом прямого расчета дифракции, с применением дополнительной частотной фильтрации.

Метрика	**Сечение**	**Прямой расчет дифракции + фильтрация**	**НС + фильтрация**
КК	1	0,40±0,11	0,46±0,12
	2	0,55±0,08	0,61±0,08
ИСС	1	0,18±0,07	0,55±0,11
	2	0,23±0,08	0,60±0,11

Как видно из рис. 3.8 и таблицы 3.4, применение дополнительной фильтрации после нейросетевого метода позволило дополнительно улучшить качество восстановления (ИСС в 2,5 раза) и подавить большую часть нулевого порядка дифракции по сравнению с применением только частотной фильтрации.

Полученные результаты показывают эффективность разработанного метода фильтрации, действующего в плоскости голограммы. Он позволяет работать с голограммами как 2D- так и 3D-сцен, эффективно извлекая из них объектную информацию. После применения разработанного метода

сохраняется возможность дополнительной обработки голограммы с применением традиционных методов фильтрации, что приводит к дальнейшему увеличению качества восстановленных изображений.

Выводы по третьей главе

1. Разработан нейросетевой метод извлечения амплитудной и фазовой информации объектной волны в плоскости голограммы, основанный на архитектуре с двумя ветвями декодера.
2. Применение разработанного метода позволяет в значительной степени ослабить нулевой порядок дифракции в восстановленном изображении голограмм как 2D- так и 3D-сцен, но не удалить его полностью.
3. Показано, что комбинация частотной фильтрации и разработанного нейросетевого метода позволяет практически полностью устранить нулевой порядок дифракции и улучшить качество восстановленных изображений 3D-сцен по значению индекса структурного сходства в 2,5 раза, в сравнении с применением только частотной фильтрации.

4. Восстановление сигналов в микроволновой фотонике

Современные методы применения нейронных сетей в задачах коррекции нелинейностей аналоговых оптических трактов часто основываются на применении сверточных нейронных сетей. Существующие подходы позволяют существенно улучшить качество сигналов – например, повысить эффективное число бит с 4,5 до 7,1 [98]. Однако они часто обучаются с использованием выборок, содержащих сигналы с ограниченным диапазоном частот и амплитуд, что ограничивает применимость обученной нейронной сети.

4.1 Нейросетевая фильтрация однотоновых сигналов

Для регистрации сигналов использовался АОТ L-диапазона, его схема представлена на рис. 4.1. АОТ состоит из генератора, полупроводникового лазера, излучение которого по оптоволокну предается на фотоприемник и АЦП. Для контроля рабочей точки полупроводникового лазера использовался контроллер. С использованием данной схемы, было записано десять сигналов на частотах от 10 до 100 МГц. Подаваемая мощность сигнала составляла 1 dBm.

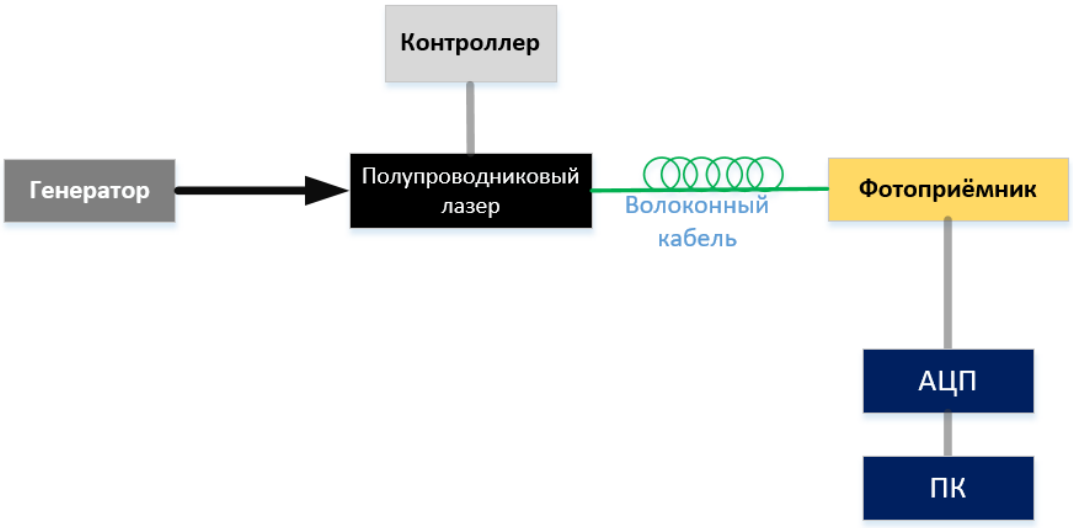
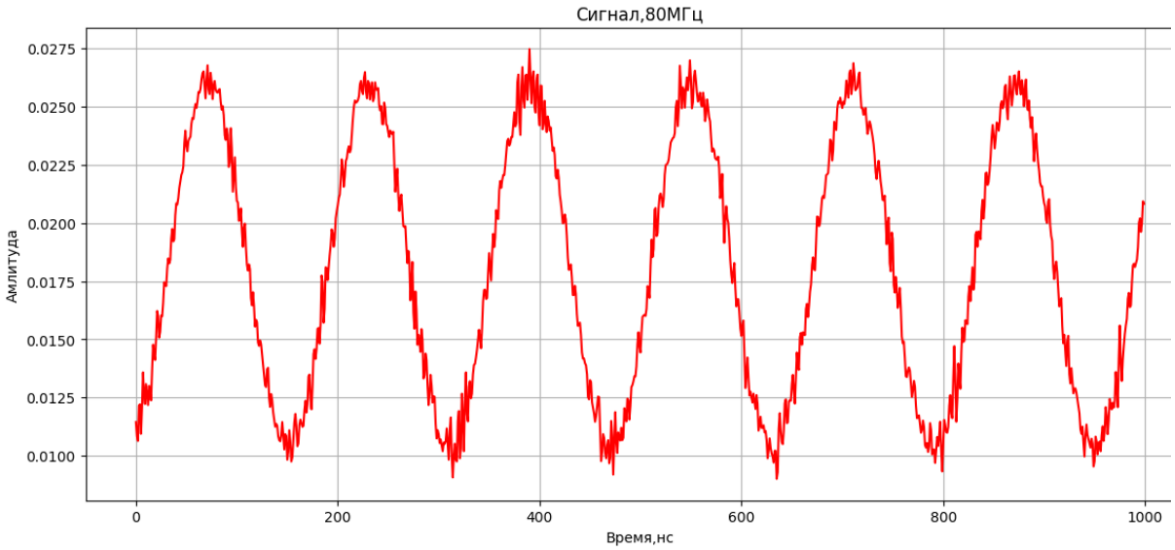
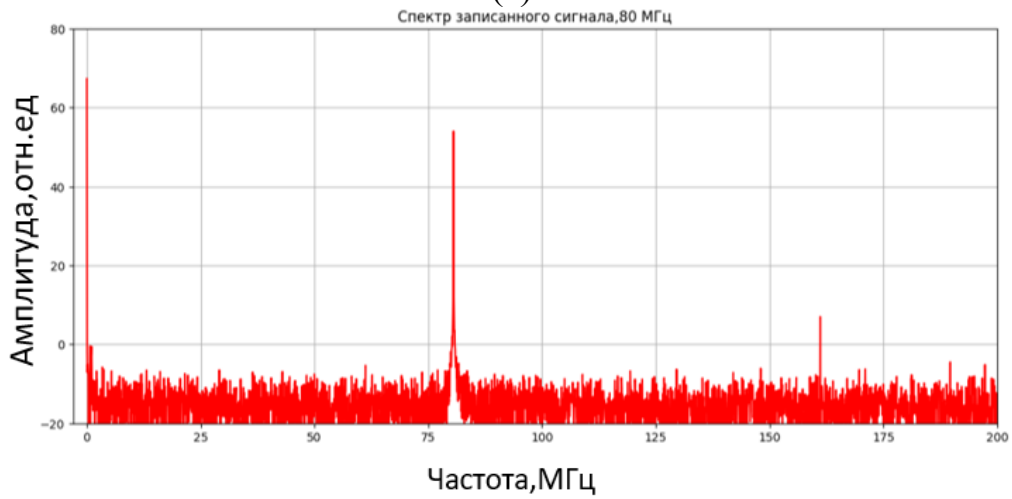


Рис. 4.1 Схема генерации синусоидальных однотонных сигналов с прямой модуляцией.

Пример синусоидального сигнала, зарегистрированного с использованием АОТ представлен на рис. 4.2(а), его спектр – на рис. 4.2(б).



(а)



(б)

Рис. 4.2 Пример синусоидального сигнала, записанного с использованием аналогового оптического тракта (а), и его спектра (б).

На спектре записанного сигнала наблюдается основная частота 80 МГц, а также частота второй гармоники 160 МГц. Для создания обучающей выборки из зашумленных данных были записаны сигналы на частотах от 10 до 100 МГц с шагом 10 МГц.

Разработанный нейросетевой метод фильтрации сигналов в радиофотонике основан на архитектуре U-net. Обучающая выборка состояла из пар «зашумленных» и «не зашумленных» сигналов. Из записанного набора сигналов использовались два сигнала с частотами 50 МГц и 80 МГц.

Далее для этих сигналов аппроксимировался ожидаемый сигнал, имеющий вид идеального синусоидального сигнала. На рис. 4.3 представлены примеры указанных сигналов.

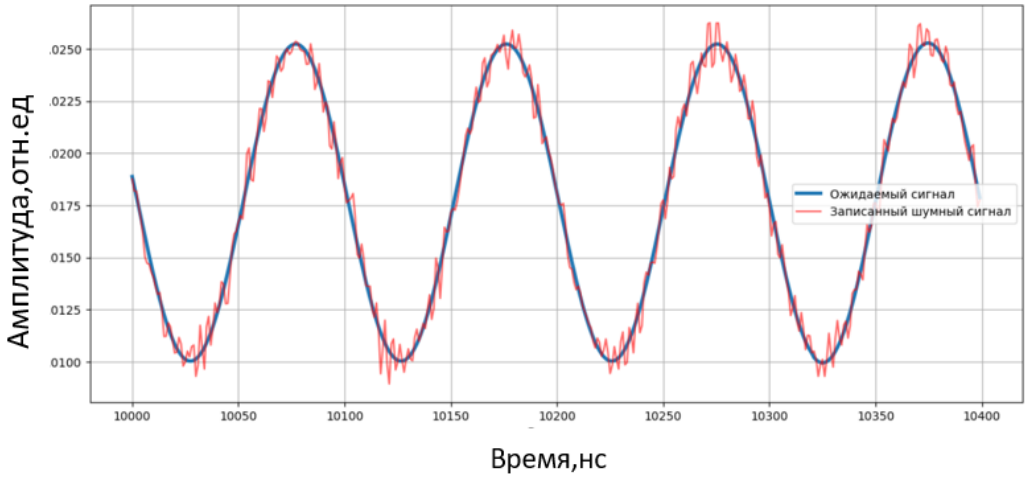
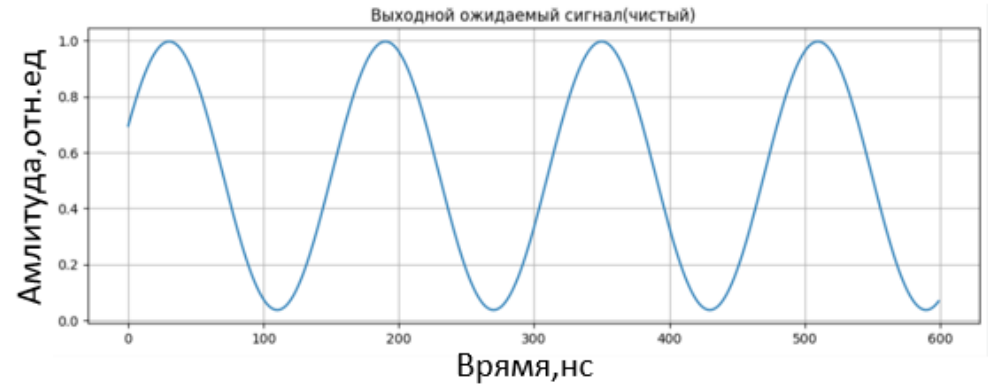


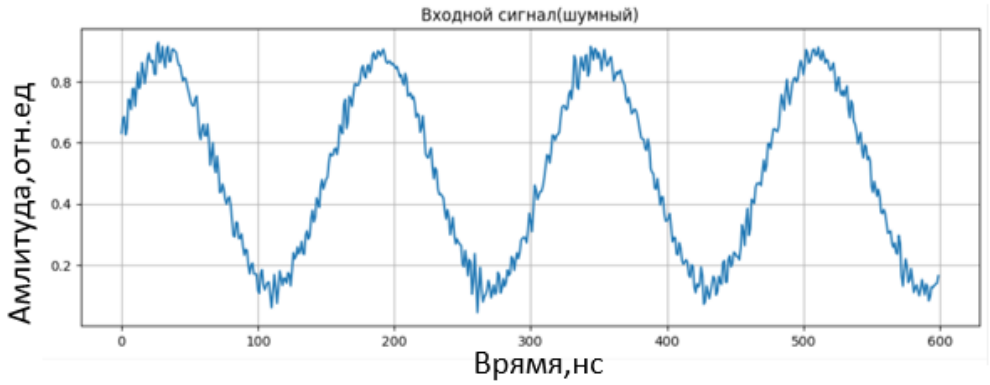
Рис. 4.3 Пример сигналов, использованных для создания обучающей выборки: сигнал, зарегистрированный с использованием оптического тракта и сгенерированный синусоидальный сигнал.

Синтез идеального сигнала для каждого участка зашумленного сигнала происходил путем его аппроксимации по параметрам частоты и фазы зашумленного сигнала. Далее для сигналов с шумом подбирался ожидаемый сигнал, имеющий вид идеального синусоидального сигнала. После чего, сигналы, записанные для двух частот, объединялись в единый набор. Далее входной вектор данных разделялся на матрицы размером 64×64 значения. Таким образом, сигнал преобразовывался в трехмерную структуру данных, имеющую вид 72 матриц размером 64×64.

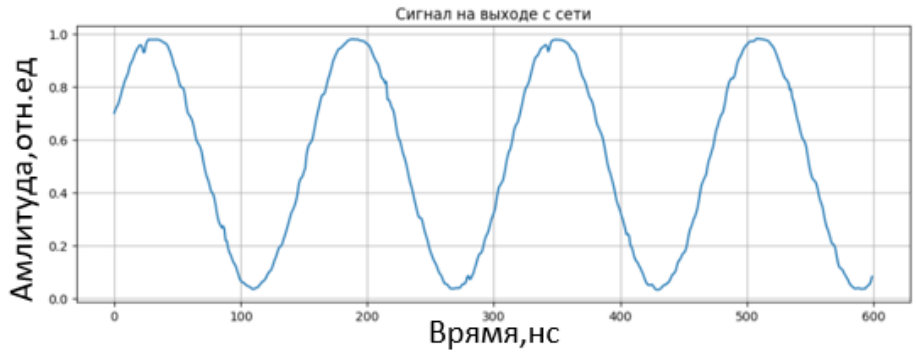
На рис 4.4 показаны графики сигналов, сгенерированных нейронной сетью в сравнении с входными зашумленными сигналами и исходным синусоидальным сигналом, на примере сигнала с частотой 50 МГц, который присутствовал в обучающей выборке.



(а)



(б)



(в)

Рис. 4.4. Пример исходного синусоидального сигнала (а); сигнала, записанного с аналогового оптического тракта (б), сигнала, полученного с использованием обученной нейронной сети (в).

На рис. 4.5 приведено сравнение сигнала, сгенерированного с использованием НС, с исходным и с оцифрованным сигналом, зарегистрированным с использованием аналогового оптического тракта.

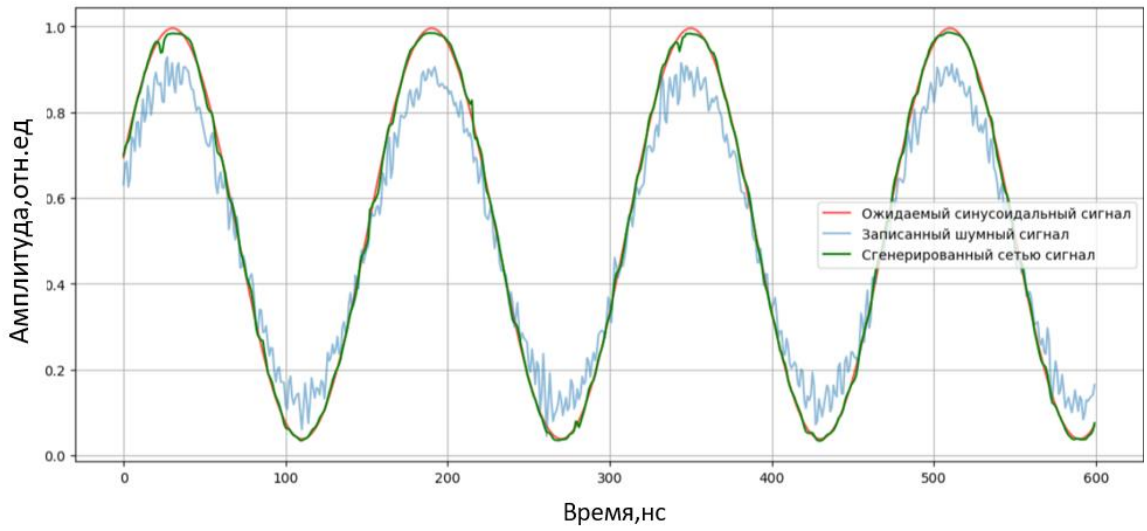
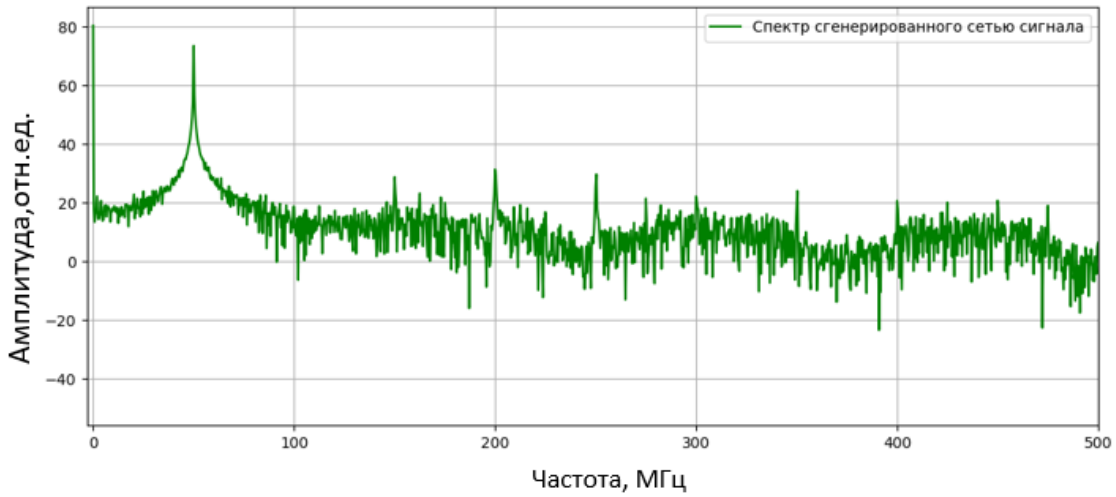
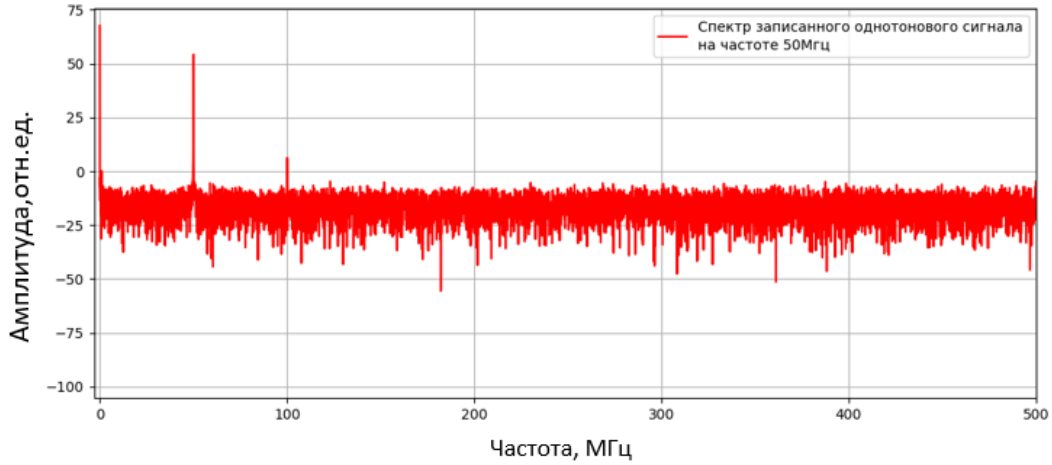


Рис. 4.5 Сигнал, сгенерированный нейронной сетью в сравнении с ожидаемым синусоидальным и записанным с тракта сигналами, на частоте 50МГц.

Из рис. 4.5 видно, что полученный с использованием обученной нейронной сети сигнал, совпадает с ожидаемым по фазе и амплитуде, однако, наблюдаются неровные участки. Примеры спектров сгенерированного исходного сигналов в масштабе несущей частоты представлены на рис. 4.6.



(а)

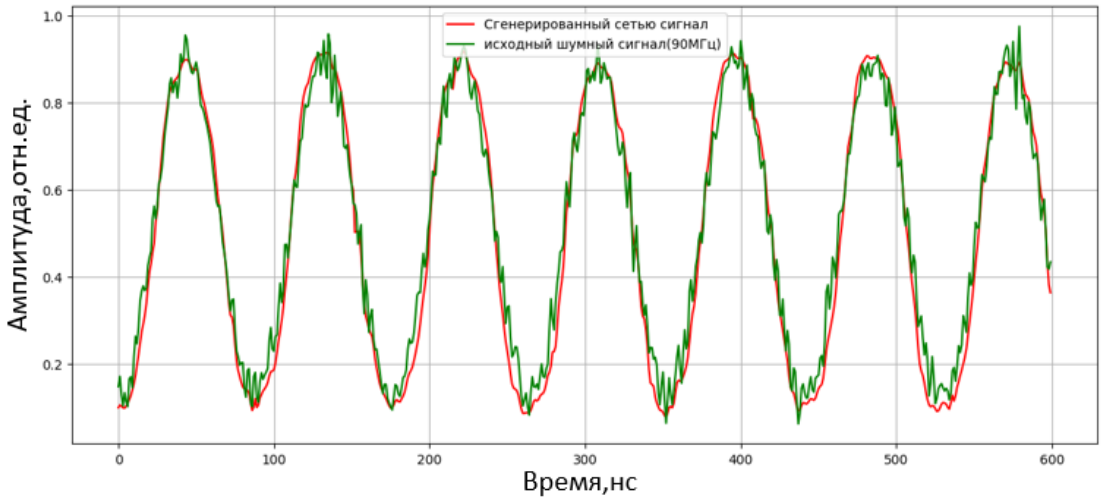


(б)

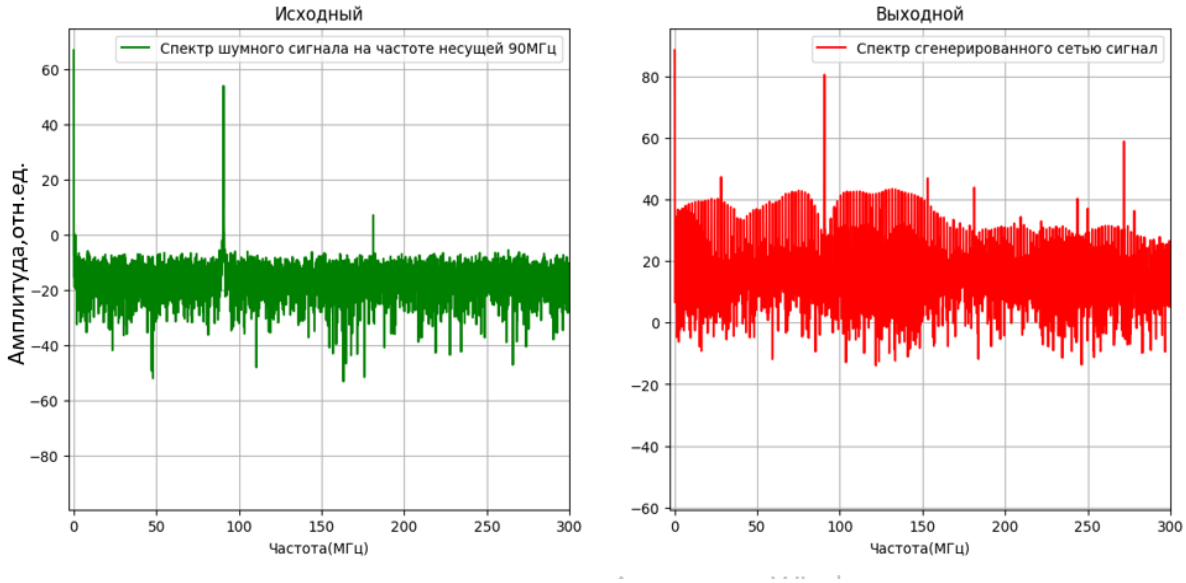
Рис. 4.6 Пример спектров входного однотонного сигнала (а), и выходного сигнала, сгенерированного с использованием обученной НС (б).

Из вида спектров сигналов видно, что обученная нейронная сеть способна устранить гармонику второго порядка. Однако, после нейросетевой обработки, во входном сигнале наблюдаются дополнительные составляющие, которые не присутствовали в исходном сигнале.

Также с использованием обученной НС были обработаны сигналы с частотами, которые не входили в обучающий набор. На рис. 4.7 представлен пример нейросетевой обработки сигнала с частотой 90 МГц, который не входил в обучающую выборку.



(а)



(б)

Рис. 4.7 Пример исходного, зашумленного сигнала, с частотой 90 МГц и сигнала сгенерированной НС, обученной на синусоидальных сигналах частотой 50 МГц; Пример спектров сигналов, исходного зашумленного сигнала, полученного с использованием НС (б).

Из рис. 4.7 видно, что сигнал, полученный с использованием НС совпадает с исходным, записанным с тракта сигналом, с частотой, отличной от частоты сигнала, содержавшегося в обучающей выборке. Однако, вид спектра сгенерированного сигнала, не соответствует спектру идеального синусоидального сигнала. Таким образом, применение разработанного нейросетевого метода для обработки сигналов, не входящих в обучающую

выборку, может привести к появлению «лишних» гармоник в спектре сигнала.

4.2 Нейросетевая фильтрация двухтоновых сигналов

Разработанная нейронная сеть также была применена для обработки двухтоновых сигналов. На рис. 4.8 представлена схема АОТ, на вход которого подается двухтоновый сигнал. Модулирующий сигнал поступает на полупроводниковый лазер в виде суммы двух сигналов с отстройкой по частоте 10 МГц. Один из сигналов поступает с генератора, а другой с синтезатора, далее через сумматор сигналы направлялись на полупроводниковый лазер. Сумматор представлял собой делитель мощности (WA1515), на один из выходов которого был поставлен отражатель.

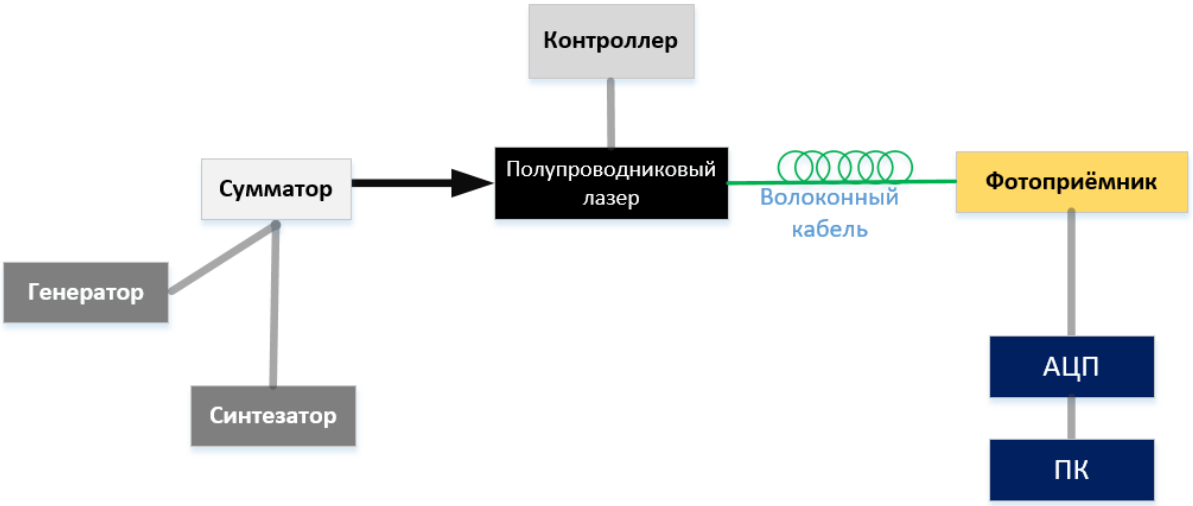


Рис. 4.8 Схема оцифровки двухтоновых сигналов, с прямой модуляцией.

Для оценки амплитуд нелинейных составляющих сигнала, при создании обучающей выборки учитывались величины сигналов, прошедших через АОТ. Примеры нелинейностей различных порядков для двухтонового сигнала с частотами 600 и 610 МГц представлены на рис. 4.9.

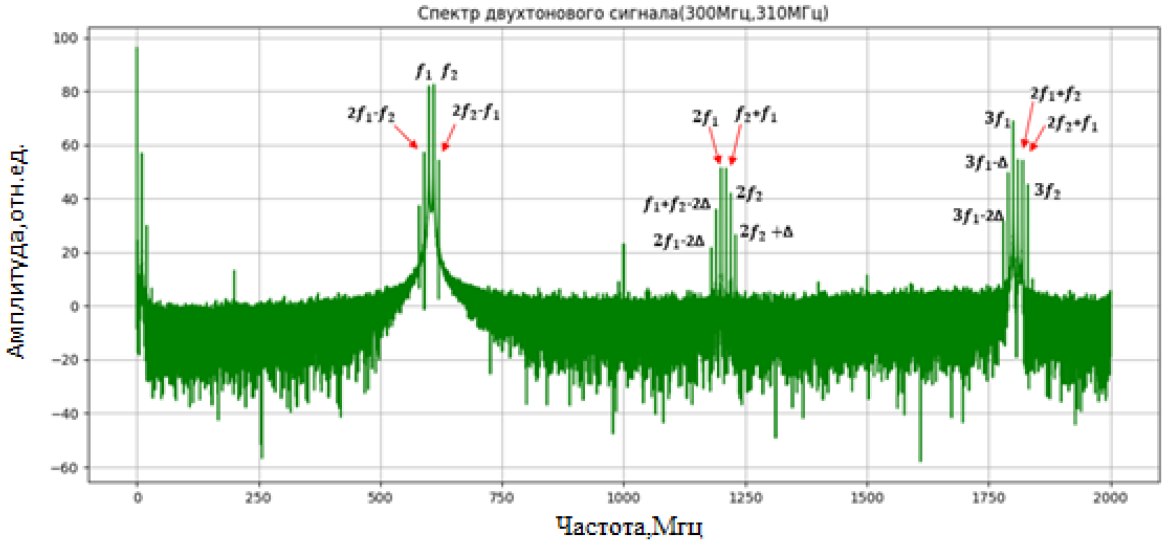


Рис. 4.9 Спектр записанного двухтонового сигнала (на частотах 300 и 310МГц) с отмеченными на нем величинами частот нелинейных гармоник.

Шум, сигнала АОТ, принимался Гауссовым, при анализе записанных сигналов был измерен уровень шума, величина которого составила 0,004% от амплитуды несущей частоты. Обучение НС фильтрации двухтоновых сигналов выполнялось с использованием обучающей выборки, состоявшей из численно-синтезированных сигналов, содержавших несколько гармоник. На рис. 4.10 представлен пример сигналов, которые были использованы для создания обучающей выборки. Использовались сигналы на разных частотах, с учетом и без учета нелинейных искажений, и шумов, уровень шума повышался для более явного выделения параметра шума в сравнении с эталонным сигналом.

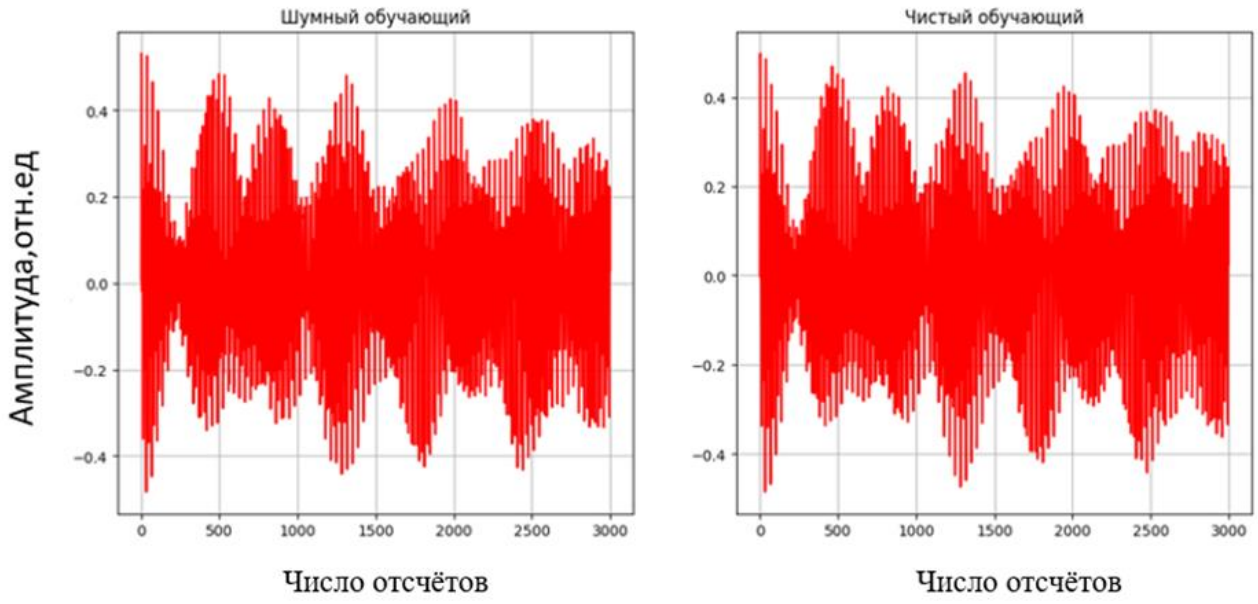
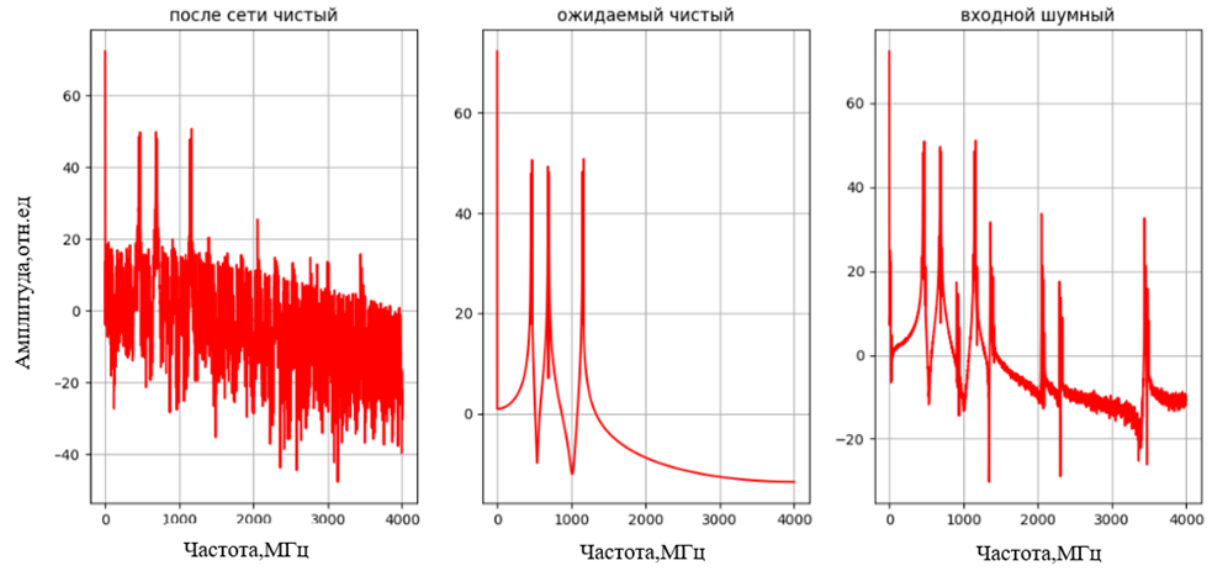


Рис. 4.10 Пример двухтоновых сигналов использованных, для создания обучающей выборки.

На рис. 4.11 представлен сигнала, фильтрованного с использованием обученной НС.



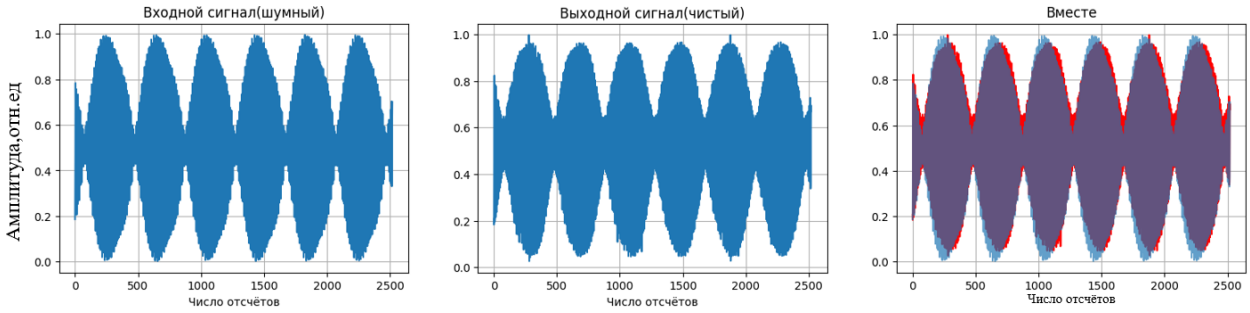
(а) (б) (в)

Рис. 4.11 Пример спектра сигнала, полученного с использованием обученной НС (а); пример спектра исходного незашумленного сигнала (б); пример спектра исходного зашумленного сигнала (в).

Из рис. 4.11 видно, что в спектре выходного сигнала, уменьшилась амплитуда нелинейных искажений сигнала, а величины некоторых составляющих уменьшены до уровня шумов. Однако, после нейросетевой

обработки в спектре выходного сигнала наблюдается значительный уровень шума.

Также была опробована возможность линеаризации двухтонового входного сигнала с использованием обученной НС. Примеры таких сигналов представлены на рис. 4.12.



(а) (б) (в)

Рис. 4.12 Исходный зашумленный двухтоновой сигнал(а); сигнал, полученный с использованием обученной НС (б); сравнение исходного и фильтрованного сигналов.

Из рис.4.12, видно, что НС успешно восстановила форму и амплитуду сигнала, однако в отфильтрованном сигнале присутствуют дополнительные искажения. На рис. 4.13 представлены спектры исходного зашумленного и фильтрованного сигналов.

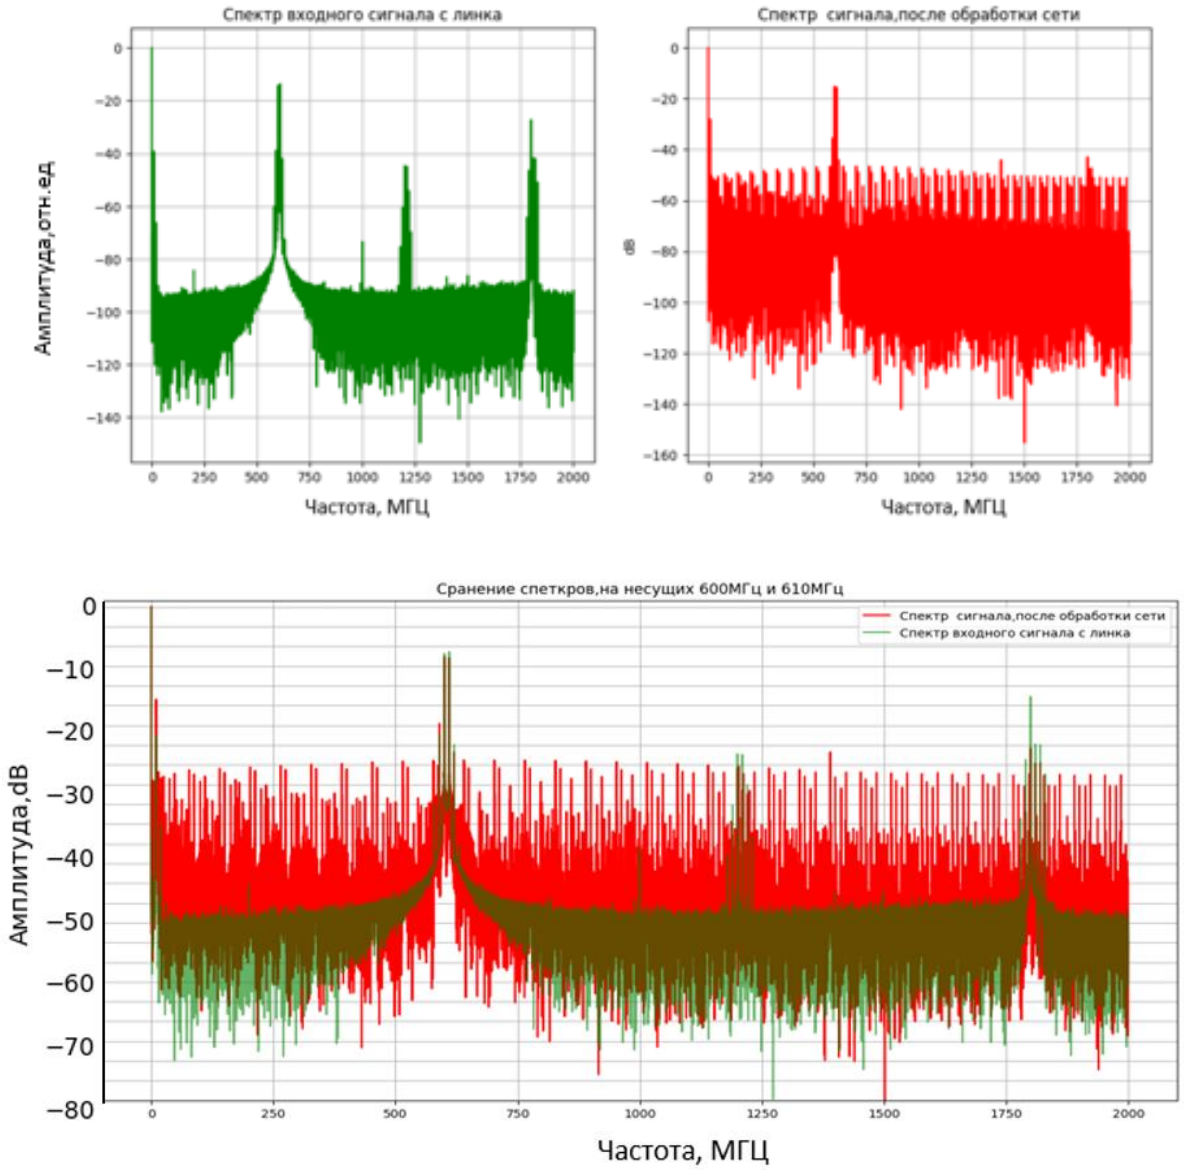


Рис. 4.13 Примеры спектров исходного зашумленного двухтонового сигнала (сумма частот 600 МГц и 610 МГц) и сигнала, полученного с использованием обученной НС.

Из на рис. 4.13 видно, что после нейросетевой обработки, в сигнале была устранена вторая гармоника и снижена по величине, составляющая третьей гармоники. Но при этом, в спектре присутствуют дополнительные составляющие, которые отсутствовали в исходном сигнале.

Выводы по четвертой главе

1. Продемонстрирована возможность использования нейросетевых подходов для подавления искажений выходного сигнала аналоговых оптических трактов, обусловленных нелинейностью их элементов. Сверточная нейронная сеть, обученная на однотоновых сигналах, способна качественно восстанавливать форму для сигналов частот, использованных в обучающей выборке.

3. Для однотоновых сигналов на частотах, не входивших в обучающую выборку, после нейросетевой обработке наблюдаются дополнительные частоты. При обучении на синтезированных многотоновых сигналах нейронная сеть позволяет восстановить форму двухтоновых сигналов и устранить вторую гармонику, но не подавить разностные составляющие.

5. Нейросетевая обработка приводит к возникновению периодических составляющих по всему спектру, как для однотоновых, так и для двухтоновых сигналов.

5. Нейросетевой криптоанализ системы оптического кодирования с пространственно-некогерентным освещением

Современные методы криптоанализа систем оптического кодирования, как правило, рассматривают системы на основе метода. Они, обычно основаны на использовании НС для декодирования изображения, то есть НС напрямую преобразует кодированное изображение в исходное без необходимости применения дополнительных методов обработки.

Для кодирования с пространственно-некогерентным освещением перспективным является подход, основанный на воссоздании ключа из кодированного изображения. Это позволяет облегчить процесс обучения НС, по сравнению с моделями, основанными на воссоздании исходных изображений, поскольку в случае оптического кодирования с пространственно-некогерентным освещением размер ключа кодирования составляет около четверти линейного размера исходного изображения, по сравнению с DRPE, где их размеры одинаковы. Обработка изображений с более высоким разрешением с использованием НС потребовала бы значительно больше вычислительных ресурсов (обучение занимает на 65% больше времени, если кодированные изображения равны по размеру исходным изображениям).

В данной работе впервые реализован нейросетевой метод криптоанализа системы оптического кодирования с пространственно-некогерентным освещением. Схема метода приведена на рис. 5.1.

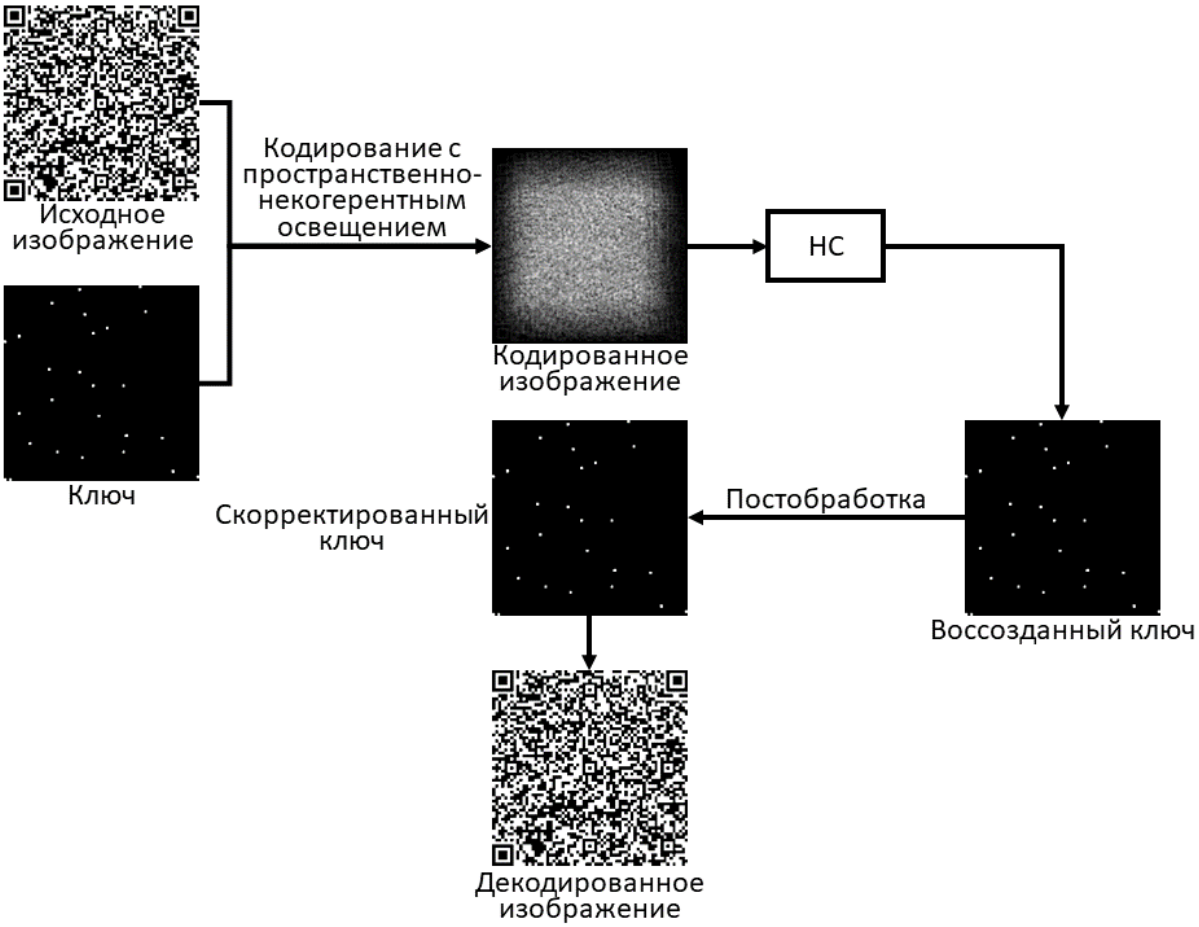


Рис. 5.1 Схема предлагаемого метода воссоздания ключей кодирования из изображений, оптически кодированных в пространственно-некогерентном освещении (ключи кодирования и исходные изображения для наглядности).

Разработанный НС метод выполняет воссоздание ключей из изображений, кодированных в пространственно-некогерентном освещении, что позволяет декодировать исходные изображения.

5.1 Численное моделирование оптического кодирования с пространственно-некогерентным освещением

Для обучения НС воссозданию ключей из изображений, кодированных в пространственно-некогерентном освещении, потребуется создание обучающей выборки из численно-кодированных изображений.

Численная модель оптического кодирования описывает свертку исходного изображения и ключа кодирования. Также могут моделироваться

различные типы искажений, которые возникают в оптической системе, такие как:

- шум фотосенсора,
- оптические аберрации,
- разностью растров между фотосенсором и ПВМС,
- шум синтеза ДОЭ,
- переотражения от оптических поверхностей [117].

Наибольшее влияние на качество кодированных изображений, по сравнению с другими типами искажений, оказывает аддитивный шум фотосенсора. За счет этого использовалась упрощенная численная модель оптического кодирования, которая учитывала только шум фотосенсора. Использование упрощенной модели позволит ускорить процесс создания обучающих выборок, но при применении НС, обученной на таких выборках для воссоздания ключей из изображений, кодированных в ходе оптического эксперимента, потребуется постобработка воссозданных ключей, для имитации искажений, вносимых оптической системой.

Ключ кодирования – это изображение, содержащее распределение кодирующих элементов (как правило, белых точек), они располагаются на поле ключа так, чтобы полученный фурье-спектр являлся максимально равномерным. Для бинарных ключей количество кодирующих элементов описывается с помощью нормированной средней энергии (НСЭ) [118]. НСЭ определяется как отношение количества кодирующих элементов к полному числу пикселей ключа. Например, ключ с разрешением 64×64 пикселя и НСЭ 0,005 имеет примерно 20 кодирующих элементов. В процессе численного моделирования от исходных численных ключей с использованием алгоритма ГС рассчитываются КГ. В процессе моделирования процесса кодирования выполняется восстановление изображений из этих КГ в плоскости фотосенсора, восстановленное изображение в данном случае будет

представлять собой ФРТ КГ, а его свертка с исходным – кодированное изображение.

Ключ кодирования также может быть использован для декодирования изображения и извлечения информации. Кодирование с пространственно-некогерентном освещением может быть записано как:

$$g(i,j) = f(i,j) \otimes h(i,j) + n(i,j), \quad (5.1)$$

где $g(i,j)$ – кодированное изображение, $f(i,j)$ – исходное изображение, $h(i,j)$ – ФРТ КГ, и $n(i,j)$ – шум фотосенсора, i, j – индексы отсчетов изображений.

Фурье-спектр кодированного изображения можно записать в виде:

$$G(u,v) = F(u,v) * H(u,v) + N(u,v), \quad (5.2)$$

где G, F, H, N – фурье-спектры кодированного изображения, исходного изображения, ФРТ КГ, и шума фотосенсора соответственно, u, v – индексы отсчетов в Фурье плоскости.

Фурье-спектр декодированного изображения можно записать в виде:

$$F'(u,v) = G(u,v) * H^{-1}(u,v), \quad (5.3)$$

где F', G – Фурье-спектры декодированного и кодированного изображений соответственно, H^{-1} – фильтр декодирования.

Таким образом, если известен ключ кодирования $h(i,j)$, то поэлементное умножение спектра Фурье кодированного изображения на фильтр декодирования позволяет получить спектр Фурье исходного изображения.

Процесс декодирования – это обратная задача, заключающаяся в нахождении операции декодирования, которая преобразует кодированное изображение в исходное. Это некорректно поставленная задача, которая требует дополнительной регуляризации. В данной работе используется метод регуляризации Тихонова [119]. В качестве сглаживающей функции использовалось максимальное значение спектра мощности ФРТ.

$$K(u,v,\alpha) = \frac{|H(u,v)|^*}{|H(u,v)|^2 + \alpha * max(|H(u,v)|^2)}, \quad (5.4)$$

где $K(u,v,\alpha)$ – фильтр декодирования, α – параметр регуляризации. H^* – комплексно-сопряженный фурье-спектр исходного изображения.

Данная численная модель оптического кодирования с пространственно-некогерентным освещением была использована для синтеза обучающих выборок для обучения разработанной НС воссозданию ключей кодирования.

5.2 Архитектура нейронной сети для криптоанализа оптического кодирования

Разработанный метод основывается на архитектуре U-Net [58]. Данная реализация U-Net (рис. 5.2) имеет три основных отличия от стандартной:

1. Все сверточные слои, кроме последнего, в котором используется функция активации LeakyReLU [49], используют функцию активации Swish [50], которая демонстрирует хорошие результаты для восстановления изображений, подобных ключам кодирования в голографии [63].
2. Первый слой НС уменьшает размеры одноканальных входных изображений (320×320 пикселей) за счет использования техники чередования пикселей для их перегруппировки в несколько каналов для повышения вычислительной производительности. В данной модели используется шаг чередования $S = 4$, что позволяет изменить размерность входных изображений с 320×320×1 до 80×80×16. Такой подход позволяет снизить вычислительную нагрузку за счет уменьшения разрешения исходного изображения без потери пространственной информации.
3. Выходной блок был изменен, в соответствии с размером ключей кодирования (71×71 пиксель).

Поскольку поставленная задача требует сравнения двух изображений в процессе обучения, в качестве функции потерь использовалась СКО между

ключами кодирования из обучающей выборки и ключами, воссозданными НС.

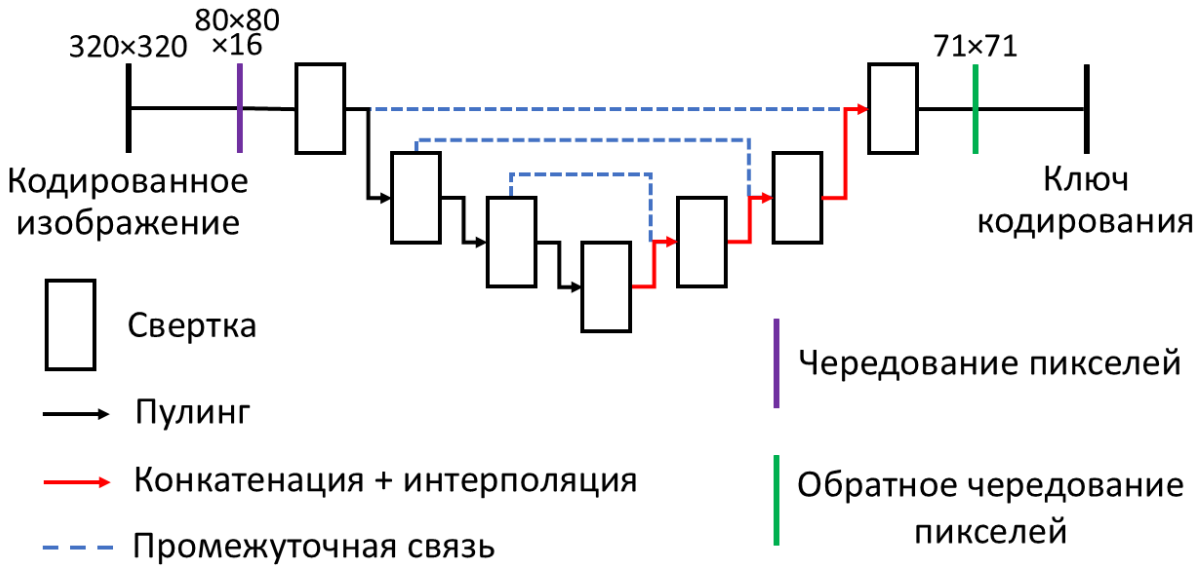


Рис. 5.2 Архитектура НС для криптоанализа систем оптического кодирования с пространственно-некогерентным освещением.

5.3 Воссоздание ключей из численно-синтезированных кодированных изображений

С использованием описанной численной модели оптического кодирования с пространственно-некогерентным освещением было создано две обучающие выборки. Одна была синтезирована без учета искажений оптической системы ($n(i,j) = 0$ – выборка №1), а вторая включала моделирование шума фотосенсора научной камеры (выборка № 2). Это позволит оценить влияние наибольшей составляющей оптических искажений на работу обученной НС.

В качестве исходных изображений использовались QR коды, содержавшие последовательность случайных цифр. Использование высокочастотных контейнеров информации с возможностью коррекции ошибок [120], таких как QR коды, важно для оптического кодирования, поскольку они помогают компенсировать влияние оптических шумов и

искажений. Использовался коэффициент коррекции ошибок 30%, что является максимальным значением.

Обучающие выборки были построены из кодированных изображений и соответствующих им ключей кодирования. Размеры изображений составляли, 71×71 пиксель для ключей кодирования и 320×320 пикселей для кодированных изображений. Эти разрешения были выбраны для оптимальной скорости обучения НС.

Для исследования зависимости между размером выборки и точностью работы обученной НС использовались обучающие выборки из 10, 20, 40, 80, 160 и 320 тысяч пар. НС была реализована на Python с использованием библиотеки Tensorflow и обучена на графическом процессоре NVIDIA GeForce RTX 2060 SUPER.

Численная оценка с использованием проверочного набора из 1000 кодированных изображений представлена на рис. 5.3. Критерием оценки является точность ключей, воссозданных обученной НС (точный ключ – ключ, в котором все кодирующие элементы расположены корректно).

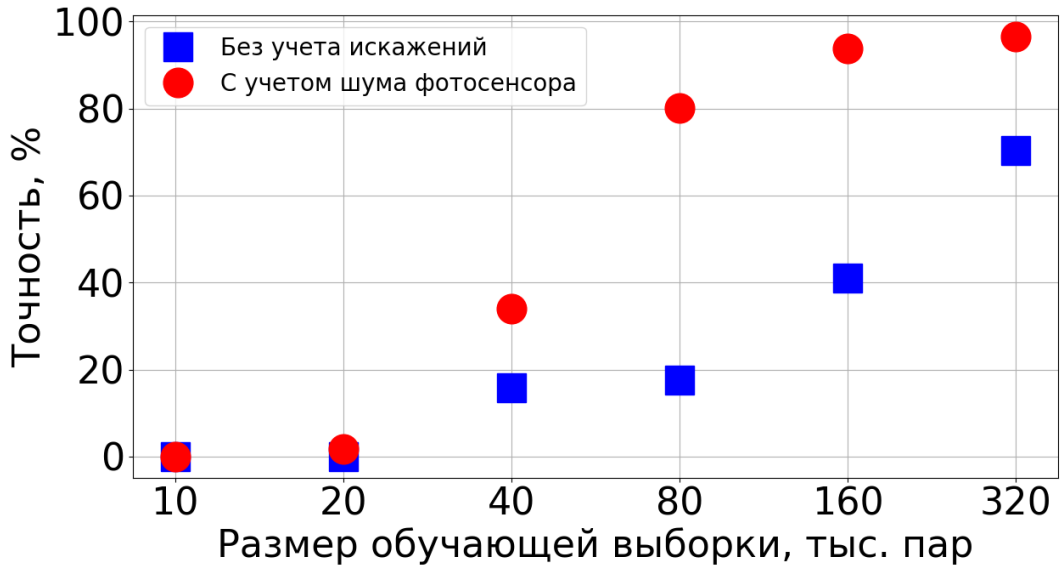


Рис. 5.3 Точность воссоздания ключей в зависимости от размера обучающих выборок.

Как видно из рис. 5.3, НС, обученная с использованием выборки, выборки №2 значительно превосходит по точности НС, обученную с

использованием выборки №1. НС №1 достигает точности 70%, в то время как НС №1 воссоздает корректные ключи с вероятностью 95% при 160 и 320 тысячах пар, причем разница между ними незначительна. Прирост точности за счет увеличения размера обучающей выборки до 320 тысяч пар не настолько значителен по сравнению с двукратным увеличением времени обучения. Поэтому все последующие эксперименты проводились с использованием обучающей выборки №2 из 160 тысяч пар.

5.4 Воссоздание ключей из оптически-зарегистрированных кодированных изображений

При тестировании на численно-синтезированных кодированных изображениях обученная НС показала способность воссоздавать правильные ключи кодирования напрямую, без дополнительной обработки. Однако это упрощенный случай, и воссоздание ключей из оптически зарегистрированных кодированных изображений потребует дополнительной обработки из-за шумов и искажений, вносимых оптической установкой.

Оптическая установка, которая использовалась для оптического кодирования QR кодов представлена на рис. 5.4.

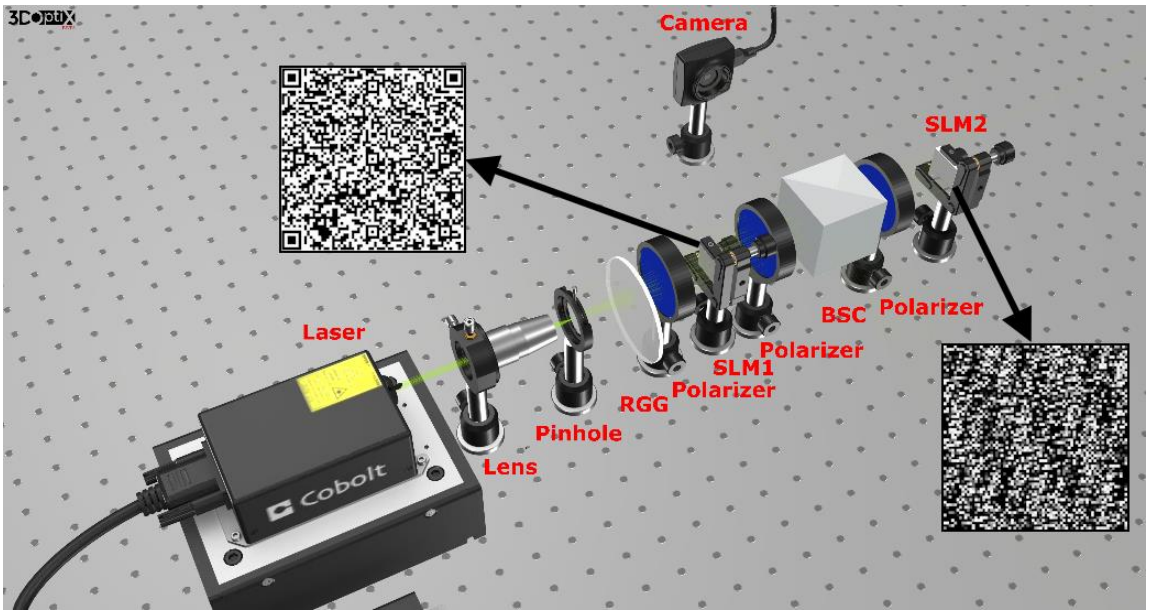


Рис. 5.4 Экспериментальная схема установки оптического кодирования с использованием пространственно-некогерентного освещения.

В качестве источника монохроматического когерентного света использовался волоконный лазер IPG Photonics VLM-561-5 с длиной волны 561 нм. Расходящийся пучок формировался с использованием микрообъективной линзы и диафрагмы. Пространственная когерентность пучка разрушалась вращающимся рассеивателем (тонким диском из матового стекла), что подавляло образование спекл-шума. Для отображения исходных изображений (QR кодов) использовался амплитудный жидкокристаллический (ЖК) ПВМС1 HoloEye LC2002 с разрешением 800×600 пикселей и размером пикселя 32 мкм. Для обеспечения оптимальной работы ПВМС использовались поляризаторы. Для вывода ДОЭ ключей кодирования использовался фазовый ЖК ПВМС2 HoloEye PLUTO VIS с разрешением 1920×1080 пикселей и размером пикселя 8 мкм. Светоделительный куб (СД) располагался таким образом, чтобы в плоскости фотосенсора камеры формировалась оптическая свертка изображения, отображаемого на ПВМС1 с ФРТ ДОЭ. Фокусное расстояние ДОЭ составляло 19 см. Для регистрации кодированных изображений использовалась КМОП-камера Vieworks VA-29MG2 с разрешением 6576×4384 пикс. и размером пикселя 5,5×5,5 мкм. Размер экспериментальной установки составлял около 50 см вдоль оси распространения света.

Чтобы проиллюстрировать разницу между численно-синтезированными (рис. 5.5) и оптически зарегистрированными (рис. 5.6) ключами, на показан пример каждого из них, в сравнении с аналогичным ключом, воссозданным с использованием обученной НС. Оптически зарегистрированный ключ имеет прямоугольную форму из-за разрешения ПВМС, используемого в оптической установке.



(а) (б)

Рис. 5.5 Численно-синтезированный ключ (а); ключ, воссозданный с использованием разработанной нейронной сети (б).

Как видно из рис. 5.5 исходный ключ и ключ, воссозданный с использованием разработанной нейронной сети из численно-синтезированного кодированного изображения неотличимы друг от друга, что позволит использовать воссозданный ключ для декодирования.



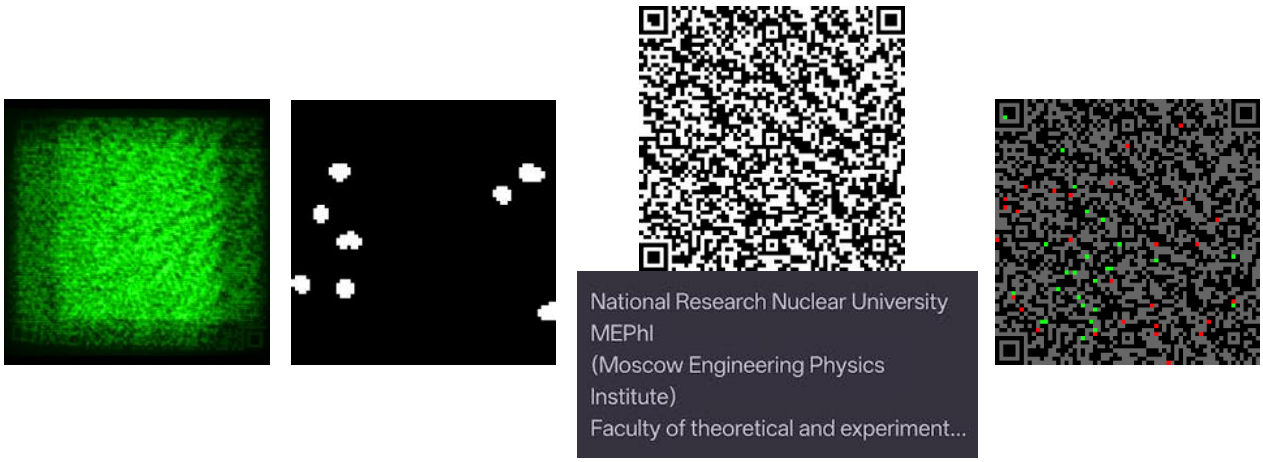
(а) (б) (в)

Рис. 5.6 Исходный ключ, использовавшийся для синтеза ДОЭ (а); ФРТ ДОЭ ключа кодирования, зарегистрированная на фотодетекторе (б); ключ, воссозданный разработанной НС (в).

Как показано на рис. 5.6, ключ, воссозданный с использованием разработанной НС, похож на оптически зарегистрированный, однако рассеяние кодирующих элементов не было корректно воспроизведено. В ключе, воссозданном с использованием нейронной сети, вместо рассеянных кодирующих элементов наблюдаются группы точек. Причиной этого являются дополнительные искажения в оптической установке по сравнению с численной моделью. Численная модель учитывает только шум фотосенсора

и не включает оптические аберрации, разность растров между фотосенсором и ПВМС, шум синтеза ДОЭ или переотражения от оптических поверхностей.

Постобработка ключа, воссозданного из оптически-зарегистрированного кодированного изображения, заключалась в локальном пороговом преобразовании Брэдли [121] и размытии кодирующих элементов в ключе с помощью фильтра Лапласиана Гаусса. Параметры размытия были выбраны на основе анализа параметров оптических ключей. Это было сделано для того, чтобы визуально приблизить воссозданный ключ к исходному оптически зарегистрированному ключу (рис. 5.6 б), где каждый кодирующий элемент представляет рассеянную точку. Благодаря такому подходу было достигнуто успешное декодирование изображения, с 54 (0,1%) ошибками в QR коде, что может быть эффективно скомпенсировано алгоритмом коррекции ошибок. Оптически-зарегистрированное кодированное изображение, скорректированный ключ, декодированный QR код и QR код с картой ошибок показаны на рис. 5.7.



(а) (б) (в) (г)

Рис. 5.7 Разработанная нейросетевая атака на систему оптического кодирования: зарегистрированное кодированное изображение (а); воссозданный ключ кодирования после пост-обработки (б); декодированное изображение (в); карта ошибок (г). Ошибочные белые пиксели выделены зеленым цветом, черные – красным. Декодированный QR код может быть успешно считан.

QR код, показанный на рис.5.7(в), может быть успешно считан с использованием смартфона. Таким образом, можно утверждать, что разработанный метод нейросетевого воссозданния ключей кодирования может быть эффективно применен как к численно-синтезированным, так и оптически-зарегистрированным изображениям.

Полученные результаты показывают, что разработанный метод криптоанализа может быть эффективно использован для поиска уязвимостей в системах оптического кодирования с пространственно-некогерентным освещением, в первую очередь к атакам на основе применения машинного обучения, которые в области оптического кодирования остаются слабо изучены. Разработанная НС была обучена с использованием упрощенной численной модели кодирования, которая учитывала только шум фотосенсора. Согласно принципу Керкгоффса, неизвестной частью криптографической системы является только ключ кодирования, что говорит о возможности создания численно-синтезированных обучающих выборок, которые точно моделируют конкретные системы оптического кодирования с пространственно-некогерентным освещением. Это может позволить более эффективно воссоздавать ключи из оптически-зарегистрированных кодированных изображений, и упростить или избежать постобработки ключа, которая была необходима при применении упрощенной численной модели оптического кодирования.

Выводы по пятой главе

1. Разработан нейросетевой метод криптографического анализа системы оптического кодирования с пространственно-некогерентным освещением. Метод основан на воссоздании ключей из кодированных изображений.
2. Показано, что добавление шума фотосенсора в численную модель, используемую для создания обучающей выборки, приводит к значительному росту точности нейронной сети в случае обработки численно-синтезированных кодированных изображений (70% для модели без учета шума фотосенсора, 95% – для модели с учетом).
3. Было показано, что оптимальных размер обучающей выборки для разработанной нейронной сети составляет 160 тысяч пар. Дальнейшее увеличение не приводит к значительному повышению точности, но растет время обучения.
4. Дополнительная постобработка воссозданного ключа кодирования, заключающаяся в применении локального порогового преобразования Брэдли и фильтра лапласиана Гаусса, позволяет успешно декодировать оптически зарегистрированные изображения.

Заключение

В результате проведенных исследований получены следующие основные результаты и выводы:

1. Для синтеза компьютерных голограмм, содержащих изображения 3D- и цветных сцен, разработана физически-информированная архитектура нейронной сети, интегрирующая численную модель расчета дифракции Френеля. Разработанная нейронная сеть может быть использована для синтеза голограмм со значениями параметров дифракции, отличными от использованных при обучении.
2. Предложенный нейросетевой метод может на порядок повысить скорость синтеза голограмм 3D-сцен по сравнению с итеративными алгоритмами при сохранении качества восстановленного изображения: результаты численных и оптических экспериментов показывают, что значения коэффициента корреляции совпадают с точностью 99,5%.
3. Применение предложенной архитектуры нейронной сети для синтеза голограмм изображений цветных сцен позволяет восстанавливать их без возникновения искажений в виде ложных элементов, свойственных итеративным алгоритмам.
4. Разработан метод создания оптимальных обучающих выборок, предназначенных для нейросетевого синтеза и фильтрации голограмм, основанный на использовании графических примитивов. Показано, что нейронные сети, обученные с помощью данных выборок, могут синтезировать голограммы, содержащие изображения объектов различных классов (контурные, бинарные, естественные полутоновые).
5. Разработан метод удаления нулевого порядка дифракции, основанный на извлечении амплитудной и фазовой информации объектной волны в плоскости голограммы. Применение разработанного метода в комбинации с частотной фильтрацией позволяет достигнуть увеличения индекса структурного сходства восстановленного изображения в 2,5 раза по сравнению с применением только частотной фильтрации.

6. Предложенная нейросетевая обработка сигналов аналоговых оптических трактов позволяет подавить искажения выходного сигнала тракта, обусловленные нелинейностью его элементов.

7. В рамках криптографического анализа системы оптического кодирования с пространственно-некогерентным излучением показано, что подход на основе нейросетевого воссоздания ключа кодирования способен обеспечить корректное извлечение кодированной информации в 95% случаев.

Список литературы

1. Gerchberg R. W. A practical algorithm for the determination of phase from image and diffraction plane pictures // Optik. 1972. V. 35. P. 237–246.

2. Soifer V. A., Doskolovich L. L., Kazanskiy N. L. Methods for Computer Design of Diffractive Optical Elements. USA, Wiley, 2002.

3. Yamamoto Y. et al. Large-scale electroholography by HORN-8 from a point-cloud model with 400,000 points // Opt. Express. 2018. V. 26, No. 26. P. 34259.

4. Lu T., Chao T.-H. Advances in Pattern Recognition Research. Nova Science Publishers, 2018.

5. Soĭfer V. A., Kotlyar V., Doskolovich L. Iterative methods for diffractive optical elements computation. Taylor & Francis, 1997.

6. Cuche E., Marquet P., Depeursinge C. Spatial filtering for zero-order and twin-image elimination in digital off-axis holography // Appl. Opt. 2000. V. 39, No. 23. P. 4070.

7. Stoykova E., Kang H., Park J. Twin-image problem in digital holography-a survey (Invited Paper) // Chinese Optics Letters. 2014. V. 12, No. 6. P. 060013.

8. Zhang W. et al. Twin-Image-Free Holography: A Compressive Sensing Approach // Physical Review Letters. 2018. V. 121, No. 9.

9. Cuche E., Marquet P., Depeursinge C. Spatial filtering for zero-order and twin-image elimination in digital off-axis holography // Appl. Opt. 2000. V. 39, No. 23. P. 4070.

10. Kreis T. M. Suppression of the dc term in digital holography // Optical Engineering. 1997. V. 36, No. 8. P. 2357.

11. Griffin L. D. Mean, median and mode filtering of images // Proceedings of the Royal Society of London. Series A: Mathematical, Physical and Engineering Sciences. 2000. V. 456, No. 2004. P. 2995–3004.

12. Cheremkhin P. A. et al. Comparison of methods of suppression of undesired diffraction orders at numerical reconstruction of digital Fresnel holograms // Optics and Photonics for Information Processing VIII. SPIE. 2014. V. 9216. P. 374-382.

13. Рымов Д., Черёмхин П. Неитеративный нелинейный метод фильтрации порядков дифракции в цифровой голографии // VIII Международная

конференция по фотонике и информационной оптике. Москва, 2019. С. 729–730.

14. Charles H. CoxIII. Optical Links: Theory and Practice. Cambridge University Press, 2006.

15. Nebavskiy V. A., Starikov R. S., Cheremkhin P. A. Linearization methods for analog optical paths // Achievements of Modern Radioelectronics. 2021. V. 75. No. 12. P. 42-62.

16. Wang Y. et al. Optical multi-image encryption based on chaotic fingerprint phase mask and multi-slice diffractive imaging // Journal of Optics. 2024. V. 53. No. 5. P. 4997-5009.

17. Hazer A., Yıldırım R. A review of single and multiple optical image encryption techniques // Journal of Optics. 2021. V. 23, No. 11. P. 113501.

18. Verma G. Nonlinear image encryption based on phase truncation and phase retrieval operation // Journal of Optics. 2023. V. 53. No. 5. P. 4159-4169.

19. Yu S.-S. et al. Optical image encryption algorithm based on phase-truncated short-time fractional Fourier transform and hyper-chaotic system // Opt. Lasers Eng. 2020. V. 124. P. 105816.

20. Sun G. et al. A novel optical video cryptosystem based on improved 3D arnold transform in gyrator domains // Opt. Laser Technol. 2024. V. 168. P. 109891.

21. Alexis Jaramillo-Osorio J. et al. Focus-tunable experimental optical cryptosystem // Opt. Laser Technol. 2022. V. 148. P. 107689.

22. Wang L., Wu Q., Situ G. Chosen-plaintext attack on the double random polarization encryption // Opt. Express. 2019. V. 27, No. 22. P. 32158.

23. Nishchal N. K. Optical Cryptosystems. IOP Publishing, 2019.

24. Chiu R. et al. Images cipher based on convolution with chaotic maps and retrieving using the alternating direction method of multipliers // Opt. Laser Technol. 2023. V. 167. P. 109680.

25. Chen H. et al. Asymmetric optical cryptosystem for multiple images based on devil’s spiral Fresnel lens phase and random spiral transform in gyrator domain // Sci. Rep. 2021. V. 11, No. 1. P. 20846.

26. Wu T. et al. Optical Encryption Based on Computer Generated Holograms in Photopolymer // Polymers (Basel). 2021. V. 13, No. 9. P. 1358.

27. Yu H. et al. Optical image encryption scheme with extended visual cryptography and non-mechanical ptychographic encoding // Journal of Optics. 2022. V. 24, No. 3. P. 035702.

28. Hadj Brahim A., Ali Pacha A., Hadj Said N. An image encryption scheme based on a modified AES algorithm by using a variable S-box // Journal of Optics. 2023. V. 53. No. 2. P. 1170-1185.

29. Kaur M., Singh S., Kaur M. Computational Image Encryption Techniques: A Comprehensive Review // Math. Probl. Eng. 2021. V. 2021. P. 1–17.

30. Refregier P., Javidi B. Optical image encryption based on input plane and Fourier plane random encoding // Opt. Lett. 1995. V. 20, No. 7. P. 767.

31. Tajahuerce E. et al. Optical security and encryption with totally incoherent light // Opt. Lett. 2001. V. 26, No. 10. P. 678.

32. Sahoo S. K., Tang D., Dang C. Enhancing security of incoherent optical cryptosystem by a simple position-multiplexing technique and ultra-broadband illumination // Sci. Rep. 2017. V. 7, No. 1. P. 17895.

33. Evtikhiev N. N. et al. High-speed implementation of holographic and diffraction elements using digital micromirror devices // Quantum Elec. 2020. V. 50, No. 7. P. 667–674.

34. Zlokazov E. Y. Methods and algorithms for computer synthesis of holographic elements to obtain a complex impulse response of optical information processing systems based on modern spatial light modulators // Quantum Elec. 2020. V. 50, No. 7. P. 643–652.

35. Javidi B. et al. Roadmap on optical security // Journal of Optics. 2016. V. 18, No. 8. P. 083001.

36. Frauel Y. et al. Resistance of the double random phase encryption against various attacks. // Opt. Express. 2007. V. 15, No. 16. P. 10253–10265.

37. Zhang C. et al. Ciphertext-only attack on a joint transform correlator encryption system // Opt. Express. 2013. V. 21, No. 23. P. 28523.

38. Liao M. et al. Ciphertext-only attack on optical cryptosystem with spatially incoherent illumination: from the view of imaging through scattering medium // Sci. Rep. 2017. V. 7, No. 1. P. 41789.

39. Liao M. et al. Deep-learning-based ciphertext-only attack on optical double random phase encryption // Opto-Electronic Advances. 2021. V. 4, No. 5. P. 200016–200016.

40. Bhangale K. B., Kothandaraman M. Survey of Deep Learning Paradigms for Speech Processing // Wirel. Pers. Commun. 2022. V. 125, No. 2. P. 1913–1949.

41. Shi W. et al. Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network // Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2016. P. 1874–1883.

42. Singhal P. et al. A Survey: Approaches to Facial Detection and Recognition with Machine Learning Techniques. Proceedings of Second Doctoral Symposium on Computational Intelligence: DoSCI 2021. Springer Singapore, 2021. P. 103-125.

43. Xie L. et al. Scene recognition: A comprehensive survey // Pattern Recognit. 2020. V. 102. P. 107205.

44. Gu J. et al. Recent advances in convolutional neural networks // Pattern Recognit. 2018. V. 77. P. 354-377.

45. Zheng H. et al. Computing 3D Phase-Type Holograms Based on Deep Learning Method // Photonics. 2021. V. 8, No. 7. P. 280.

46. Dhillon A., Verma G. K. Convolutional neural network: a review of models, methodologies and applications to object detection // Progress in Artificial Intelligence. 2020. V. 9, No. 2. P. 85–112.

47. Ioffe S., Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. International conference on machine learning. pmlr, 2015. P. 448-456.

48. Householder A. S. A theory of steady-state activity in nerve-fiber networks: I. Definitions and preliminary lemmas // Bull. Math. Biophys. 1941. V. 3, No. 2. P. 63–69.

49. Xu B. et al. Empirical Evaluation of Rectified Activations in Convolutional Network. 2015. arXiv preprint. 2015. arXiv:1505.00853.

50. Prajit Ramachandran B. Z. Q. V. Le. Swish: a Self-Gated Activation Function. arXiv preprint. 2017. arXiv:1710.05941.

51. Hossein Eybposh M. et al. DeepCGH: 3D computer-generated holography using deep learning // Opt. Express. 2020. V. 28, No. 18. P. 26636-26650.

52. Janocha K., Czarnecki W. M. On Loss Functions for Deep Neural Networks in Classification // arXiv preprint. 2017. arXiv:1702.05659.

53. Lecun Yann. The MNIST database of handwritten digits [Электронный ресурс] // http://Yann.Lecun.Com/Exdb/Mnist/.

54. Jonnalagadda A. et al. Convolutional neural network model observers discount signal-like anatomical structures during search in virtual digital breast tomosynthesis phantoms // Journal of Medical Imaging. 2025. V. 12, No. 05.

55. Shao W. et al. Generation of Digital Brain Phantom for Machine Learning Application of Dopamine Transporter Radionuclide Imaging // Diagnostics. 2022. V. 12, No. 8. P. 1945.

56. He K. et al. Deep Residual Learning for Image Recognition // 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2016.

57. Bengio Y., Simard P., Frasconi P. Learning long-term dependencies with gradient descent is difficult // IEEE Trans. Neural Netw. 1994. V. 5, No. 2. P. 157–166.

58. Ronneberger O., Fischer P., Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation // International Conference on Medical image computing and computer-assisted intervention. 2015. V. 9351. P. 234–241.

59. Xu Z., Zuo S., Lam E. Y. End-to-end learning for digital hologram reconstruction // Proc. SPIE. 2018. V. 10505. P. 1050510.

60. Chen H. et al. Fourier Imager Network (FIN): A deep neural network for hologram reconstruction with superior external generalization // Light Sci. Appl. Springer Nature, 2022. V. 11, No. 1.

61. Rivenson Y. et al. Deep learning microscopy // Optica. 2017. V. 4. No. 11. P. 1437-1443.

62. Ju Y.-G., Choo H.-G., Park J.-H. Learning-based complex field recovery from digital hologram with various depth objects // Opt. Express. 2022. V. 30, No. 15. P. 26149.

63. Shao S. et al. Machine learning holography for 3D particle field imaging // Opt. Express. 2020. V. 28, No. 3. P. 2987-2999.

64. Wu Y. et al. Dense-U-net: Dense encoder–decoder network for holographic imaging of 3D particle fields // Opt. Commun. 2021. V. 493. P. 126970.

65. Wang K. et al. Y-Net: a one-to-two deep learning framework for digital holographic reconstruction // Opt. Lett. 2019. V. 44, No. 19. P. 4765-4768.

66. Svistunov A. S. et al. HoloForkNet: Digital Hologram Reconstruction via Multibranch Neural Network // Applied Sciences (Switzerland). 2023. V. 13, No. 10. P. 6125.

67. Chen B. et al. Deep-Learning Multiscale Digital Holographic Intensity and Phase Reconstruction // Applied Sciences (Switzerland). 2023. V. 13, No. 17. P. 9806.

68. Wang K. et al. Y4-Net: a deep learning solution to one-shot dual-wavelength digital holographic reconstruction // Opt. Lett. 2020. V. 45, No. 15. P. 4220.

69. Pan Z. et al. Recent Progress on Generative Adversarial Networks (GANs): A Survey // IEEE Access. 2019. V. 7. P. 36322–36333.

70. Senthilkumar S. et al. Advanced Progress in Optimized Generative Adversarial Network Applications Across Domains: A Comprehensive Survey // Archives of Computational Methods in Engineering. 2026. V. 33, No. 1. P. 1467–1483.

71. Pan X. et al. Drag Your GAN: Interactive Point-based Manipulation on the Generative Image Manifold // Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Proceedings. 2023. P. 1–11.

72. Rymov D. A. et al. 3D-CGH-Net: Customizable 3D-hologram generation via deep learning // Opt. Lasers Eng. 2025. V. 184. P. 108645.

73. Zhu S.-P. et al. Physics-informed machine learning and its structural integrity applications: state of the art // Philosophical Transactions of the Royal Society A. 2023. V. 381. No. 2260. P. 20220406.

74. Banerjee C. et al. Physics-Informed Computer Vision: A Review and Perspectives // ACM Comput. Surv. 2025. V. 57, No. 1. P. 1–38.

75. Liu S.-C., Chu D. Deep learning for hologram generation // Opt. Express. 2021. V. 29, No. 17. P. 27373.

76. Velez-Zea A., Fredy Barrera-Ramírez J., Torroba R. Improved phase hologram generation of multiple 3D objects // Appl. Opt. 2022. V. 61, No. 11. P. 3230.

77. Horisaki R., Takagi R., Tanida J. Deep-learning-generated holography // Appl. Opt. 2018. V. 57, No. 14. P. 3859-3863.

78. Lee J. et al. Deep neural network for multi-depth hologram generation and its training strategy // Opt. Express. 2020. V. 28, No. 18. P. 27137-27154.

79. Horisaki R. et al. Three-dimensional deeply generated holography [Invited] // Appl. Opt. 2021. V. 60, No. 4. P. A323-A328.

80. Shi L. et al. Towards real-time photorealistic 3D holography with deep neural networks // Nature. 2021. V. 591, No. 7849. P. 234–239.

81. Liu N. et al. Propagation-adaptive 4K computer-generated holography using physics-constrained spatial and Fourier neural operator // Nat. Commun. 2025. V. 16, No. 1. P. 7761.

82. Schnars U. et al. Digital Holography and Wavefront Sensing: Principles, Techniques and Applications. Berlin Heidelberg: Springer-Verlag.

83. Verrier N., Atlan M. Off-axis digital hologram reconstruction: some practical considerations // Appl. Opt. 2011. V. 50, No. 34. P. H136.

84. Cheremkhin P. A. et al. Demonstration of digital hologram recording and 3D-scenes reconstruction in real-time // Proc. SPIE. 2016. V. 9889. P. 98891M.

85. Cuche E., Marquet P., Depeursinge C. Spatial filtering for zero-order and twin-image elimination in digital off-axis holography // Appl. Opt. 2000. V. 39, No. 23. P. 4070.

86. Kiriy S. A. et al. Generative adversarial neural network for 3D-hologram reconstruction // Laser Phys. Lett. 2024. V. 21, No. 4. P. 045201.

87. Yin D. et al. Digital holographic reconstruction based on deep learning framework with unpaired data // IEEE Photonics J. Institute of Electrical and Electronics Engineers Inc., 2020. V. 12, No. 2. P. 1-12.

88. Zeng T., So H. K.-H., Lam E. Y. RedCap: residual encoder-decoder capsule network for holographic image reconstruction // Opt. Express. 2020. V. 28, No. 4. P. 4876.

89. Ren Z., Xu Z., Lam E. Y. End-to-end deep learning framework for digital holographic reconstruction // Advanced Photonics. 2019. V. 1, No. 1. P. 1–12.

90. Rivenson Y. et al. Phase recovery and holographic image reconstruction using deep learning in neural networks // Light Sci. Appl. 2018. V. 7, No. 2. P. 17141.

91. Huang L. et al. Holographic Image Reconstruction with Phase Recovery and Autofocusing Using Recurrent Neural Networks // ACS Photonics. American Chemical Society, 2021. V. 8, No. 6. P. 1763–1774.

92. Velez-Zea A. et al. Generation and experimental reconstruction of optimized Fresnel random phase-only holograms // Journal of Optics. 2021. V. 23, No. 5. P. 055602.

93. Li H. et al. Deep DIH: Single-Shot Digital In-Line Holography Reconstruction by Deep Learning // IEEE Access. Institute of Electrical and Electronics Engineers Inc., 2020. V. 8. P. 202648–202659.

94. Wang H., Lyu M., Situ G. eHoloNet: a learning-based end-to-end approach for in-line digital holographic reconstruction // Opt. Express. 2018. V. 26, No. 18, P. 22603-22614.

95. Zhang Y. et al. PhaseGAN: a deep-learning phase-retrieval approach for unpaired datasets // Opt. Express. Optica Publishing Group, 2021. V. 29, No. 13. P. 19593.

96. Cheng H. et al. Phase retrieval algorithm based on the neural network and the GS // Holography, Diffractive Optics, and Applications IX, 2019 V. 11188, P. 36-43.

97. Park S., Kim Y., Moon I. Fast automated quantitative phase reconstruction in digital holography with unsupervised deep learning // Optics and Lasers in Engineering. 2023. V. 167 P. 107624.

98. Xu S. et al. Deep-learning-powered photonic analog-to-digital conversion // Light Sci. Appl. 2019. V. 8, No. 1. P. 66.

99. Huang H. et al. Deep-Learning-Based Millimeter-Wave Massive MIMO for Hybrid Precoding // IEEE Trans. Veh. Technol. 2019. V. 68, No. 3. P. 3027–3032.

100. Pereira L. A. M. et al. Linearization Schemes for Radio Over Fiber Systems Based on Machine Learning Algorithms // IEEE Photonics Technology Letters. 2022. V. 34, No. 5. P. 279–282.

101. Pereira L. A. M. et al. Machine Learning-Based Linearization Schemes for Radio Over Fiber Systems // IEEE Photonics J. 2022. V. 14, No. 6. P. 1–10.

102. Yi A. et al. Factorized Fourier Operator Based Neural Network for Fiber Nonlinearity Compensation in Coherent Optical Communication Systems // Journal of Lightwave Technology. 2025. V. 43, No. 8. P. 3612–3622.

103. Abdullah M. et al. Nonlinearity compensation for terahertz communications through neural networks // Opt. Express. 2025. V. 33, No. 5. P. 11178.

104. Zhao J. et al. Second-Order Perturbation-Based Nonlinearity Compensation Using BiLSTM Neural Network in Optical Transmission Systems // Journal of Lightwave Technology. 2025. V. 43, No. 11. P. 5140–5148.

105. Zhang T. et al. Multi-channel photonic sampled ADC with hybrid deep-learning for distortion recovery // Opt. Commun. 2025. V. 574. P. 131192.

106. Yang S. et al. A complex-valued neural network approach to passive intermodulation suppression // Physical Communication. 2026. V. 75. P. 103050.

107. Hai H. et al. Cryptanalysis of random-phase-encoding-based optical cryptosystem via deep learning // Opt. Express. 2019. V. 27, No. 15. P. 21204-21213

108. Liao M. et al. Deep-learning-based ciphertext-only attack on optical double random phase encryption // Opto-Electronic Advances. 2021. V. 4, No. 5. P. 200016.

109. Chen L. et al. Plaintext attack on joint transform correlation encryption system by convolutional neural network // Opt. Express. 2020. V. 28, No. 19. P. 28154.

110. Wu C. et al. Cryptoanalysis of the modified diffractive-imaging-based image encryption by deep learning attack // J. Mod. Opt. 2020. V. 67, No. 17. P. 1398–1409.

111. Qin Y., Wan Y., Gong Q. Learning-based chosen-plaintext attack on diffractive-imaging-based encryption scheme // Opt. Lasers Eng. 2020. V. 127. P. 105979.

112. Zhou L., Xiao Y., Chen W. Learning-based attacks for detecting the vulnerability of computer-generated hologram based optical encryption // Opt. Express. 2020. V. 28, No. 2. P. 2499.

113. Zhou L., Xiao Y., Chen W. Vulnerability to machine learning attacks of optical encryption based on diffractive imaging // Opt. Lasers Eng. 2020. V. 125. P. 105858.

114. Wang X., Wei H. Cryptanalysis of compressive interference-based optical encryption using a U-net deep learning network // Opt. Commun. 2022. V. 507. P. 127641.

115. Zhuang X., Yan A. Deep-learning-based ciphertext-only attack on optical scanning cryptosystem // Opt. Laser Technol. 2023. V. 157. P. 108744.

116. He W. et al. A learning-based method of attack on optical asymmetric cryptosystems // Opt. Lasers Eng. 2021. V. 138. P. 106415.

117. Cheremkhin P. A. et al. Lensless optical encryption with speckle-noise suppression and QR codes // Appl. Opt. 2021. V. 60, No. 24. P. 7336–7345.

118. Evtikhiev N. N. et al. Multi-Factor Model of an Optical Encryption System with Spatially Incoherent Illumination // Optoelectronics, Instrumentation and Data Processing. 2020. V. 56, No. 2. P. 176–182.

119. Tykhonoff A. N., Arsenin V. Y. Solutions of Ill-posed Problems. Vh Winston, 1977.

120. Gazi O. Forward Error Correction via Channel Coding. Cham: Springer International Publishing, 2020.

121. Bradley D., Roth G. Adaptive Thresholding using the Integral Image // Journal of Graphics Tools. 2007. V. 12, No. 2. P. 13–21.